VIN DATATHON 2026

Báo cáo EDA & Chất lượng dữ liệu

Mô tả dữ liệu, kiểm tra missing / trùng lặp / dữ liệu không hợp lệ / ràng buộc nghiệp vụ / outlier

---

Ngày tạo: 15/10/2026
Nguồn nội dung:

- reports/markdown/00_data_overview.md
- reports/markdown/data_quality_and_eda.md

Mô tả tổng quan dữ liệu

Bộ dữ liệu mô phỏng hoạt động của một doanh nghiệp thương mại điện tử thời trang tại Việt Nam, giai đoạn **04/07/2012 – 31/12/2022**. Gồm 13 tệp CSV trong `data/raw/`, chia thành 4 nhóm: **Master** (danh mục tham chiếu), **Transaction** (giao dịch), **Analytical** (tổng hợp) và **Operational** (vận hành).

> Số dòng/số cột được đếm trực tiếp từ `data/raw/`. Nếu dữ liệu nguồn thay đổi, chạy lại `python eda/data_quality_eda.py` và đối chiếu với `data/processed/eda/table_overview.csv`.

1. Tổng quan các bảng

STT	Tên bảng	Số dòng	Số cột	Ý nghĩa
	Bảng Master (danh mục)			
1	`customers`	121.930	7	Mỗi dòng là một khách hàng đã đăng ký tài khoản. Chứa mã bưu chính, thành phố, ngày đăng ký, giới tính, nhóm tuổi và kênh thu hút. Là thuộc tính **tĩnh**, dùng để mô tả và phân nhóm khách hàng.
2	`geography`	39.948	4	Mỗi dòng là một mã bưu chính (`zip`) và thành phố, vùng (East/Central/West), quận tương ứng. Dùng để gắn vị trí địa lý cho khách hàng và đơn hàng.
3	`products`	2.412	8	Mỗi dòng là một SKU (tên sản phẩm × size × màu). Chứa danh mục, phân khúc, giá niêm yết và giá vốn (COGS) **trên một đơn vị**.
4	`promotions`	50	10	Mỗi dòng là một chương trình khuyến mãi: loại (phần trăm/cố định), mức giảm, thời gian hiệu lực, danh mục áp dụng, kênh, khả năng cộng dồn và giá trị đơn tối thiểu.
	Bảng Transaction (giao dịch)			
5	`orders`	646.945	8	Mỗi dòng là một đơn hàng: ngày đặt, khách hàng, địa chỉ giao (`zip`), trạng thái, phương thức thanh toán, thiết bị và nguồn truy cập. Là bảng **trung tâm** để nối các bảng giao dịch khác.
6	`order_items`	714.669	7	Mỗi dòng là một sản phẩm trong một đơn: số lượng, đơn giá bán thực tế, số tiền giảm giá và tối đa 2 mã khuyến mãi. Đây là chỉ tiêu **phát sinh**, được cộng dồn để ra doanh thu.
7	`payments`	646.945	4	Mỗi dòng là khoản thanh toán của một đơn (quan hệ 1–1 với `orders`): phương thức, số tiền thanh toán, số kỳ trả góp. `payment_value` = Σ(số lượng × đơn giá − giảm giá) của đơn, **chưa gồm phí vận chuyển**.
8	`shipments`	566.067	4	Mỗi dòng là thông tin vận chuyển của một đơn đã gửi: ngày gửi, ngày giao, phí vận chuyển. Chỉ tồn tại với đơn ở trạng thái `shipped` / `delivered` / `returned` .
9	`returns`	39.939	7	Mỗi dòng là một lần trả hàng của một sản phẩm trong đơn: ngày trả, lý do, số lượng trả và số tiền hoàn.
10	`reviews`	113.551	7	Mỗi dòng là một đánh giá của khách hàng cho một sản phẩm trong đơn đã giao: ngày đánh giá, điểm (1–5), tiêu đề.
	Bảng Analytical (tổng hợp)			
11	`sales`	3.833	3	Mỗi dòng là doanh thu và giá vốn của **một ngày** (04/07/2012 – 31/12/2022, liên tục). Đây là chỉ tiêu **phát sinh**, cộng dồn được theo tháng/năm; là biến mục tiêu của bài toán dự báo. `Revenue` = Σ(số lượng × đơn giá) của mọi đơn trong ngày, **trước giảm giá**.

STT	Tên bảng	Số dòng	Số cột	Ý nghĩa
	Bảng Operational (vận hành)			
12	`inventory`	60.247	17	Mỗi dòng là tồn kho của một sản phẩm tại **ngày chốt cuối tháng** (07/2012 – 12/2022). Chứa tồn cuối kỳ, nhập/bán trong tháng, số ngày hết hàng, số ngày cung ứng, tỷ lệ đáp ứng, các cờ hết hàng/tồn dư/đặt lại. `stock_on_hand` là chỉ tiêu **số dư**, không cộng dồn qua các tháng; `units_received` / `units_sold` là **phát sinh** trong tháng.
13	`web_traffic`	3.652	7	Mỗi dòng là lưu lượng truy cập website của **một ngày** (01/01/2013 – 31/12/2022): phiên, người dùng duy nhất, lượt xem trang, tỷ lệ thoát, thời lượng phiên trung bình và nguồn truy cập chính.

2. Mô tả chi tiết từng bảng

Ký hiệu: **PK** = khóa chính, **FK** = khóa ngoại.

2.1. `customers` — khách hàng

- **Grain:** 1 dòng / khách hàng. **PK:** `customer_id` . **FK:** `zip` → `geography.zip` .

Cột	Kiểu	Ý nghĩa
`customer_id`	int	Mã khách hàng
`zip`	int	Mã bưu chính nơi ở
`city`	text	Thành phố (phải khớp `geography.city` theo `zip`)
`signup_date`	date	Ngày đăng ký tài khoản
`gender`	text	Female / Male / Non-binary
`age_group`	text	18-24 / 25-34 / 35-44 / 45-54 / 55+
`acquisition_channel`	text	Kênh thu hút: organic_search, paid_search, social_media, email_campaign, referral, direct

2.2. `geography` — địa lý

- **Grain:** 1 dòng / mã bưu chính. **PK:** `zip` .

Cột	Kiểu	Ý nghĩa
`zip`	int	Mã bưu chính
`city`	text	Thành phố
`region`	text	Vùng: East / Central / West
`district`	text	Quận/huyện

2.3. `products` — sản phẩm

- **Grain:** 1 dòng / SKU. **PK:** `product_id` . Khóa nghiệp vụ: (`product_name` , `size` , `color`).

Cột	Kiểu	Ý nghĩa
`product_id`	int	Mã SKU
`product_name`	text	Tên dòng sản phẩm
`category`	text	Danh mục: Streetwear, Outdoor, Casual, GenZ
`segment`	text	Phân khúc trong danh mục (Everyday, Activewear, Premium, ...)
`size`	text	S / M / L / XL
`color`	text	Màu sắc
`price`	float	Giá niêm yết / đơn vị
`cogs`	float	Giá vốn / đơn vị (phải < `price`)

2.4. `promotions` — khuyến mãi

- **Grain:** 1 dòng / chương trình. **PK:** `promo_id`.

Cột	Kiểu	Ý nghĩa
`promo_id`	text	Mã khuyến mãi (PROMO-xxxx)
`promo_name`	text	Tên chương trình
`promo_type`	text	`percentage` (giảm %) hoặc `fixed` (giảm số tiền cố định)
`discount_value`	float	Mức giảm: % nếu `percentage`, số tiền nếu `fixed`
`start_date`, `end_date`	date	Thời gian hiệu lực (`start_date` ≤ `end_date`)
`applicable_category`	text	Danh mục áp dụng; **trống = áp dụng mọi danh mục**
`promo_channel`	text	Kênh triển khai
`stackable_flag`	0/1	Được cộng dồn với khuyến mãi khác hay không
`min_order_value`	float	Giá trị đơn tối thiểu để áp dụng

2.5. `orders` — đơn hàng

- **Grain:** 1 dòng / đơn. **PK:** `order_id`. **FK:** `customer_id` → `customers`, `zip` → `geography`.

Cột	Kiểu	Ý nghĩa
`order_id`	int	Mã đơn
`order_date`	date	Ngày đặt
`customer_id`	int	Khách đặt
`zip`	int	Mã bưu chính giao hàng
`order_status`	text	created → paid → shipped → delivered / returned; hoặc cancelled
`payment_method`	text	credit_card, paypal, cod, apple_pay, bank_transfer
`device_type`	text	mobile / desktop / tablet
`order_source`	text	Nguồn truy cập dẫn đến đơn

2.6. `order_items` — chi tiết đơn

- **Grain:** 1 dòng / sản phẩm trong đơn. Khóa logic: (`order_id` , `product_id`). **FK:** `order_id` → `orders` , `product_id` → `products` , `promo_id` / `promo_id_2` → `promotions` .

Cột	Kiểu	Ý nghĩa
`order_id` , `product_id`	int	Đơn và sản phẩm
`quantity`	int	Số lượng mua (> 0)
`unit_price`	float	Đơn giá bán thực tế (có thể khác giá niêm yết)
`discount_amount`	float	Tổng tiền giảm cho dòng (0 ≤ giảm ≤ số lượng × đơn giá)
`promo_id`	text	Mã khuyến mãi thứ nhất; **trống = dòng không có khuyến mãi**
`promo_id_2`	text	Mã khuyến mãi cộng dồn thứ hai; chỉ có khi đã có `promo_id`

2.7. `payments` — thanh toán

- **Grain:** 1 dòng / đơn. **PK + FK:** `order_id` → `orders` .

Cột	Kiểu	Ý nghĩa
`order_id`	int	Mã đơn
`payment_method`	text	Phải trùng `orders.payment_method`
`payment_value`	float	Số tiền thanh toán = Σ(`quantity` × `unit_price` − `discount_amount`)
`installments`	int	Số kỳ trả góp 1–12 (COD luôn = 1)

2.8. `shipments` — vận chuyển

- **Grain:** 1 dòng / đơn đã gửi. **PK + FK:** `order_id` → `orders` .

Cột	Kiểu	Ý nghĩa
`order_id`	int	Mã đơn
`ship_date`	date	Ngày gửi (≥ `order_date`)
`delivery_date`	date	Ngày giao (≥ `ship_date`)
`shipping_fee`	float	Phí vận chuyển (≥ 0)

2.9. `returns` — trả hàng

- **Grain:** 1 dòng / lần trả một sản phẩm. **PK:** `return_id` . **FK:** (`order_id` , `product_id`) → `order_items` .

Cột	Kiểu	Ý nghĩa
`return_id`	text	Mã phiếu trả (RET-xxxxxx)
`order_id` , `product_id`	int	Dòng sản phẩm bị trả
`return_date`	date	Ngày trả (≥ ngày giao)
`return_reason`	text	wrong_size, defective, not_as_described, changed_mind, late_delivery

Cột	Kiểu	Ý nghĩa
`return_quantity`	int	Số lượng trả (0 < trả ≤ số lượng mua)
`refund_amount`	float	Số tiền hoàn (tổng hoàn theo đơn ≤ tiền thanh toán của đơn)

2.10. `reviews` — đánh giá

- **Grain:** 1 dòng / đánh giá. **PK:** `review_id`. **FK:** (`order_id`, `product_id`) → `order_items`, `customer_id` → `customers`.

Cột	Kiểu	Ý nghĩa
`review_id`	text	Mã đánh giá
`order_id`, `product_id`, `customer_id`	int	Đơn, sản phẩm, khách đánh giá (khách phải là người đặt đơn)
`review_date`	date	Ngày đánh giá (≥ ngày giao)
`rating`	int	Điểm 1–5
`review_title`	text	Tiêu đề đánh giá

2.11. `sales` — doanh thu theo ngày

- **Grain:** 1 dòng / ngày. **PK:** `Date`.

Cột	Kiểu	Ý nghĩa
`Date`	date	Ngày
`Revenue`	float	Doanh thu ngày (Σ số lượng × đơn giá, trước giảm giá, mọi trạng thái đơn)
`COGS`	float	Giá vốn hàng bán trong ngày

2.12. `inventory` — tồn kho cuối tháng

- **Grain:** 1 dòng / sản phẩm / tháng. Khóa: (`product_id`, `snapshot_date`). **FK:** `product_id` → `products`.

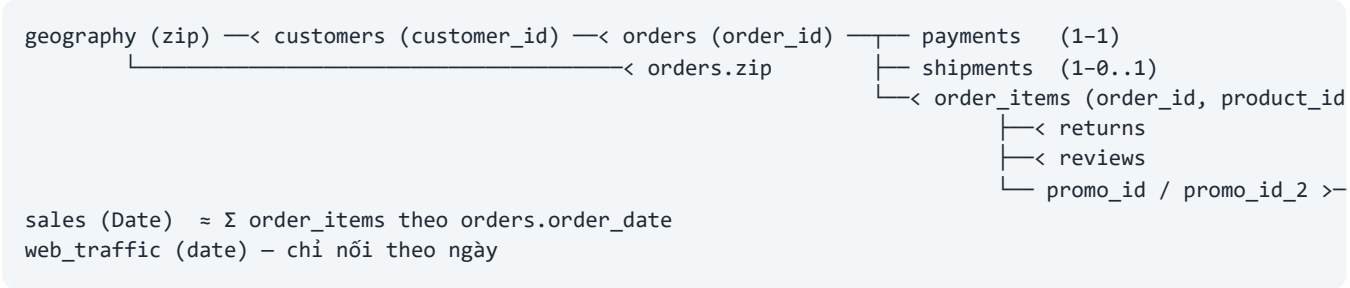
Cột	Kiểu	Ý nghĩa
`snapshot_date`	date	Ngày chốt (ngày cuối tháng)
`product_id`	int	Mã SKU
`stock_on_hand`	int	Tồn cuối kỳ (**số dư**)
`units_received`, `units_sold`	int	Nhập / bán trong tháng (**phát sinh**)
`stockout_days`	int	Số ngày hết hàng trong tháng (≤ số ngày của tháng)
`days_of_supply`	float	Số ngày đủ hàng ≈ `stock_on_hand` / `units_sold` × 30
`fill_rate`	float	Tỷ lệ đáp ứng đơn (0–1)
`stockout_flag`, `overstock_flag`, `reorder_flag`	0/1	Cờ hết hàng (= `stockout_days` > 0), tồn dư, cần đặt lại
`sell_through_rate`	float	`units_sold` / (`units_sold` + `stock_on_hand`)
`product_name`, `category`, `segment`	text	Thuộc tính sản phẩm (sao chép từ `products`)
`year`, `month`	int	Năm, tháng của `snapshot_date`

2.13. `web_traffic` — lưu lượng website

- **Grain:** 1 dòng / ngày. **PK:** `date`.

Cột	Kiểu	Ý nghĩa
`date`	date	Ngày
`sessions`	int	Số phiên truy cập
`unique_visitors`	int	Số người dùng duy nhất (≤ `sessions`)
`page_views`	int	Lượt xem trang (≥ `sessions`)
`bounce_rate`	float	Tỷ lệ thoát (0–1)
`avg_session_duration_sec`	float	Thời lượng phiên trung bình (giây)
`traffic_source`	text	Nguồn truy cập chính của ngày

3. Quan hệ giữa các bảng



4. Lưu ý khi sử dụng

- **Số dư vs phát sinh:** `inventory.stock_on_hand` là số dư tại ngày chốt — lấy giá trị cuối kỳ, **không cộng** qua các tháng. `sales`, `order_items`, `payments`, `inventory.units_sold/units_received` là phát sinh — cộng dồn được theo kỳ.
- **Grain khác nhau:** nối `orders` với `order_items` làm nhân bản dòng đơn; cần tổng hợp `order_items` / `returns` về cấp đơn trước khi nối với `payments`, `shipments`.
- **Doanh thu:** `sales.Revenue` là doanh thu **trước giảm giá, gồm cả đơn hủy**; `payments.payment_value` là số tiền **sau giảm giá**. Không dùng lẫn hai định nghĩa.
- **Giá trị trống có ý nghĩa:** `order_items.promo_id` / `promo_id_2` trống = không khuyến mãi; `promotions.applicable_category` trống = mọi danh mục. Đây không phải dữ liệu thiếu.
- Chi tiết chất lượng dữ liệu (missing, trùng lặp, vi phạm ràng buộc, outlier) xem tại `data_quality_and_eda.md`.

Báo cáo chất lượng dữ liệu và EDA

Tạo tự động bởi `eda/data_quality_eda.py` từ `data/raw/`. Mô tả ý nghĩa từng bảng: `00_data_overview.md`. Script chỉ phát hiện, **không sửa** dữ liệu gốc; dòng vi phạm của từng kiểm tra nằm tại `data/processed/eda/violations/<bảng>__<kiểm tra>.csv`.

Mức độ: **ERROR** — vi phạm ràng buộc cứng, phải xử lý trước khi phân tích; **WARNING** — bất thường/nghi vấn, cần quyết định cách xử lý; **INFO** — đặc điểm dữ liệu cần biết.

1. Tổng quan

- 13 bảng, 2,960,188 dòng; 361 kiểm tra, **17** có vi phạm (2 ERROR, 12 WARNING, 3 INFO).

Nhóm	Bảng	Số dòng	Số cột	Ô thiếu (%)	Dòng trùng	ERROR	WARNING	INFO
Master	`customers`	121,930	7	0%	0	0	1	1
Master	`geography`	39,948	4	0%	0	0	0	0
Master	`products`	2,412	8	0%	0	0	2	1
Master	`promotions`	50	10	8%	0	0	0	0
Transaction	`orders`	646,945	8	0%	0	1	2	0
Transaction	`order_items`	714,669	7	23.04%	0	0	3	0
Transaction	`payments`	646,945	4	0%	0	0	0	0
Transaction	`shipments`	566,067	4	0%	0	0	0	0
Transaction	`returns`	39,939	7	0%	0	1	2	0
Transaction	`reviews`	113,551	7	0%	0	0	0	0
Analytical	`sales`	3,833	3	0%	0	0	1	0
Operational	`inventory`	60,247	17	0%	0	0	0	1
Operational	`web_traffic`	3,652	7	0%	0	0	1	0

2. Các vấn đề chính cần xử lý

Mức	Bảng	Kiểm tra	Vi phạm	%	Đề xuất xử lý
ERROR	`returns`	Tổng tiền hoàn của đơn ≤ `payments.payment_value`	3,633	10.07%	Clip tổng hoàn về tiền thanh toán (giá trị ròng của đơn không âm).
ERROR	`orders`	Đơn `shipped` / `delivered` / `returned` phải có bản ghi `shipments`	564	0.10%	Giữ đơn cho doanh thu; loại khỏi phân tích thời gian giao hàng (không impute ngày giao).
WARNING	`orders`	Ngày đặt ≥ ngày đăng ký của khách	477,453	73.80%	Giữ đơn (giao dịch là dữ liệu gốc đáng tin hơn); coi `signup_date` là không tin cậy.
WARNING	`order_items`	Giá trị đơn (trước giảm) ≥ `min_order_value` của khuyến mãi	110,717	40.07%	Gắn cờ khuyến mãi áp không đủ điều kiện.

Mức	Bảng	Kiểm tra	Vi phạm	%	Đề xuất xử lý
WARNING	`customers`	Ngày đăng ký ≤ ngày đặt đơn đầu tiên	80,623	89.34%	Không dùng `signup_date` để tính tenure/cohort; thay bằng ngày đơn đầu tiên (hoặc min(signup_date, first_order_date)).
WARNING	`order_items`	Đơn giá bán trong khoảng 50%–120% giá niêm yết	10,531	1.47%	Giá lệch mạnh so với niêm yết: xác minh; dùng `unit_price` làm giá thực tế.
WARNING	`returns`	Tiền hoàn ≤ giá trị dòng sau giảm (khách thực trả)	4,415	11.05%	Hoàn theo giá trước giảm giá: khi tính doanh thu thuần, clip tiền hoàn về giá trị dòng sau giảm.
WARNING	`web_traffic`	`bounce_rate` ≥ 1% (giá trị < 1% nghi lưu sai thang)	3,652	100%	Nhiều khả năng đơn vị là % chia thêm 100 → nhân 100 hoặc chỉ dùng so sánh tương đối.
WARNING	`products`	Giá niêm yết < 100 (nhỏ hơn ~50 lần mức thông thường — nghi sai đơn vị)	654	27.11%	Các SKU này không có giao dịch; tách riêng hoặc loại khỏi thống kê giá sản phẩm.
WARNING	`products`	Khóa nghiệp vụ (product_name, size, color) không lặp	426	17.66%	Gộp các dòng cùng khóa (cộng số lượng/tiền) trước khi nối bảng để tránh nhân bản.
WARNING	`sales`	`COGS` ≤ `Revenue` (ngày không lỗ gộp)	382	9.97%	Có thể hợp lệ (ngày khuyến mãi sâu); giữ lại, gắn cờ khi phân tích biên lợi nhuận.
WARNING	`orders`	Đơn `returned` phải có ít nhất một dòng `returns`	80	0.22%	Không có tiền hoàn tương ứng: coi tiền hoàn = 0, gắn cờ khi tính tỷ lệ trả.
WARNING	`order_items`	Khóa nghiệp vụ (order_id, product_id) không lặp	32	0.00%	Gộp các dòng cùng khóa (cộng số lượng/tiền) trước khi nối bảng để tránh nhân bản.
WARNING	`returns`	Khóa nghiệp vụ (order_id, product_id) không lặp	4	0.01%	Gộp các dòng cùng khóa (cộng số lượng/tiền) trước khi nối bảng để tránh nhân bản.
INFO	`customers`	Khách hàng có ít nhất một đơn	31,684	25.99%	Hợp lệ (khách chưa mua). Giữ trong bảng khách hàng, loại khỏi phân tích RFM.
INFO	`products`	SKU xuất hiện ít nhất một lần trong `order_items`	814	33.75%	SKU chưa bán: giữ trong danh mục, loại khỏi phân tích hiệu quả sản phẩm.
INFO	`inventory`	`reorder_flag` có biến thiên (không hằng số)	1	100%	Cột hằng số: loại khỏi mô hình/phân tích.

3. Chi tiết theo bảng

3.1. `customers` (Master)

121,930 dòng × 7 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	7 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	121,930	0	✅ PASS
Trùng lặp	Khóa chính (customer_id) là duy nhất	ERROR	121,930	0	✅ PASS
Kiểu dữ liệu & miền giá trị	13 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Khóa ngoại	`zip` tồn tại trong `geography.zip`	ERROR	121,930	0	✅ PASS
Ràng buộc nghiệp vụ	`city` khớp với `geography.city` theo `zip`	ERROR	121,930	0	✅ PASS
Ràng buộc nghiệp vụ	Ngày đăng ký ≤ ngày đặt đơn đầu tiên	WARNING	90,246	80,623	❌ 89.34%
Ràng buộc nghiệp vụ	Khách hàng có ít nhất một đơn	INFO	121,930	31,684	❌ 25.99%

3.2. `geography` (Master)

39,948 dòng × 4 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	4 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	39,948	0	✅ PASS
Trùng lặp	Khóa chính (zip) là duy nhất	ERROR	39,948	0	✅ PASS
Kiểu dữ liệu & miền giá trị	6 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS

3.3. `products` (Master)

2,412 dòng × 8 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	8 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	2,412	0	✅ PASS
Trùng lặp	Khóa chính (product_id) là duy nhất	ERROR	2,412	0	✅ PASS
Trùng lặp	Khóa nghiệp vụ (product_name, size, color) không lặp	WARNING	2,412	426	❌ 17.66%
Kiểu dữ liệu & miền giá trị	13 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Ràng buộc nghiệp vụ	Giá vốn < giá bán (`cogs` < `price`)	ERROR	2,412	0	✅ PASS
Ràng buộc nghiệp vụ	Giá niêm yết < 100 (nhỏ hơn ~50 lần mức thông thường — nghi sai đơn vị)	WARNING	2,412	654	❌ 27.11%
Ràng buộc nghiệp vụ	SKU xuất hiện ít nhất một lần trong `order_items`	INFO	2,412	814	❌ 33.75%

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`price`	9.06	59.44	4,399.60	7,720.51	40,950	1.33	[-11,432.16; 19,212.12]	31 (1.29%)	2	0
`cogs`	5.18	35.07	3,184.93	5,864.92	38,902.50	1.49	[-8,709.71; 14,609.69]	37 (1.53%)	3	0

3.4. `promotions` (Master)

50 dòng × 10 cột · 40 ô thiếu (8%) · 0 dòng trùng toàn bộ.

Missing values

Cột	Thiếu	%	Loại	Xử lý
`applicable_category`	40	80%	có ý nghĩa nghiệp vụ	Trống = áp dụng mọi danh mục. Điền 'ALL'.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	9 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	50	0	✅ PASS
Trùng lặp	Khóa chính (promo_id) là duy nhất	ERROR	50	0	✅ PASS
Kiểu dữ liệu & miền giá trị	17 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Ràng buộc nghiệp vụ	`start_date` ≤ `end_date`	ERROR	50	0	✅ PASS
Ràng buộc nghiệp vụ	Khuyến mãi % có `discount_value` trong (0, 100]	ERROR	45	0	✅ PASS

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`discount_value`	10	12	16.50	20	50	2.20	[0; 32]	5 (10%)	5	5
`min_order_value`	0	0	0	100,000	200,000	1.04	[-150,000; 250,000]	0 (0%)	0	—

3.5. `orders` (Transaction)

646,945 dòng × 8 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	8 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	646,945	0	✅ PASS
Trùng lặp	Khóa chính (order_id) là duy nhất	ERROR	646,945	0	✅ PASS
Kiểu dữ liệu & miền giá trị	16 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Khóa ngoại	`customer_id` tồn tại trong `customers.customer_id`	ERROR	646,945	0	✅ PASS
Khóa ngoại	`zip` tồn tại trong `geography.zip`	ERROR	646,945	0	✅ PASS
Ràng buộc nghiệp vụ	`zip` của đơn trùng `zip` của khách	INFO	646,945	0	✅ PASS
Ràng buộc nghiệp vụ	Ngày đặt ≥ ngày đăng ký của khách	WARNING	646,945	477,453	❌ 73.80%
Ràng buộc nghiệp vụ	Mỗi đơn có ít nhất một dòng `order_items`	ERROR	646,945	0	✅ PASS
Ràng buộc nghiệp vụ	Mỗi đơn có một bản ghi `payments`	ERROR	646,945	0	✅ PASS
Ràng buộc nghiệp vụ	Đơn `shipped` / `delivered` / `returned` phải có bản ghi `shipments`	ERROR	566,631	564	❌ 0.10%
Ràng buộc nghiệp vụ	Đơn `created` / `paid` / `cancelled` không có bản ghi `shipments`	ERROR	80,314	0	✅ PASS
Ràng buộc nghiệp vụ	Đơn `returned` phải có ít nhất một dòng `returns`	WARNING	36,142	80	❌ 0.22%

3.6. `order_items` (Transaction)

714,669 dòng × 7 cột · 1,152,816 ô thiếu (23.04%) · 0 dòng trùng toàn bộ.

Missing values

Cột	Thiếu	%	Loại	Xử lý
`promo_id`	438,353	61.34%	có ý nghĩa nghiệp vụ	Trống = dòng không dùng khuyến mãi. Giữ nguyên / điền 'NO_PROMO' khi phân tích.
`promo_id_2`	714,463	99.97%	có ý nghĩa nghiệp vụ	Trống = không có khuyến mãi cộng dồn. Giữ nguyên / điền 'NO_PROMO'.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	5 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	714,669	0	✅ PASS
Trùng lặp	Khóa nghiệp vụ (order_id, product_id) không lặp	WARNING	714,669	32	❌ 0.00%
Kiểu dữ liệu & miền giá trị	13 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Khóa ngoại	`order_id` tồn tại trong `orders.order_id`	ERROR	714,669	0	✅ PASS
Khóa ngoại	`product_id` tồn tại trong `products.product_id`	ERROR	714,669	0	✅ PASS

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Khóa ngoại	`promo_id` tồn tại trong `promotions.promo_id`	ERROR	276,316	0	✅ PASS
Khóa ngoại	`promo_id_2` tồn tại trong `promotions.promo_id`	ERROR	206	0	✅ PASS
Ràng buộc nghiệp vụ	0 ≤ `discount_amount` ≤ `quantity` × `unit_price`	ERROR	714,669	0	✅ PASS
Ràng buộc nghiệp vụ	Có `promo_id_2` thì phải có `promo_id`	ERROR	714,669	0	✅ PASS
Ràng buộc nghiệp vụ	Có giảm giá ⇔ có mã khuyến mãi	WARNING	714,669	0	✅ PASS
Ràng buộc nghiệp vụ	Ngày đặt nằm trong thời gian hiệu lực khuyến mãi	ERROR	276,316	0	✅ PASS
Ràng buộc nghiệp vụ	Danh mục sản phẩm khớp `applicable_category` của khuyến mãi	ERROR	29,855	0	✅ PASS
Ràng buộc nghiệp vụ	Giá trị đơn (trước giảm) ≥ `min_order_value` của khuyến mãi	WARNING	276,316	110,717	❌ 40.07%
Ràng buộc nghiệp vụ	Đơn giá bán trong khoảng 50%–120% giá niêm yết	WARNING	714,669	10,531	❌ 1.47%

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`quantity`	1	2	4	6	8	0.00	[-4; 12]	0 (0%)	0	0
`unit_price`	392.57	1,906.89	4,257.77	7,273.76	43,056	1.02	[-6,143.41; 15,324.07]	8,623 (1.21%)	177	0
`discount_amount`	0	0	0	967.63	35,235.47	3.38	[-1,451.44; 2,419.07]	105,767 (14.80%)	66,211	—

3.7. `payments` (Transaction)

646,945 dòng × 4 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	4 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	646,945	0	✅ PASS
Trùng lặp	Khóa chính (order_id) là duy nhất	ERROR	646,945	0	✅ PASS
Kiểu dữ liệu & miền giá trị	9 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Khóa ngoại	`order_id` tồn tại trong `orders.order_id`	ERROR	646,945	0	✅ PASS

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Ràng buộc nghiệp vụ	`payment_value` = Σ(`quantity` × `unit_price` − `discount_amount`) của đơn (sai số ≤ 1)	ERROR	646,945	0	✅ PASS
Ràng buộc nghiệp vụ	`payment_method` trùng `orders.payment_method`	ERROR	646,945	0	✅ PASS
Ràng buộc nghiệp vụ	`installments` trong 1–12; COD chỉ 1 kỳ	ERROR	646,945	0	✅ PASS

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`payment_value`	389.74	7,681.06	17,229.44	33,706.35	331,570.40	1.68	[-31,356.87; 72,744.29]	30,219 (4.67%)	2,843	3,976

3.8. `shipments` (Transaction)

566,067 dòng × 4 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	4 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	566,067	0	✅ PASS
Trùng lặp	Khóa chính (order_id) là duy nhất	ERROR	566,067	0	✅ PASS
Kiểu dữ liệu & miền giá trị	8 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Khóa ngoại	`order_id` tồn tại trong `orders.order_id`	ERROR	566,067	0	✅ PASS
Ràng buộc nghiệp vụ	`ship_date` ≥ `order_date`	ERROR	566,067	0	✅ PASS
Ràng buộc nghiệp vụ	`delivery_date` ≥ `ship_date`	ERROR	566,067	0	✅ PASS
Ràng buộc nghiệp vụ	Đơn có vận chuyển phải ở trạng thái shipped/delivered/returned	ERROR	566,067	0	✅ PASS
Outlier theo ngữ cảnh	`shipping_days` ≤ rào IQR trên (10.5 ngày)	WARNING	566,067	0	✅ PASS
Outlier theo ngữ cảnh	`processing_days` ≤ rào IQR trên (5.0 ngày)	WARNING	566,067	0	✅ PASS

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`shipping_fee`	0	0.87	1.73	2.60	32	2.17	[-1.72; 5.20]	76,050 (13.43%)	76,050	—

3.9. `returns` (Transaction)

39,939 dòng × 7 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	7 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	39,939	0	✅ PASS
Trùng lặp	Khóa chính (return_id) là duy nhất	ERROR	39,939	0	✅ PASS
Trùng lặp	Khóa nghiệp vụ (order_id, product_id) không lặp	WARNING	39,939	4	❌ 0.01%
Kiểu dữ liệu & miền giá trị	14 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Khóa ngoại	`order_id` tồn tại trong `orders.order_id`	ERROR	39,939	0	✅ PASS
Khóa ngoại	`product_id` tồn tại trong `products.product_id`	ERROR	39,939	0	✅ PASS
Ràng buộc nghiệp vụ	(`order_id` , `product_id`) trả hàng có trong `order_items`	ERROR	39,939	0	✅ PASS
Ràng buộc nghiệp vụ	Tổng số lượng trả ≤ số lượng mua của dòng	ERROR	39,939	0	✅ PASS
Ràng buộc nghiệp vụ	Tiền hoàn ≤ giá trị dòng trước giảm (`quantity` × `unit_price`)	ERROR	39,939	0	✅ PASS
Ràng buộc nghiệp vụ	Tiền hoàn ≤ giá trị dòng sau giảm (khách thực trả)	WARNING	39,939	4,415	❌ 11.05%
Ràng buộc nghiệp vụ	Tổng tiền hoàn của đơn ≤ `payments.payment_value`	ERROR	36,062	3,633	❌ 10.07%
Ràng buộc nghiệp vụ	`return_date` ≥ `order_date`	ERROR	39,939	0	✅ PASS
Ràng buộc nghiệp vụ	`return_date` ≥ `delivery_date`	ERROR	39,939	0	✅ PASS
Ràng buộc nghiệp vụ	Đơn có trả hàng phải ở trạng thái `returned`	WARNING	39,939	0	✅ PASS

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`return_quantity`	1	1	2	4	8	0.97	[-3.50; 8.50]	0 (0%)	0	0
`refund_amount`	458.81	3,573.39	7,888.88	16,881.99	160,937.94	2.32	[-16,389.50; 36,844.88]	2,778 (6.96%)	820	0

3.10. `reviews` (Transaction)

113,551 dòng × 7 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	6 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	113,551	0	✅ PASS
Trùng lặp	Khóa chính (review_id) là duy nhất	ERROR	113,551	0	✅ PASS
Trùng lặp	Khóa nghiệp vụ (order_id, product_id) không lặp	WARNING	113,551	0	✅ PASS
Kiểu dữ liệu & miền giá trị	13 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Khóa ngoại	`order_id` tồn tại trong `orders.order_id`	ERROR	113,551	0	✅ PASS
Khóa ngoại	`product_id` tồn tại trong `products.product_id`	ERROR	113,551	0	✅ PASS
Khóa ngoại	`customer_id` tồn tại trong `customers.customer_id`	ERROR	113,551	0	✅ PASS
Ràng buộc nghiệp vụ	(`order_id` , `product_id`) đánh giá có trong `order_items`	ERROR	113,551	0	✅ PASS
Ràng buộc nghiệp vụ	`customer_id` đánh giá trùng người đặt đơn	ERROR	113,551	0	✅ PASS
Ràng buộc nghiệp vụ	`review_date` ≥ `delivery_date` (và ≥ `order_date`)	ERROR	113,551	0	✅ PASS
Ràng buộc nghiệp vụ	Chỉ đơn đã giao (`delivered` / `returned`) mới được đánh giá	WARNING	113,551	0	✅ PASS

3.11. `sales` (Analytical)

3,833 dòng × 3 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	3 cột bắt buộc đều có giá trị	—	—	0	✅ PASS

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	3,833	0	✅ PASS
Trùng lặp	Khóa chính (Date) là duy nhất	ERROR	3,833	0	✅ PASS
Kiểu dữ liệu & miền giá trị	6 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Ràng buộc nghiệp vụ	Chuỗi ngày liên tục, không thiếu ngày	ERROR	3,833	0	✅ PASS
Ràng buộc nghiệp vụ	`COGS` ≤ `Revenue` (ngày không lỗ gộp)	WARNING	3,833	382	❌ 9.97%
Ràng buộc nghiệp vụ	`Revenue` = Σ(`quantity` × `unit_price`) các đơn trong ngày (sai số ≤ 1)	WARNING	3,833	0	✅ PASS

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`Revenue`	279,813.94	2,471,088.82	3,647,303.90	5,350,877.20	20,905,271.35	1.67	[-1,848,593.75; 9,670,559.77]	169 (4.41%)	34	41
`COGS`	236,576.31	2,150,580.23	3,161,112.99	4,637,293.92	16,535,857.67	1.63	[-1,579,490.31; 8,367,364.46]	165 (4.30%)	32	31

3.12. `inventory` (Operational)

60,247 dòng × 17 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	5 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	60,247	0	✅ PASS
Trùng lặp	Khóa nghiệp vụ (product_id, snapshot_date) không lặp	WARNING	60,247	0	✅ PASS
Kiểu dữ liệu & miền giá trị	39 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Khóa ngoại	`product_id` tồn tại trong `products.product_id`	ERROR	60,247	0	✅ PASS
Ràng buộc nghiệp vụ	`snapshot_date` là ngày cuối tháng	ERROR	60,247	0	✅ PASS
Ràng buộc nghiệp vụ	`year` / `month` khớp `snapshot_date`	ERROR	60,247	0	✅ PASS
Ràng buộc nghiệp vụ	`stockout_days` ≤ số ngày trong tháng	ERROR	60,247	0	✅ PASS
Ràng buộc nghiệp vụ	`stockout_flag` = 1 ⇔ `stockout_days` > 0	ERROR	60,247	0	✅ PASS
Ràng buộc nghiệp vụ	`sell_through_rate` = sold / (sold + stock_on_hand)	ERROR	60,247	0	✅ PASS
Ràng buộc nghiệp vụ	Tên/danh mục/phân khúc khớp bảng `products`	ERROR	60,247	0	✅ PASS
Ràng buộc nghiệp vụ	`reorder_flag` có biến thiên (không hằng số)	INFO	1	1	❌ 100%

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`stock_on_hand`	3	15	62	210	2,673	3.22	[-277.50; 502.50]	6,432 (10.68%)	3,253	0
`units_received`	1	2	6	19	817	5.60	[-23.50; 44.50]	6,392 (10.61%)	3,321	8
`units_sold`	1	2	6	16	670	5.55	[-19; 37]	6,388 (10.60%)	3,410	16
`stockout_days`	0	0	1	2	28	7.40	[-3; 5]	724 (1.20%)	483	—
`days_of_supply`	5.20	96	240	683.10	68,100	8.92	[-784.65; 1,563.75]	7,455 (12.37%)	4,742	508
`fill_rate`	0.07	0.93	0.97	1	1	-7.40	[0.83; 1.10]	724 (1.20%)	483	848
`sell_through_rate`	0.00	0.04	0.11	0.24	0.85	1.31	[-0.25; 0.53]	1,284 (2.13%)	4	845

3.13. `web_traffic` (Operational)

3,652 dòng × 7 cột · 0 ô thiếu (0%) · 0 dòng trùng toàn bộ.

Missing values

Không có giá trị thiếu.

Kiểm tra

Nhóm	Kiểm tra	Mức	Đã kiểm	Vi phạm	Kết quả
Missing values	7 cột bắt buộc đều có giá trị	—	—	0	✅ PASS
Trùng lặp	Không có dòng trùng toàn bộ	ERROR	3,652	0	✅ PASS
Trùng lặp	Khóa chính (date) là duy nhất	ERROR	3,652	0	✅ PASS
Kiểu dữ liệu & miền giá trị	17 kiểm tra kiểu / miền / dấu / phạm vi ngày / định dạng text	—	—	0	✅ PASS
Ràng buộc nghiệp vụ	Chuỗi ngày liên tục, không thiếu ngày	ERROR	3,652	0	✅ PASS
Ràng buộc nghiệp vụ	`unique_visitors` ≤ `sessions`	ERROR	3,652	0	✅ PASS
Ràng buộc nghiệp vụ	`page_views` ≥ `sessions`	ERROR	3,652	0	✅ PASS
Ràng buộc nghiệp vụ	`bounce_rate` ≥ 1% (giá trị < 1% nghi lưu sai thang)	WARNING	3,652	3,652	❌ 100%

Phân phối & outlier (IQR)

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`sessions`	7,973	17,099.25	23,633.50	31,782.75	50,947	0.47	[-4,926; 53,808]	0 (0%)	0	0
`unique_visitors`	6,136	12,915	17,924	24,191.75	40,430	0.51	[-4,000.12; 41,106.88]	0 (0%)	0	0

Cột	Min	Q1	Median	Q3	Max	Skew	Rào IQR 1,5×	Outlier	Cực trị 3×	Outlier thang log
`page_views`	30,451	72,982	101,010.50	138,086	275,560	0.65	[-24,674; 235,742]	18 (0.49%)	0	0
`bounce_rate`	0.00	0.00	0.00	0.01	0.01	0.04	[0.00; 0.01]	0 (0%)	0	0
`avg_session_duration_sec`	100.10	156.70	209.20	266.20	319.90	0.00	[-7.55; 430.45]	0 (0%)	0	0

4. Nguyên tắc xử lý outlier

- Outlier IQR chỉ được **gắn cờ**, không tự động xóa: các biến tiền/số lượng lệch phải mạnh (skew > 1), nên rào IQR trên thang gốc đánh dấu nhiều giá trị lớn hợp lệ. Cột *Outlier thang log* cho số outlier sau log-transform — gần 0 nghĩa là đuôi phải tự nhiên, không phải lỗi.
- Với mô hình nhạy với outlier (K-Means, hồi quy tuyến tính): dùng log1p hoặc winsorize tại P1/P99; với mô hình cây: giữ nguyên.
- Outlier ở bảng tổng hợp ngày (`sales` , `web_traffic`) thường là ngày khuyến mãi/lễ — giữ lại và tạo biến cờ sự kiện.
- Giá trị vi phạm ràng buộc (âm, ngoài miền, sai thứ tự ngày) là **lỗi**, xử lý theo cột *Đề xuất xử lý* ở mục 2.
- Thời gian giao (`delivery_date - ship_date`): 2–7 ngày, trung vị 4 ngày.