VIN DATATHON 2026

Báo cáo Phân nhóm khách hàng

Rule-based + K-Means trên RFM: phương pháp, feature engineering, PCA, chọn k, profile và hành động theo nhóm

---

Ngày tạo: 16/10/2026
Nguồn nội dung:

- customer_segmentation/README.md
- reports/markdown/customer_segmentation_features.md
- reports/markdown/customer_segmentation_pca.md
- reports/markdown/customer_segmentation_k_selection.md
- reports/markdown/customer_segment_profiles.md

Customer Segmentation

Phân nhóm khách hàng theo hành vi mua (RFM) bằng K-Means, mô tả chân dung từng nhóm và đề xuất hành động để tăng doanh thu.

> README này mô tả **flow** của phần phân cụm. Các mục đánh dấu ✍️ là chỗ cần điền khi có kết quả cụ thể.

Flow tổng quan



Bước	Script	Việc làm	Trạng thái
1–2	`01_build_customer_dataset.py`	Aggregation, quality check, tính RFM, gán nhóm rule-based	✅
3a	`02_transform_features.py`	Feature engineering: so sánh phép biến đổi, scale, đánh giá biến ứng viên → `reports/markdown/customer_segmentation_features.md`	✅
3b	`03_pca_analysis.py`	PCA + giải thích → `reports/markdown/customer_segmentation_pca.md`	✅
4	`04_select_k.py`	Quét k = 2–8, đánh giá thống kê + ổn định + business → `reports/markdown/customer_segmentation_k_selection.md`	✅
5	`05_kmeans_segmentation.py`	K-Means với k = 5 → `customer_segments.csv` (`customer_id` , `cluster`)	✅
6–8	`06_cluster_profiling.py`	Bức tranh tổng thể, profile, gợi ý hành động → `reports/markdown/customer_segment_profiles.md`	✅ (chạy lại sau khi chốt K-Means)

`config.py` chứa toàn bộ đường dẫn, định nghĩa trạng thái đơn, luật rule-based và phép biến đổi biến. `behavior_features.py` tạo các biến hành vi dùng chung cho bước 02 và 06. `segment_naming.py` chứa luật đặt tên cụm gợi ý và hành động theo nhóm. `plot_style.py` chứa màu và style biểu đồ.

---

0. Mục đích

- **Câu hỏi kinh doanh:** khách hàng của doanh nghiệp chia thành những nhóm hành vi nào, mỗi nhóm đóng góp bao nhiêu doanh thu, và nên tác động vào nhóm nào, bằng cách nào để **tăng doanh thu**?
- **Đầu ra mong muốn:** 1. Mỗi khách hàng có nhãn cụm. 2. Mỗi cụm có tên dễ hiểu, quy mô, mức đóng góp doanh thu và chân dung (độ tuổi, giới tính, vùng, kênh...). 3. Mỗi cụm có hành động cụ thể và KPI để đo hiệu quả.
- **Phạm vi: toàn bộ 121.930 khách đã đăng ký** (04/07/2012 – 31/12/2022):
- Khách đã có đơn phát sinh doanh thu (`paid` / `shipped` / `delivered` / `returned`) → phân cụm K-Means.
- Khách chưa có đơn phát sinh doanh thu → gán nhóm rule-based.

1. Dữ liệu đầu vào & aggregation

Bảng và cột sử dụng

Bảng	Cột	Dùng để
`orders`	`order_id`, `customer_id`, `order_date`, `order_status`	Lọc đơn phát sinh doanh thu, tính Recency/Frequency
`payments`	`order_id`, `payment_value`	Tiền khách trả (sau giảm giá) → Monetary
`returns`	`order_id`, `refund_amount`	Trừ tiền hoàn khỏi Monetary
`customers`	`customer_id`, `gender`, `age_group`, `acquisition_channel`, `zip`, `signup_date`	Biến mô tả (profile), **không** đưa vào K-Means
`geography`	`zip`, `region`	Vùng của khách
`order_items`, `products`, `reviews` *(dự kiến)*		Biến hành vi bổ sung cho profile: danh mục ưa thích, tỷ lệ dùng khuyến mãi, điểm đánh giá

Các bước gộp (grain: đơn hàng → khách hàng)

1. **Business rule — đơn tính doanh thu:** `order_status ∈ {paid, shipped, delivered, returned}`, tức đơn đã thanh toán trở đi. Loại `created` (chưa thanh toán) và `cancelled` (đã hủy). Đơn `returned` vẫn tính, nhưng trừ tiền hoàn ở bước 3. Định nghĩa nằm ở `config.REVENUE_STATUSES`.
2. Cộng `refund_amount` theo `order_id`, rồi nối 1–1 với `payments`.
3. Giá trị ròng của đơn = `payment_value − tổng tiền hoàn`, **chặn dưới ở 0**.
4. Gộp theo `customer_id`: - `recency_days` = ngày tham chiếu (**2023-01-01** = ngày đặt cuối cùng + 1) − ngày đặt gần nhất. - `frequency` = số đơn phát sinh doanh thu khác nhau. - `monetary` = Σ giá trị ròng của các đơn.
5. Nối thông tin nhân khẩu học và vùng (qua `zip` → `geography.region`). Giá trị thiếu gán `Unknown`.

Kết quả: `customer_analysis_base.csv` có 121.930 khách, kèm các cột `segment_method` (`kmeans` / `rule_based`), `rule_segment`, `failed_order_count`, `failed_reason` và `order_count_all`.

Rule-based segmentation (khách không có đơn phát sinh doanh thu)

Khách không có đơn doanh thu thì không có RFM có ý nghĩa: F = M = 0, còn R không xác định. Nếu đưa vào K-Means, họ sẽ tạo thành một cụm "toàn số 0" và làm lệch các cụm còn lại. Vì vậy họ được gán nhãn bằng luật **trước khi** phân cụm (`config.RULE_SEGMENTS`).

Tiêu chí: rule-based dành cho khách **không có hành vi tạo doanh thu để phân cụm**. Tiêu chí này rộng hơn "chưa có giao dịch", để khách đã đặt đơn nhưng không chuyển đổi vẫn có nhóm và có hành động riêng.

Mã	Nhóm	Điều kiện	Số khách	Mục tiêu
—	→ K-Means	Có ≥ 1 đơn `paid` / `shipped` / `delivered` / `returned`	87.839	Xem bước 4–6
RB2	Đặt đơn nhưng chưa chuyển đổi	Có ≥ 1 đơn, tất cả đều `cancelled` / `created`	2.407	Gỡ rào cản để chuyển đổi đơn đầu tiên
RB1	Chưa giao dịch	Đăng ký nhưng chưa đặt đơn nào	31.684	Kích hoạt đơn đầu tiên

Thuộc tính của RB2 (không tách thành nhóm riêng vì phần lẻ quá nhỏ):

- `failed_order_count` : 1 đơn có 2.255 khách (93,7%); 2 đơn có 140 khách; 3 đơn có 12 khách. Khách có ≥ 2 đơn thất bại thể hiện ý định mua rõ hơn, gặp rào cản lặp lại, nên được ưu tiên.
- `failed_reason` : `cancelled` 2.123, `abandoned` (đơn `created` bỏ dở) 258, cả hai 26. Đơn `created` trải đều 2012–2022, tức là đơn bỏ dở, không phải đơn đang chờ thanh toán.

Kết quả cuối: `customer_segments_all.csv` , gồm `customer_id` , `segment_method` , `segment` (RB1, RB2 / C0…Ck), `segment_name` . Mọi khách hàng đều có đúng một nhãn.

2. Quality check

Kiểm tra trong `01_build_customer_dataset.py` — script dừng ngay nếu có lỗi:

- Khóa chính không trùng, không rỗng: `customers.customer_id` , `orders.order_id` , `payments.order_id` , `geography.zip` .
- `order_date` và `payment_value` chuyển kiểu hợp lệ.
- Mọi `orders.customer_id` có trong `customers` ; `payments` khớp 1–1 với `orders` ; mọi `returns.order_id` có trong `orders` .

Vấn đề dữ liệu ảnh hưởng đến phân cụm (từ báo cáo EDA) và cách xử lý:

Vấn đề	Quy mô	Xử lý
Tổng tiền hoàn > tiền thanh toán (hoàn theo giá **trước** giảm giá)	3.640 đơn	Giữ đơn, giá trị ròng chặn ở 0; danh sách lưu trong `refund_reconciliation_issues.csv`
Đơn đặt **trước** ngày đăng ký của khách	73,8% số đơn	**Không** dùng `signup_date` để tính tenure/cohort
Đơn `returned` không có dòng trong `returns`	80 đơn	Coi tiền hoàn = 0
Monetary / Frequency lệch phải mạnh, nhiều outlier IQR		Không xóa outlier; giảm ảnh hưởng bằng `log1p`

3. Feature engineering

3.1 Biến dùng cho K-Means: RFM

Biến	Ý nghĩa	Chiều tốt
`recency_days`	Mới mua gần đây hay đã lâu	Thấp là tốt
`frequency`	Mức độ gắn bó	Cao là tốt
`monetary`	Giá trị mang lại	Cao là tốt

Nhân khẩu học (tuổi, giới tính, vùng, kênh) **không** đưa vào K-Means. Lý do: cụm cần phản ánh **hành vi** (thứ có thể tác động bằng marketing); nhân khẩu học chỉ dùng để mô tả cụm sau khi đã phân xong.

3.2 Biến đổi — `02_transform_features.py`

Chi tiết và số liệu: `reports/markdown/customer_segmentation_features.md` .

1. **Biến đổi phân phối** (`config.FEATURE_TRANSFORMS`): giảm độ lệch để vài khách cực lớn không kéo tâm cụm. Mỗi biến được thử 4 phép (không biến đổi, `sqrt` , `log1p` , Yeo-Johnson) và so sánh skew:

Biến	Skew gốc	`log1p` (đang dùng)	Gợi ý
Recency	+0,62	−1,22 (lệch hơn gốc)	`sqrt` (+0,01)
Frequency	+2,61	+0,53	Yeo-Johnson (+0,13)
Monetary	+2,55	−1,07	Yeo-Johnson (−0,02)

✍️ **Cần quyết định:** giữ `log1p` cho cả 3 biến, hay đổi theo gợi ý. Đổi thì phải chạy lại từ bước 02. 2. `StandardScaler` : đưa 3 biến về cùng thang (mean 0, std 1). K-Means dùng khoảng cách Euclid, nên nếu không scale thì Monetary sẽ lấn át hai biến còn lại. 3. **PCA** — chi tiết trong `reports/markdown/customer_segmentation_pca.md` : - **Vì sao:** Frequency và Monetary tương quan **r = 0,83**, tức K-Means sẽ tính khía cạnh "giá trị mua" gần như hai lần. PCA xoay sang các trục không tương quan, đồng thời cho phép vẽ cụm trên mặt phẳng 2D. - **Có phù hợp không:** Bartlett p ≈ 0 (các biến có tương quan) và KMO = 0,65 (chấp nhận được). - **Kết quả:** PC1 giải thích 77,1% phương sai (trục "giá trị & gắn bó": +F, +M, −R); PC2 giải thích 17,4% (trục "độ mới", Recency nổi trội). **Giữ 2 PC = 94,6% phương sai.** - **Lưu ý:** nếu giữ đủ 3 PC thì K-Means cho kết quả y hệt dữ liệu đã scale. Lợi ích chỉ đến từ việc bỏ PC3.

3.3 Biến hành vi ứng viên

Các biến hành vi được tạo trong `behavior_features.py` (dùng chung với bước profiling) và đánh giá bằng tương quan Spearman với RFM. Nếu |ρ| ≥ 0,7 thì biến đó trùng thông tin với RFM.

Biến	Định nghĩa	Tương quan mạnh nhất với RFM
`aov`	Monetary / Frequency	Monetary (ρ = 0,56)
`tenure_days`	Số ngày từ đơn doanh thu đầu tiên	Frequency (0,66)
`return_rate`	Tỷ lệ đơn bị trả	Frequency (0,40)
`cancel_rate`	Tỷ lệ đơn hủy	Frequency (0,39)
`items_per_order`	Số sản phẩm / đơn	Monetary (0,20)
`promo_share`	Tỷ lệ dòng có khuyến mãi	Frequency (0,12)
`avg_rating`	Điểm đánh giá TB (55% khách có)	Frequency (−0,07)

Không biến nào trùng thông tin với RFM. Hiện tất cả chỉ dùng để **mô tả cụm**. Biến phân loại (danh mục, thiết bị, thanh toán, nguồn đơn) và nhân khẩu học không đưa vào K-Means vì không đo được bằng khoảng cách Euclid.

✍️ Ghi lại ở đây nếu quyết định thêm biến nào vào K-Means.

4. Chọn số cụm k — `04_select_k.py`

Bước này **chỉ đánh giá, không ghi nhãn**. Quét k = 2–8 trên `customer_pca_scores.csv` , mỗi k chạy 5 `random_state` . Chi tiết: `reports/markdown/customer_segmentation_k_selection.md` .

Tiêu chí: k chọn theo 3 lớp, vì silhouette một mình luôn ưu tiên k nhỏ.

1. **Business:** - k ≥ 3 (k = 2 quá thô để có chiến lược khác nhau). - Cụm nhỏ nhất ≥ 5% khách. - Mỗi cụm là một loại hành vi khác nhau (không có hai cụm phải xử lý giống nhau).

2. **Ổn định:** ARI giữa các lần chạy ≥ 0,9.
3. **Thống kê:** hạng trung bình của Silhouette (↑), Calinski-Harabasz (↑), Davies-Bouldin (↓); tham khảo elbow.

Kết quả quét (87.839 khách, đầu vào PCA):

k	Silhouette	Calinski-Harabasz	Davies-Bouldin	ARI	Cụm nhỏ nhất	Nhóm hành động	Đạt điều kiện business
2	0,494	117.209	0,749	0,995	44,2%	2/2	— (k < 3)
3	0,401	101.084	0,882	0,988	24,9%	3/3	✅
4	0,346	88.475	0,990	0,944	15,4%	4/4	✅
5	0,374	87.957	0,846	0,956	10,2%	5/5	✅
6	0,372	87.592	0,867	0,969	4,2%	5/6	—
7	0,346	85.550	0,873	0,986	3,2%	6/7	—
8	0,364	86.943	0,800	0,961	3,0%	6/8	—

- **Elbow:** k = 4. **Xếp hạng thống kê:** k = 3 và k = 5 đồng hạng (3,3) trong các k đạt điều kiện.
- **Ứng viên:**
- **k = 3**: tách rõ nhất, nhưng gộp chung khách mới mua gần đây với khách đã lâu không quay lại.
- **k = 5**: thống kê tốt hơn k = 4 (silhouette 0,374 so với 0,346; DB 0,846 so với 0,990), đủ ổn định. Tách thêm 2 nhóm có hành động riêng: **Khách mới / tiềm năng** (10%, mua gần đây nhưng ít đơn) và **Đã rời bỏ** (25%, chỉ 2,6% doanh thu).

k đã chọn: 5. Lý do:

1. **Đạt cả 3 lớp điều kiện:** cụm nhỏ nhất 10,2% (≥ 5%), 5/5 cụm là 5 loại hành vi khác nhau, ARI 0,956 (≥ 0,9).
2. **Nhiều nhóm hành động nhất trong các k đạt điều kiện** (k = 3, 4, 5). Mỗi nhóm thêm là một chiến lược riêng triển khai được.
3. **Thống kê không kém k = 3:** đồng hạng 3,3; Davies-Bouldin 0,846 là tốt nhất trong các k đạt điều kiện; silhouette 0,374 cao hơn k = 4 (0,346).
4. **Vì sao không chọn k = 3:** cụm "Trung thành" của k = 3 có recency median 977 ngày, tức gộp chung khách mới mua gần đây nhưng ít đơn với khách đã lâu không quay lại. k = 5 tách được 2 nhóm cần hành động ngược nhau: - **Khách mới / tiềm năng** (R = 206 ngày, F = 4): cần nuôi dưỡng để mua lặp lại. - **Đã rời bỏ** (R = 2.391 ngày, 2,6% doanh thu) tách khỏi **Ngủ đông** (R = 1.650 ngày, 13,1% doanh thu): không tốn ngân sách win-back cho nhóm gần như đã mất.
5. **Vì sao không chọn k ≥ 6:** cụm nhỏ nhất dưới 5% (4,2%, 3,2%, 3,0%) và có hai cụm cùng loại hành vi (5/6, 6/7, 6/8), tức hai cụm phải xử lý giống nhau.

Báo cáo chọn k (`customer_segmentation_k_selection.md`) sinh các lý do này trực tiếp từ số liệu.

5. K-Means — `05_kmeans_segmentation.py`

- Chạy `python customer_segmentation/05_kmeans_segmentation.py --k 5` trên 2 thành phần PCA (94,6% phương sai).
- **Đầu ra:** `customer_segments.csv` gồm `customer_id` , `cluster` ; `customer_segments_all.csv` ghép thêm nhóm rule-based, nên **mọi khách đều có đúng một nhãn**.

6. Kết quả phân cụm

Khách hàng được gom như sau (121.930 khách đã đăng ký):

```
121.930 khách đã đăng ký
├── Rule-based, gán trước khi chạy mô hình (34.091 khách, 28,0%)
│   ├── RB1 Chưa giao dịch ..................  31.684 (26,0%)
│   └── RB2 Đặt đơn nhưng chưa chuyển đổi ...   2.407 ( 2,0%)
└── K-Means k = 5 trên RFM (87.839 khách đã mua, 72,0%)
    ├── C0 Champions ....................... 12.384 · 43,6% doanh thu
    ├── C2 Trung thành ..................... 19.103 · 34,9% doanh thu
    ├── C4 Ngủ đông ........................ 24.995 · 13,1% doanh thu
    ├── C3 Khách mới / tiềm năng ............  8.945 ·  5,7% doanh thu
    └── C1 Đã rời bỏ ....................... 22.412 ·  2,6% doanh thu
```

Cụm	Tên	Số khách	% khách đã mua	% doanh thu	Recency (median, ngày)	Frequency (median)	Monetary (median)	AOV
C0	Champions	12.384	14,1%	43,6%	149	17	421.487	23.888
C2	Trung thành	19.103	21,7%	34,9%	659	9	219.127	23.764
C4	Ngủ đông	24.995	28,5%	13,1%	1.650	3	64.500	22.627
C3	Khách mới / tiềm năng	8.945	10,2%	5,7%	206	4	80.930	20.775
C1	Đã rời bỏ	22.412	25,5%	2,6%	2.391	1	12.788	10.487

Champions và Trung thành chiếm 35,8% khách đã mua nhưng mang về 78,5% doanh thu.

Cách đặt tên (`segment_naming.py`): ma trận Recency × Giá trị (giá trị = trung bình phân vị F và M của cụm so với mặt bằng):

	Giá trị cao	Giá trị thấp
Mua gần đây	Champions → Trung thành	Khách mới / tiềm năng → Cần nuôi dưỡng
Lâu chưa mua	Có nguy cơ rời bỏ	Ngủ đông → Đã rời bỏ

Hai cụm rơi cùng ô thì cụm điểm cao hơn giữ tên, cụm sau lùi sang tên kế tiếp (theo mũi tên). Tên đã được đối chiếu với profile ở mục 7.

Biểu đồ: các cụm trên PC1–PC2, boxplot RFM theo cụm, heatmap z-score của từng chỉ số theo cụm.

7. Customer group profile

Biến mô tả có trong dữ liệu:

- Nhân khẩu học: giới tính, nhóm tuổi, vùng, kênh thu hút.
- Hành vi: thiết bị, phương thức thanh toán, nguồn đơn, danh mục ưa thích.

Dữ liệu **không có** nghề nghiệp hay thu nhập.

Phương pháp:

- Tỷ lệ % của mỗi nhóm giá trị trong từng cụm.
- **Lift** = % trong cụm / % toàn bộ khách: lift > 1,15 là đặc trưng nổi bật của cụm, < 0,85 là ít gặp trong cụm.
- **Chi-square + Cramér's V** để biết biến nào thực sự khác biệt giữa các cụm. Với ~87 nghìn khách thì p-value gần như luôn rất nhỏ, nên đánh giá bằng Cramér's V: < 0,1 nghĩa là biến gần như không phân biệt cụm, không nên dùng để nhắm mục tiêu.

Biến nào phân biệt cụm (k = 5):

- **Mức trung bình** (V = 0,11–0,25): danh mục ưa thích (0,245), phương thức thanh toán (0,185), thiết bị (0,143), nguồn đơn (0,128), vùng (0,113).
- **Không đáng kể** (V < 0,01): kênh thu hút, giới tính, nhóm tuổi.

Nghĩa là khi nhắm mục tiêu nên dựa vào **hành vi mua** (danh mục, thanh toán, thiết bị, kênh đặt đơn), không nên dựa vào nhân khẩu học.

Chân dung từng nhóm (chi tiết và biểu đồ: `customer_segment_profiles.md`). Recency tính đến 01/01/2023, giá trị là median; lift = tỷ lệ trong nhóm ÷ tỷ lệ toàn bộ khách.

Nhóm rule-based: chưa tạo ra doanh thu (34.091 khách, 28%)

- **RB1 · Chưa giao dịch** (31.684 khách, 26,0%): đăng ký nhưng chưa đặt đơn nào. Tập trung ở vùng Central (43%, lift 1,17); các đặc điểm khác gần như toàn bộ khách. Cứ 4 khách đăng ký thì 1 khách chưa từng mua: cơ hội rõ nhất ở đầu phễu.
- **RB2 · Đặt đơn nhưng chưa chuyển đổi** (2.407 khách, 2,0%): mọi đơn đều bị hủy (2.123) hoặc bỏ dở (258), cả hai 26. Chân dung gần như toàn bộ khách. Đã có ý định mua nhưng gặp rào cản; 152 khách thất bại từ 2 đơn trở lên có ý định rõ nhất.

Nhóm K-Means: khách đã mua (87.839 khách, 72%)

- **C0 · Champions** (12.384 khách, 43,6% doanh thu): mua gần nhất (~5 tháng), nhiều đơn nhất (17), chi cao nhất (421 nghìn), gắn bó lâu nhất. Gần như chỉ mua Streetwear (96%, lift 1,21), trả bằng thẻ tín dụng (96%, lift 1,36), đến từ tìm kiếm tự nhiên (52%, lift 1,35), mua trên mobile (lift 1,20), tập trung ở vùng West (lift 1,73), **rất ít đến từ email** (lift 0,49). Chỉ ~10% tổng số khách nhưng gánh gần một nửa doanh thu, và doanh nghiệp chưa có kênh liên lạc trực tiếp với họ.
- **C2 · Trung thành** (19.103 khách, 34,9% doanh thu): từng mua nhiều (9 đơn, 219 nghìn) nhưng **gần 2 năm chưa quay lại** (659 ngày). Chân dung giống Champions: Streetwear (95%), thẻ tín dụng (88%), tìm kiếm tự nhiên; rất ít dùng COD (lift 0,52). Là "Champions của ngày trước" đang trôi dần; nếu không kéo lại sẽ thành Ngủ đông.
- **C4 · Ngủ đông** (24.995 khách, 13,1% doanh thu): 3 đơn, AOV cao hơn mặt bằng (22,6 nghìn) nhưng ~4,5 năm chưa mua. Đặt trực tiếp (lift 1,53) và qua email (1,35); thanh toán Apple Pay (1,60), chuyển khoản (1,58), COD (1,35). Mỗi đơn từng có giá trị khá và nhóm này phản hồi với email, nên đánh thức được bằng kênh chi phí thấp.
- **C3 · Khách mới / tiềm năng** (8.945 khách, 5,7% doanh thu): mua gần đây (~7 tháng) nhưng mới 4 đơn, gắn bó ngắn. Đặt trực tiếp (1,33) và qua email (1,17); Apple Pay (1,29), COD (1,17); ít ở vùng West (0,70). Giai đoạn quyết định họ thành Trung thành hay rơi rụng, và liên lạc được qua email.
- **C1 · Đã rời bỏ** (22.412 khách, 2,6% doanh thu): chỉ 1 đơn, giá trị thấp nhất (12,8 nghìn), ~6,5 năm chưa quay lại, tỷ lệ trả hàng cao nhất (7,8%). Chân dung khác hẳn: mua GenZ (lift 2,93) và Outdoor (2,31) nhiều bất thường, dùng tablet (2,17), PayPal (2,08), đến từ giới thiệu (1,76). Giả thuyết cần kiểm chứng: trải nghiệm sản phẩm GenZ/Outdoor có thể là lý do rời bỏ.

Tóm lại:

1. **Doanh thu phụ thuộc vào một nhóm nhỏ:** Champions và Trung thành là 35,8% khách đã mua nhưng mang về 78,5% doanh thu, và gần như đều là khách Streetwear trả bằng thẻ tín dụng.
2. **Rủi ro lớn nhất:** nhóm Trung thành đã gần 2 năm chưa mua.
3. **Cơ hội lớn nhất ở đầu phễu:** 28% khách đăng ký chưa từng tạo ra doanh thu.

8. Recommendation để tăng doanh thu

Hành động cho từng nhóm dựa trên profile ở mục 7. **Thứ tự ưu tiên** theo doanh thu đang có hoặc có thể kéo về so với chi phí:

Ưu tiên	Nhóm	Mục tiêu	Hành động	Kênh tiếp cận (theo profile)	KPI
1	C0 Champions (43,6% doanh thu)	Giữ chân, tăng giá trị	Hạng VIP, quyền mua sớm bộ sưu tập Streetwear mới, upsell sản phẩm premium; **không** giảm giá sâu	App/mobile và ưu đãi gắn thẻ tín dụng; chủ động thu email vì nhóm này hiện ít đến từ email (lift 0,49)	Tỷ lệ giữ chân 90 ngày, AOV
1	C2 Trung thành (34,9% doanh thu)	Kéo quay lại trước khi trôi thành Ngủ đông	Nhắc mua theo mốc 6/12 tháng từ đơn cuối, điểm thưởng có hạn dùng, cross-sell Streetwear	Organic search (SEO/landing page Streetwear), email nhắc mua	% khách mua lại trong 12 tháng, Frequency
2	RB1 Chưa giao dịch (26,0% khách)	Kích hoạt đơn đầu tiên	Voucher đơn đầu có hạn, email giới thiệu sản phẩm bán chạy	Email/push theo kênh thu hút của khách	Tỷ lệ chuyển đổi đơn đầu
2	RB2 Đặt đơn nhưng chưa chuyển đổi (2,0% khách)	Gỡ rào cản chuyển đổi	Tìm lý do hủy/bỏ dở (thanh toán, giá, giao hàng), retarget đúng sản phẩm từng đặt; ưu tiên 152 khách có ≥ 2 đơn thất bại	Email/retargeting theo sản phẩm đã đặt	Tỷ lệ chuyển đổi đơn đầu
3	C3 Khách mới / tiềm năng (5,7% doanh thu)	Tạo thói quen mua lặp lại	Voucher đơn kế tiếp trong 30 ngày, email onboarding, gợi ý sản phẩm bán chạy	Email và kênh trực tiếp (lift 1,17 và 1,33)	Tỷ lệ mua lần tiếp theo trong 90 ngày
4	C4 Ngủ đông (13,1% doanh thu)	Đánh thức với chi phí thấp	Email theo mùa, ưu đãi nhỏ; chạy thử với nhóm đối chứng trước khi tăng ngân sách	Email (lift 1,35), kênh trực tiếp	Reactivation rate
5	C1 Đã rời bỏ (2,6% doanh thu)	Tối ưu chi phí	Chỉ email định kỳ, không ưu đãi lớn; rà soát trải nghiệm sản phẩm GenZ/Outdoor vì nhóm này mua hai danh mục đó nhiều bất thường	Email chi phí gần 0	Chi phí/đơn kéo về

Nguyên tắc chung: đo mọi hành động bằng nhóm đối chứng (giữ 10% khách mỗi nhóm không nhận ưu đãi) để biết doanh thu tăng thêm thật sự. Ước tính tác động doanh thu cần tỷ lệ phản hồi thực tế từ lần chạy thử, nên chưa đưa con số ở đây.

Cách chạy

```
python customer_segmentation/01_build_customer_dataset.py
python customer_segmentation/02_transform_features.py
python customer_segmentation/03_pca_analysis.py                    # --variance-target 0.9 / --n-component
python customer_segmentation/04_select_k.py                        # quét k, không ghi nhãn
python customer_segmentation/05_kmeans_segmentation.py --k <k>     # --input pca|scaled
python customer_segmentation/06_cluster_profiling.py
```

Đầu ra (trong `data/processed/customer_segmentation/`):

File	Nội dung
`customer_analysis_base.csv`	RFM + nhân khẩu học + nhóm rule-based cho toàn bộ khách

File	Nội dung
`customer_features_transformed.csv`	RFM sau biến đổi + scale (khách đã mua)
`feature_engineering/*.csv`	So sánh phép biến đổi, đánh giá biến ứng viên
`customer_pca_scores.csv`, `pca_*.csv`	Điểm PC và kết quả PCA
`k_selection/*.csv`	Chỉ số và thành phần cụm theo từng k
`customer_segments.csv`	Nhãn K-Means (khách đã mua)
`customer_segments_all.csv`	Nhãn cuối cùng cho **toàn bộ** khách (rule-based + K-Means)
`profiles/*.csv`	Profile số, rank index, profile phân loại, kiểm định Cramér's V
`plots/`	Biểu đồ PCA và profile

Nhật ký cập nhật ✍️

Ngày	Thay đổi
2026-10-15	Tạo flow; hoàn thành aggregation, quality check, log + scale, PCA
2026-10-15	Thêm rule-based segmentation cho khách chưa mua; thêm bước profiling (bức tranh tổng thể)
2026-10-15	Đổi business rule doanh thu: tính cả đơn `paid` / `shipped`, chỉ loại `created` và `cancelled`; RB3 = có đơn `created`
2026-10-15	Thêm bước 4 chọn k (quét k = 2–8, đánh giá thống kê + ổn định + business); đổi luật đặt tên cụm sang ma trận Recency × Giá trị
2026-10-15	Rule-based còn 2 nhóm: RB1 Chưa giao dịch, RB2 Đặt đơn nhưng chưa chuyển đổi (gộp đơn hủy + đơn bỏ dở, thêm `failed_order_count`, `failed_reason`)
2026-10-15	Thêm báo cáo feature engineering: so sánh phép biến đổi theo skew, tham số scale, đánh giá biến hành vi ứng viên
2026-10-16	Chốt k = 5 kèm lý do; điền kết quả cụm, profile và hành động theo từng nhóm; bước chọn k ưu tiên k đạt điều kiện có nhiều nhóm hành động nhất

Feature engineering cho phân cụm khách hàng

Tạo tự động bởi `customer_segmentation/02_transform_features.py`.

1. Biến đưa vào K-Means: RFM

Áp dụng cho **87,839 khách có đơn phát sinh doanh thu**. 34,091 khách không có đơn doanh thu được gán nhóm rule-based ở bước 01, không đưa vào K-Means.

Biến	Định nghĩa	Chiều tốt	Min	Median	Mean	Max	Skew
`recency_days`	Số ngày từ đơn doanh thu gần nhất đến ngày tham chiếu (ngày đặt cuối cùng trong dữ liệu + 1)	Thấp	1	1,033	1,289	3,833	+0.62
`frequency`	Số đơn phát sinh doanh thu (`paid` / `shipped` / `delivered` / `returned`)	Cao	1	4	7	100	+2.61
`monetary`	Σ(`payment_value` − tiền hoàn của đơn), mỗi đơn chặn dưới ở 0	Cao	0	81,552	154,211	3,115,457	+2.55

Vì sao chỉ dùng RFM:

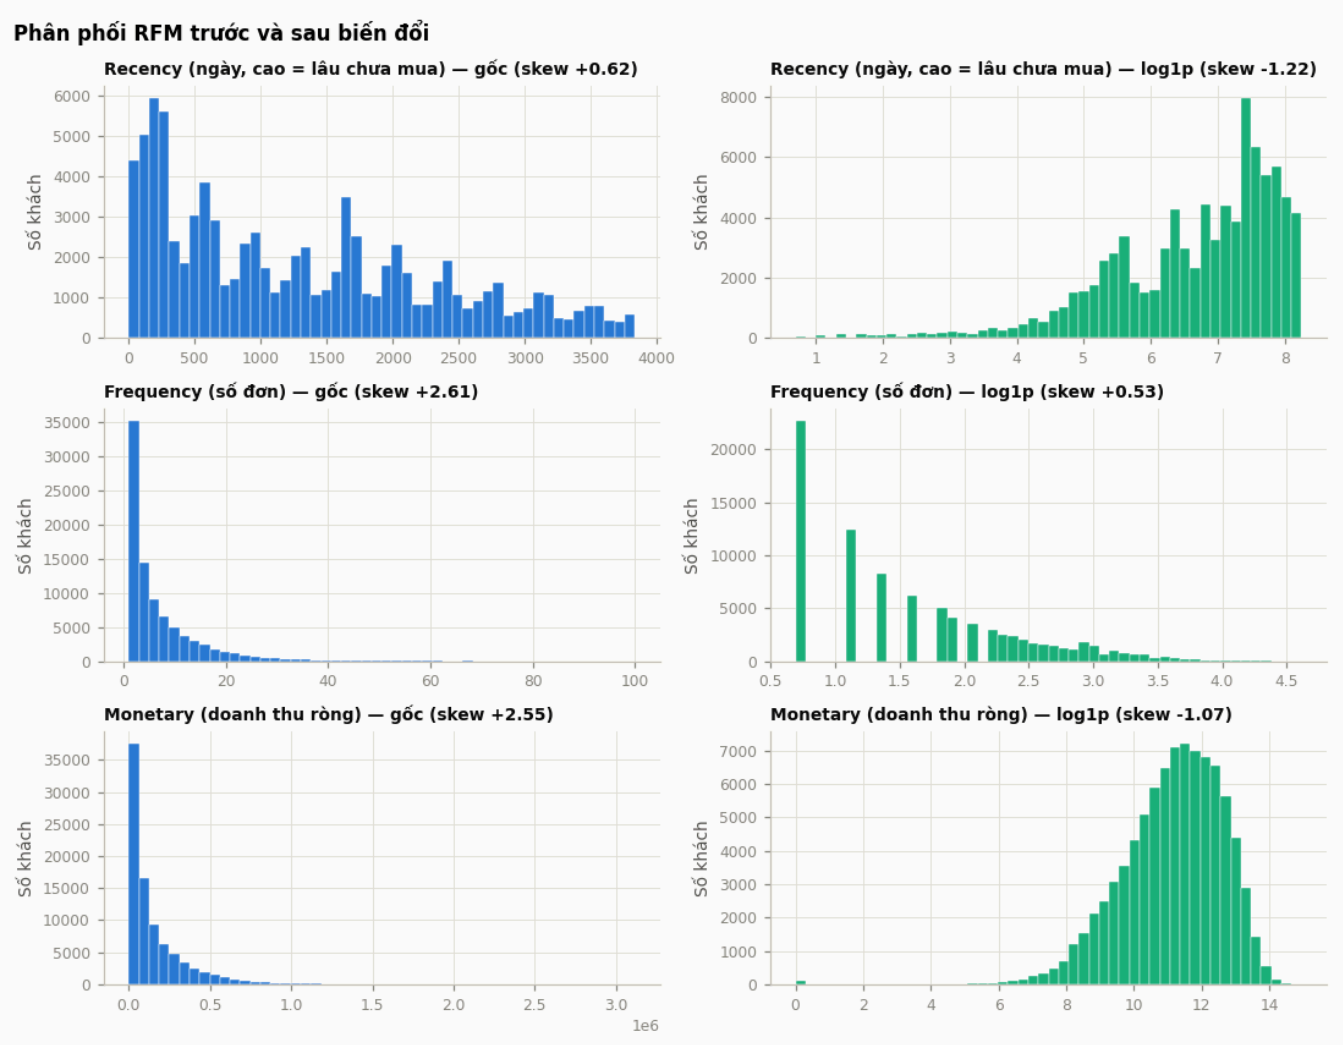
- RFM đo trực tiếp **hành vi mua tạo doanh thu**: đây là thứ doanh nghiệp tác động được bằng marketing, và gắn thẳng với mục tiêu tăng doanh thu.
- Nhân khẩu học (tuổi, giới tính, vùng, kênh thu hút) **không** đưa vào. Lý do: cụm cần phản ánh hành vi; các biến này chỉ dùng để mô tả cụm sau khi phân xong (bước 06).
- Có 119 khách có `monetary` = 0, do tiền hoàn bằng hoặc vượt tiền thanh toán (chặn ở 0). Họ vẫn có frequency và recency nên vẫn được giữ lại.

2. Biến đổi phân phối

K-Means nhạy với phân phối lệch: vài khách chi tiêu cực lớn sẽ kéo tâm cụm và chiếm khoảng cách. Mỗi biến được thử 4 phép biến đổi. Gợi ý là **phép đơn giản nhất** có |skew| không kém lựa chọn tốt nhất quá 0,1 (|skew| gần 0 nghĩa là phân phối gần đối xứng).

Biến	Không biến đổi	sqrt	log1p	Yeo-Johnson	Đang dùng	Gợi ý
`recency_days`	+0.62	+0.01	-1.22	-0.17	`log1p` ⚠️	`sqrt`
`frequency`	+2.61	+1.19	+0.53	+0.13	`log1p` ⚠️	`yeo-johnson`
`monetary`	+2.55	+0.96	-1.07	-0.02	`log1p` ⚠️	`yeo-johnson`

⚠️ **Phép biến đổi đang dùng khác gợi ý** cho: `recency_days` (đang `log1p`, skew -1.22; gợi ý `sqrt`, skew +0.01), `frequency` (đang `log1p`, skew +0.53; gợi ý `yeo-johnson`, skew +0.13), `monetary` (đang `log1p`, skew -1.07; gợi ý `yeo-johnson`, skew -0.02). Đổi trong `config.FEATURE_TRANSFORMS` rồi chạy lại từ bước 02.



3. Chuẩn hóa (StandardScaler)

Sau khi biến đổi, mỗi biến được chuẩn hóa về **mean 0, độ lệch chuẩn 1**. K-Means dùng khoảng cách Euclid, nên nếu không chuẩn hóa thì biến có thang lớn (Monetary) sẽ quyết định gần như toàn bộ khoảng cách.

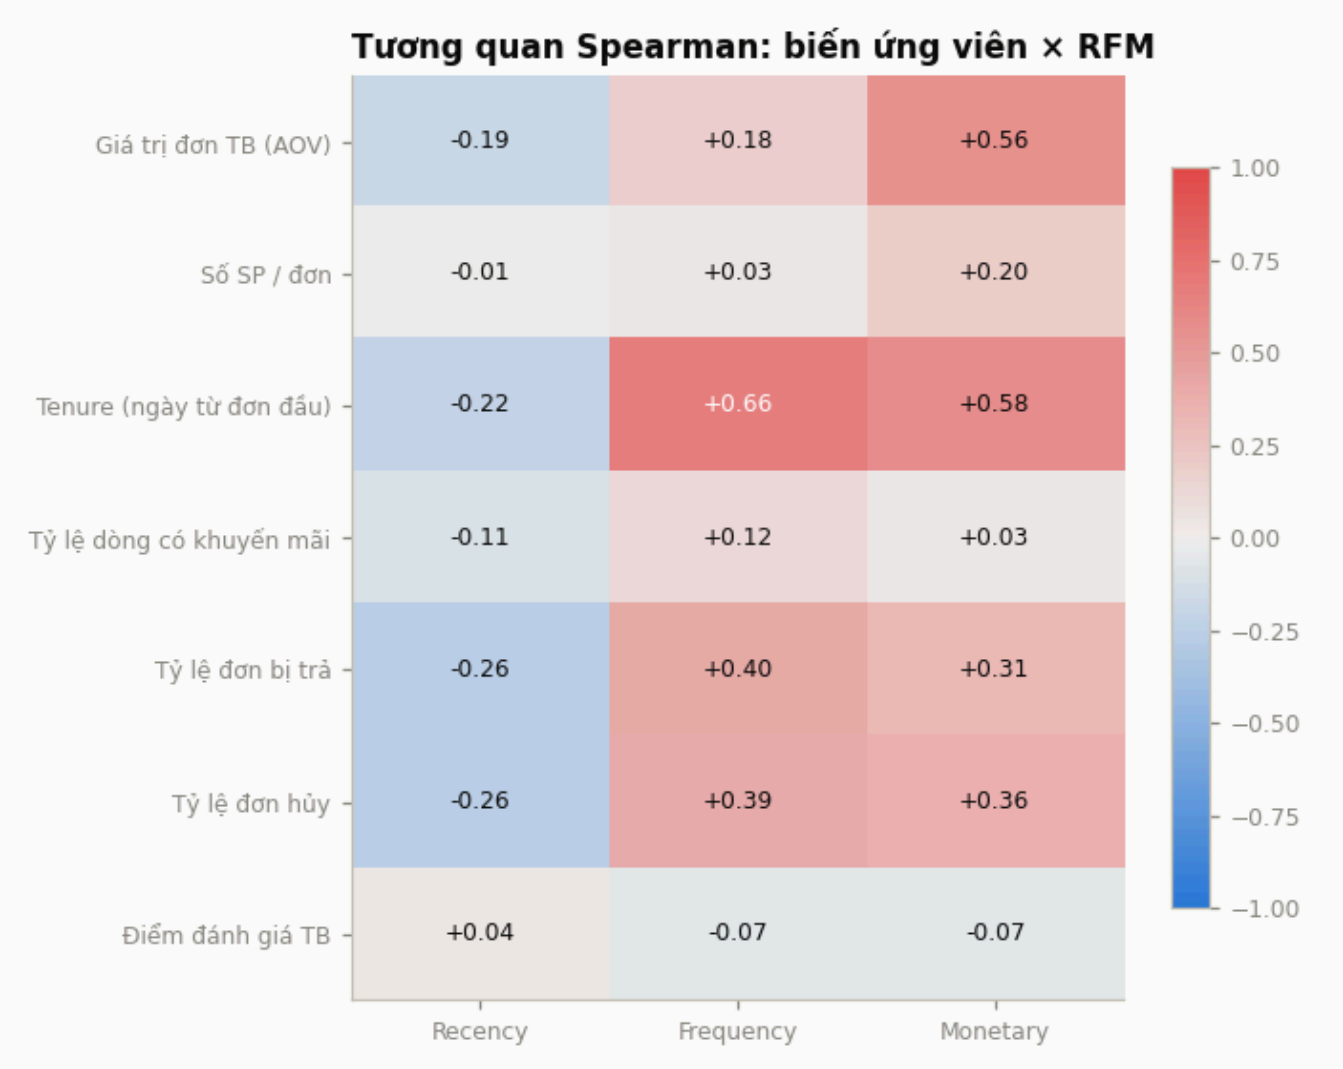
Biến	Phép biến đổi	Mean trước scale	Std trước scale	Mean sau scale	Std sau scale
`recency_days`	`log1p`	6.643	1.261	+0.000	1.000
`frequency`	`log1p`	1.651	0.832	-0.000	1.000
`monetary`	`log1p`	11.146	1.494	+0.000	1.000

Bước tiếp theo (chương PCA): các biến sau chuẩn hóa vẫn tương quan với nhau (Frequency ↔ Monetary), nên dùng PCA để khử tương quan trước khi chạy K-Means.

4. Biến hành vi ứng viên

Các biến dưới đây được tạo từ dữ liệu giao dịch và đánh giá theo câu hỏi: biến này có mang **thông tin mới** so với RFM không? Dùng tương quan Spearman (bền với dữ liệu lệch). $|\rho| \geq 0.7$ với một biến RFM nghĩa là trùng thông tin: đưa vào K-Means chỉ làm khía cạnh đó bị tính hai lần.

Biến	Định nghĩa	Độ phủ	Median	Skew	Tương quan mạnh nhất với RFM	Quyết định
`aov`	Monetary / Frequency	100%	21,266.97	+1.87	`monetary` (+0.56)	Mang thông tin mới so với RFM → dùng để mô tả cụm; có thể cân nhắc đưa vào K-Means ✍️
`items_per_order`	Tổng số sản phẩm / số đơn doanh thu	100%	5.00	+0.72	`monetary` (+0.20)	Mang thông tin mới so với RFM → dùng để mô tả cụm; có thể cân nhắc đưa vào K-Means ✍️
`tenure_days`	Số ngày từ đơn doanh thu đầu tiên đến ngày tham chiếu	100%	3,299.00	-1.40	`frequency` (+0.66)	Mang thông tin mới so với RFM → dùng để mô tả cụm; có thể cân nhắc đưa vào K-Means ✍️
`promo_share`	Tỷ lệ dòng hàng có mã khuyến mãi	100%	0.35	+0.53	`frequency` (+0.12)	Mang thông tin mới so với RFM → dùng để mô tả cụm; có thể cân nhắc đưa vào K-Means ✍️
`return_rate`	Tỷ lệ đơn bị trả trên số đơn doanh thu	100%	0.00	+4.10	`frequency` (+0.40)	Mang thông tin mới so với RFM → dùng để mô tả cụm; có thể cân nhắc đưa vào K-Means ✍️
`cancel_rate`	Tỷ lệ đơn hủy trên mọi đơn đã đặt	100%	0.00	+2.11	`frequency` (+0.39)	Mang thông tin mới so với RFM → dùng để mô tả cụm; có thể cân nhắc đưa vào K-Means ✍️
`avg_rating`	Điểm đánh giá trung bình (chỉ khách có đánh giá)	55%	4.00	-1.03	`frequency` (-0.07)	Mang thông tin mới so với RFM → dùng để mô tả cụm; có thể cân nhắc đưa vào K-Means ✍️



Biến phân loại (danh mục, thiết bị, phương thức thanh toán, nguồn đơn ưa thích) và **nhân khẩu học** không đưa vào K-Means vì không đo được bằng khoảng cách Euclid; chúng được dùng để mô tả cụm ở bước 06.

5. Kết quả

- Ma trận đặc trưng: **87,839 khách × 3 biến** (`recency_days` , `frequency` , `monetary`), đã biến đổi và chuẩn hóa.
- File: `data/processed/customer_segmentation/customer_features_transformed.csv` . Đây là đầu vào của PCA (bước 03).
- ✍️ Nếu quyết định thêm biến hành vi vào K-Means: thêm vào `config.RFM_FEATURES` , khai báo phép biến đổi trong `config.FEATURE_TRANSFORMS` , rồi chạy lại từ bước 02.

PCA cho phân cụm khách hàng

Tạo tự động bởi `customer_segmentation/03_pca_analysis.py`.

1. Vì sao dùng PCA trước K-Means

1. **K-Means đo khoảng cách Euclid**, mọi biến có trọng số như nhau. Khi hai biến tương quan mạnh, chúng đo cùng một khía cạnh hành vi và khía cạnh đó bị tính hai lần. Ở đây cặp tương quan mạnh nhất là **Frequency – Monetary (r = 0.83)**: khách mua nhiều lần thì tổng chi tiêu cũng cao. Nếu không xử lý, cụm sẽ bị chi phối bởi "giá trị mua" và Recency bị lép vế.
2. **PCA xoay dữ liệu sang các trục trực giao** (không tương quan). Mỗi trục gom phần thông tin chung của các biến tương quan, nên khoảng cách không còn bị đếm trùng khi ta bỏ bớt trục ít thông tin.
3. **Rút gọn chiều và lọc nhiễu**: giữ các PC giải thích phần lớn phương sai, bỏ PC cuối (chủ yếu là nhiễu).
4. **Trực quan hóa**: PC1–PC2 là mặt phẳng 2D tốt nhất để vẽ và kiểm tra cụm có tách nhau không.
5. **Diễn giải**: loadings cho biết mỗi trục được tạo từ biến nào, giúp đặt tên trục theo ngôn ngữ kinh doanh.

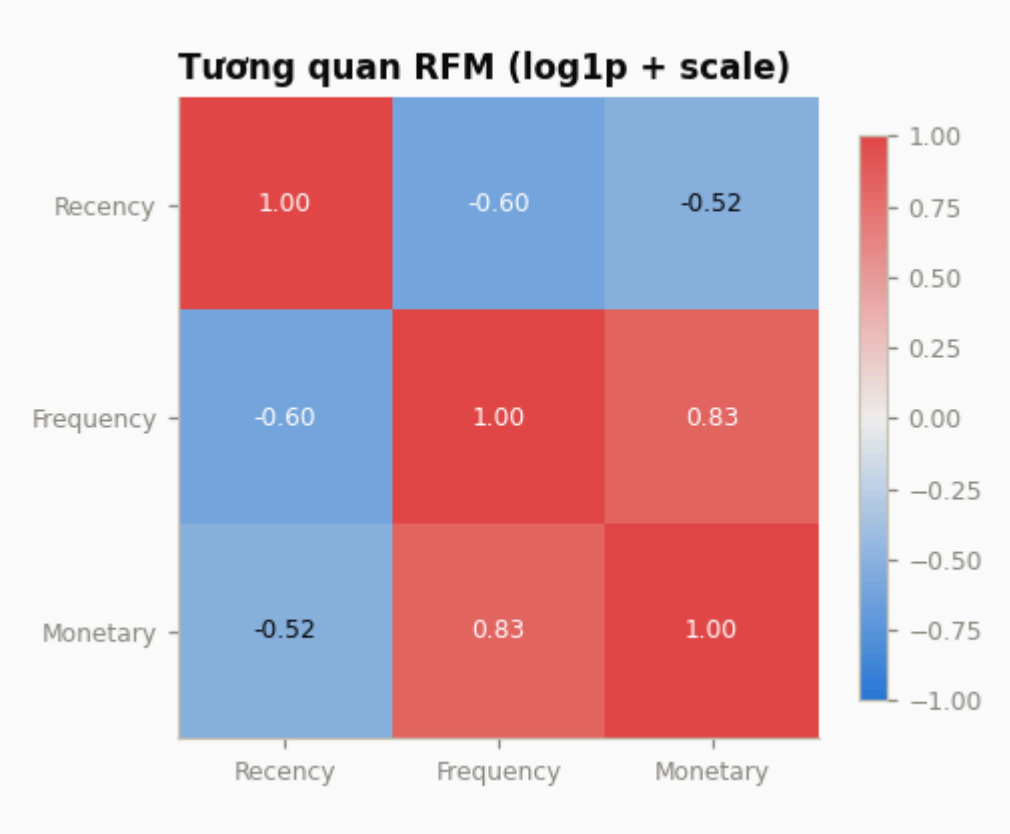
Tiền xử lý bắt buộc: `log1p` (vì Frequency/Monetary lệch phải mạnh) rồi `StandardScaler`. PCA tìm hướng có phương sai lớn nhất, nên nếu không chuẩn hóa thì Monetary (đơn vị tiền, hàng chục nghìn) sẽ chiếm gần trọn PC1.

> **Lưu ý quan trọng:** nếu giữ **đủ tất cả** PC thì PCA chỉ là phép xoay, khoảng cách Euclid không đổi, nên K-Means cho kết quả **giống hệt** khi chạy trên dữ liệu đã scale. Lợi ích của PCA với K-Means chỉ đến từ việc **bỏ bớt** PC. Với chỉ 3 biến, mức rút gọn nhỏ; giá trị chính là khử tương quan, trực quan hóa và diễn giải.

2. Dữ liệu có phù hợp để PCA không?

- Số khách hàng: **87,839**; số biến: **3** (Recency, Frequency, Monetary).
- **Bartlett's test of sphericity**: χ^2 = 142,475, p = 0 → bác bỏ H0, các biến có tương quan đáng kể, **PCA có ý nghĩa**.
- **KMO** = 0.65 → chấp nhận được (0,6–0,7).

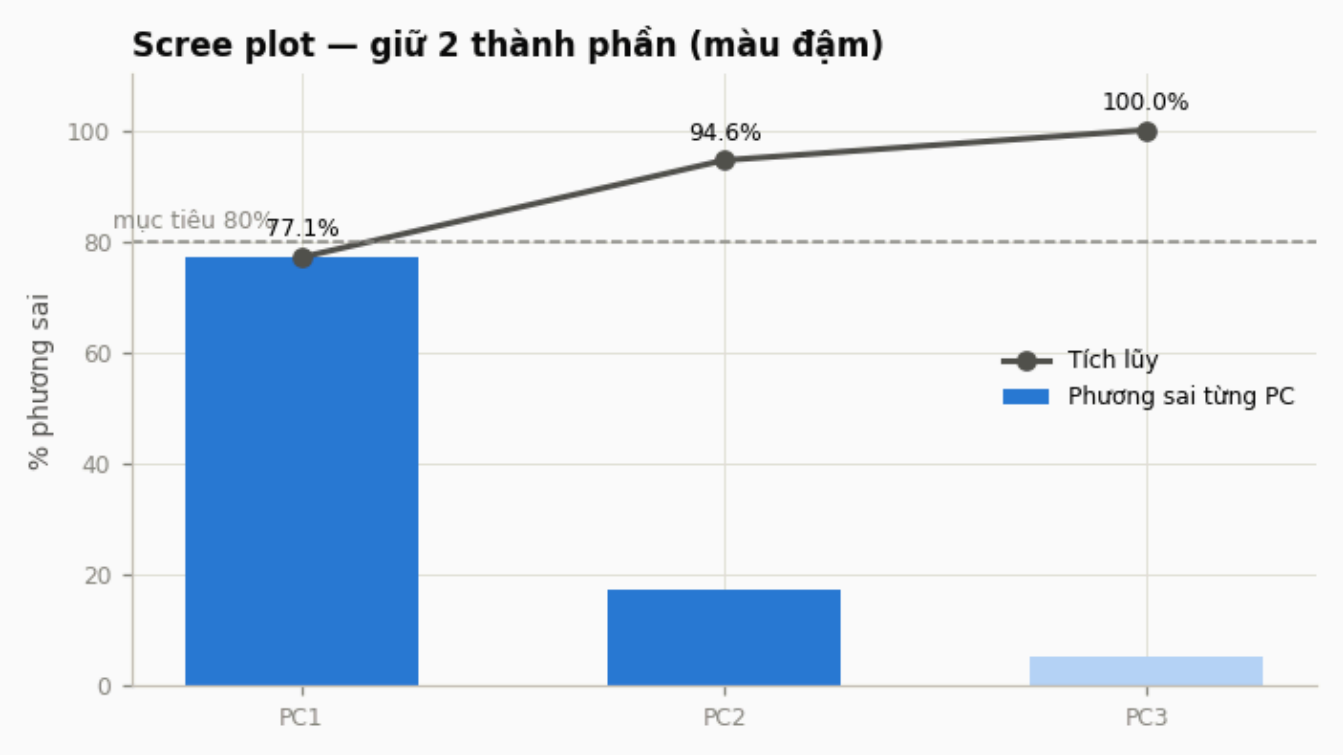
	Recency	Frequency	Monetary
Recency	1.00	-0.60	-0.52
Frequency	-0.60	1.00	0.83
Monetary	-0.52	0.83	1.00



3. Chọn số thành phần

PC	Eigenvalue	% phương sai	% tích lũy	Biến chính (trị tuyệt đối loading ≥ 0,5)
PC1	2.314	77.1%	77.1%	+Frequency (+0.93), +Monetary (+0.91), −Recency (-0.79)
PC2	0.523	17.4%	94.6%	+Recency (+0.61)
PC3	0.163	5.4%	100.0%	−Frequency (-0.30)

- **Tiêu chí phương sai tích lũy** (≥ 80%): cần **2** PC.
- **Tiêu chí Kaiser** (eigenvalue > 1): **1** PC.
- **Scree plot** (`pca_scree.png`): chọn tại "khuỷu", nơi phần phương sai tăng thêm giảm đột ngột.
- **Đã chọn: 2 PC** (phương sai tích lũy ≥ 80%, tối thiểu 2 PC), giữ **94.6%** phương sai. Đổi bằng `--variance-target` hoặc `--n-components` .

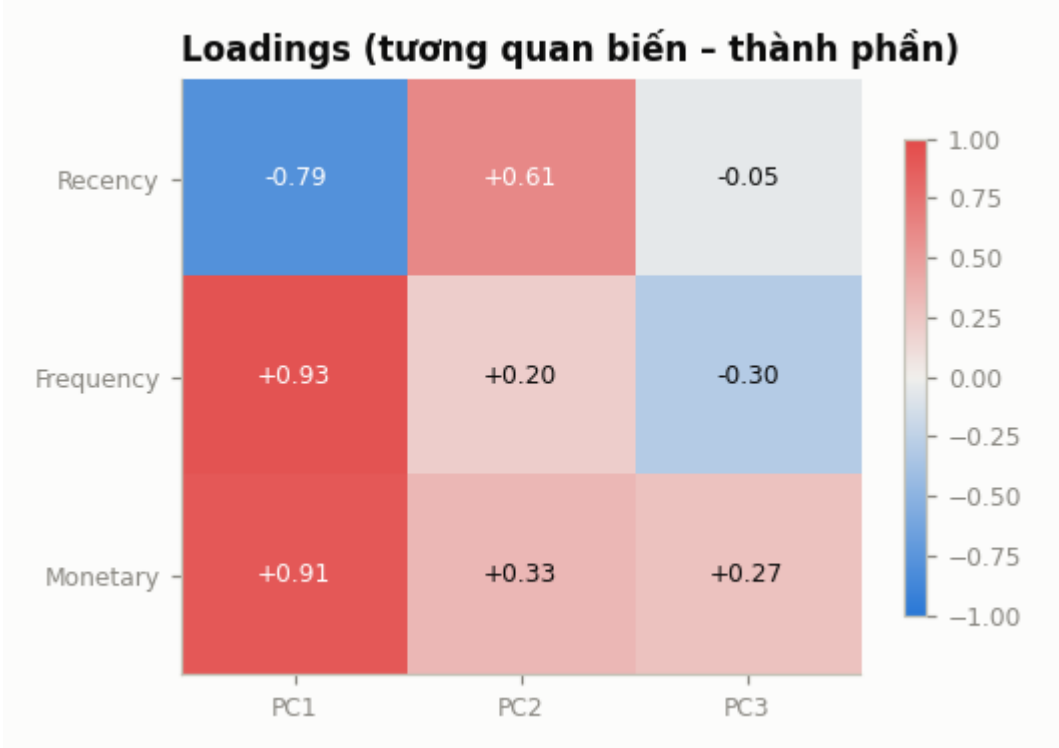


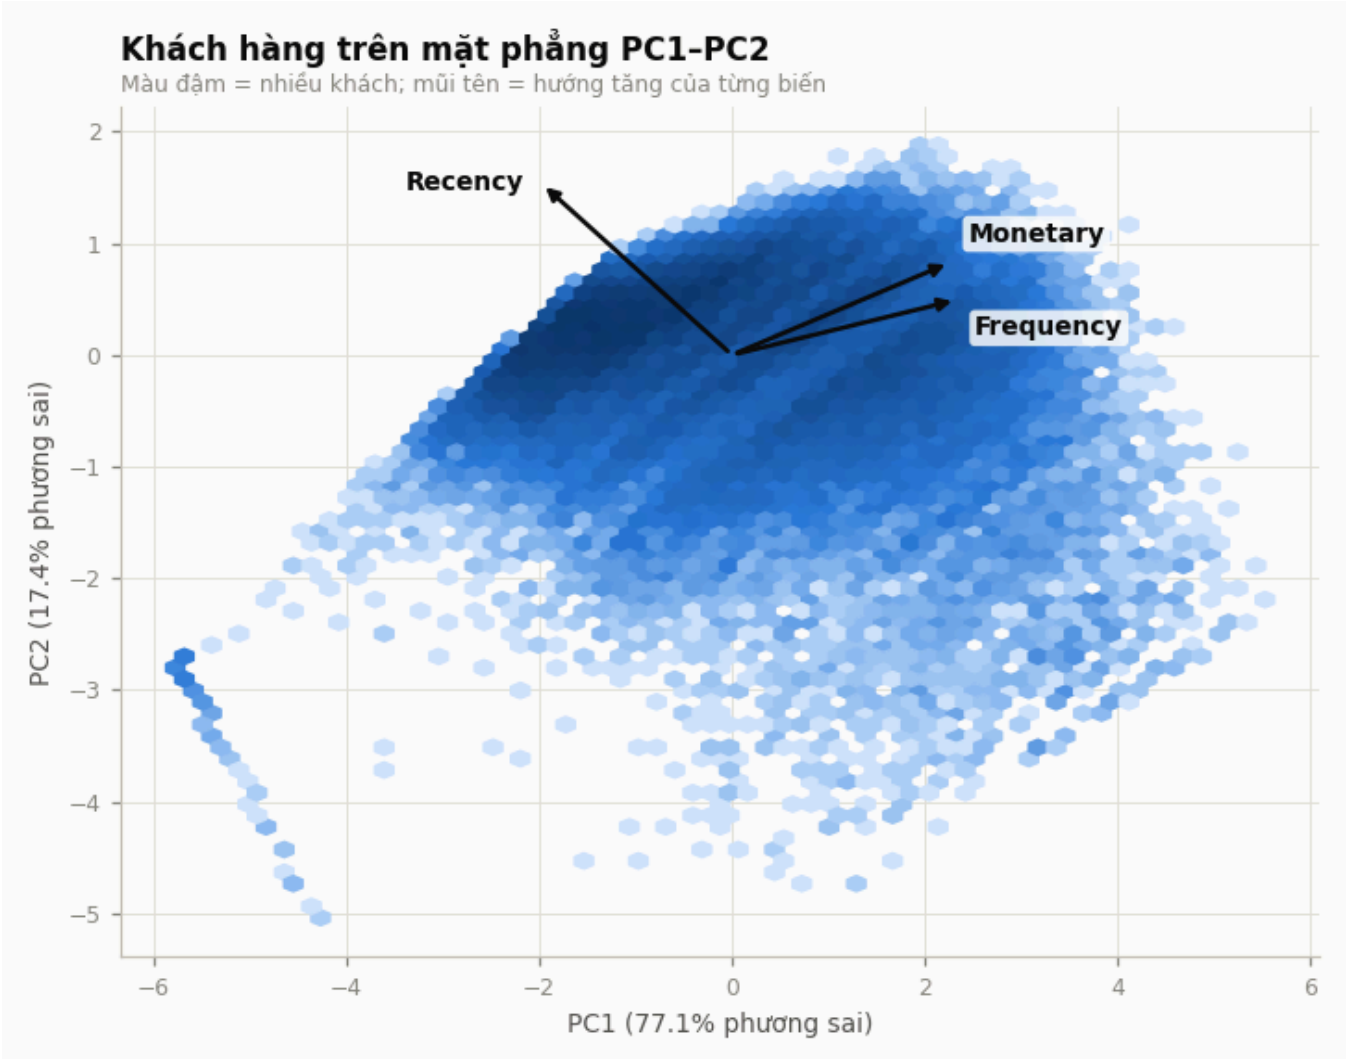
4. Diễn giải các thành phần

Loading = tương quan giữa biến gốc và PC (dấu chỉ chiều; Recency cao = lâu rồi chưa mua = **xấu**).

- **PC1**: +Frequency (+0.93), +Monetary (+0.91), −Recency (-0.79).
- **PC2**: +Recency (+0.61).
- **PC3**: −Frequency (-0.30).

Gợi ý đọc trục: thành phần mà Frequency và Monetary cùng dấu, Recency ngược dấu là trục **"giá trị & gắn bó"** (cao = mua nhiều, chi nhiều, mới mua gần đây). Thành phần mà Recency nổi trội là trục **"độ mới"**, tách khách vừa mua gần đây với khách đã lâu không quay lại ở cùng mức giá trị.


Loadings (tương quan biến – thành phần)
Recency
Frequency
Monetary
-0.79
+0.61
-0.05
+0.93
+0.20
-0.30
+0.91
+0.33
+0.27
PC1
PC2
PC3
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00


Khách hàng trên mặt phẳng PC1–PC2
Màu đậm = nhiều khách; mũi tên = hướng tăng của từng biến
Recency
Monetary
Frequency
PC2 (17.4% phương sai)
PC1 (77.1% phương sai)
2
1
0
−1
−2
−3
−4
−5
−6
−4
−2
0
2
4
6

5. Dùng kết quả cho K-Means

- File đầu vào K-Means: `data/processed/customer_segmentation/customer_pca_scores.csv` (`customer_id` , `PC1` , `PC2`).
- **Không scale lại** điểm PC: phương sai khác nhau giữa các PC chính là mức quan trọng của từng trục. Nếu muốn mọi trục có trọng số bằng nhau thì dùng whitening (`PCA(whiten=True)`), nhưng khi đó nhiễu ở PC nhỏ sẽ bị khuếch đại.
- Kết quả K-Means cần ghi ra `data/processed/customer_segmentation/customer_segments.csv` với 2 cột `customer_id` , `cluster` để bước 5 (`06_cluster_profiling.py`) mô tả cụm.

Chọn số cụm k cho K-Means

Tạo tự động bởi `customer_segmentation/04_select_k.py` · đầu vào: `pca` · 87,839 khách đã mua · k = 2–8 · 5 random_state mỗi k. Bước này **không ghi nhãn cụm**; chọn k xong chạy `05_kmeans_segmentation.py --k <k>`.

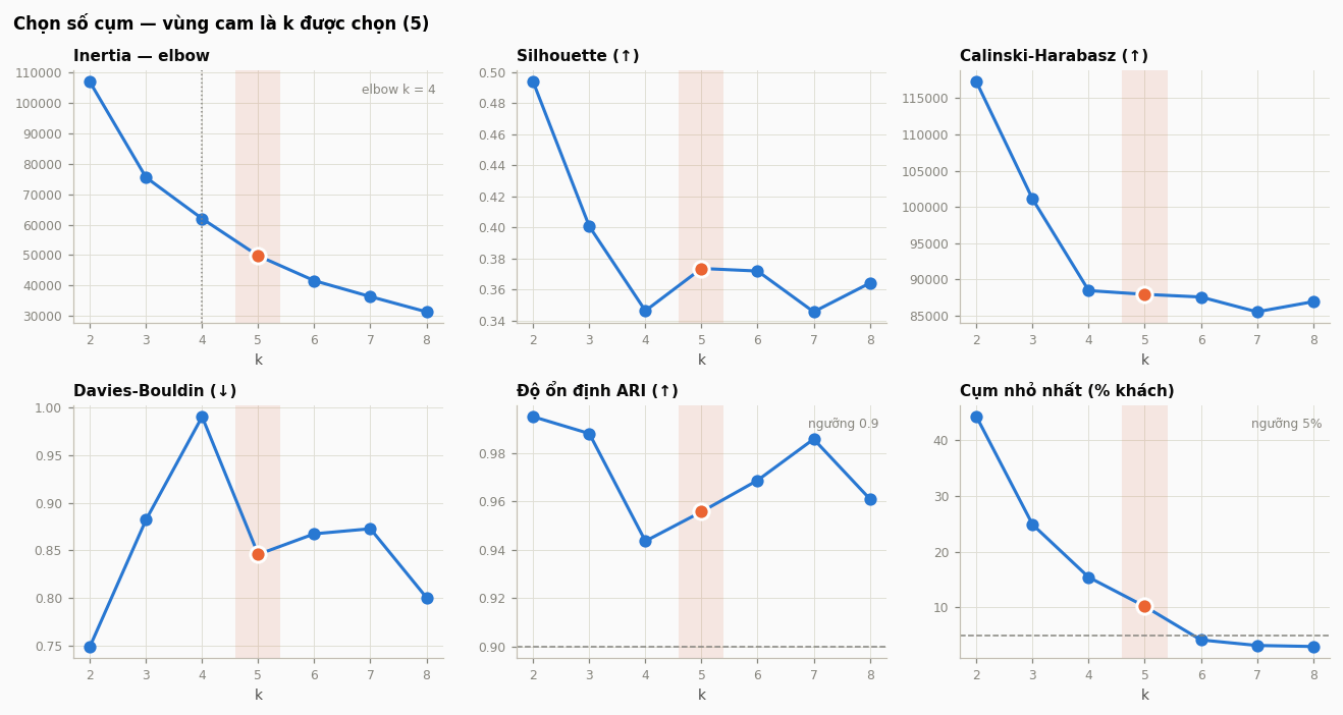
1. Vì sao không chỉ nhìn silhouette

Các chỉ số thống kê thường ưu tiên k nhỏ: ít cụm thì cụm tách nhau rõ hơn. Nhưng số nhóm phải đủ để **mỗi nhóm nhận một chiến lược khác nhau**. Vì vậy k được chọn theo 3 lớp:

1. **Điều kiện business (lọc):** - k ≥ 3. - Cụm nhỏ nhất ≥ 5% khách (đủ lớn để chạy chiến dịch riêng). - Mỗi cụm có tên hành vi khác nhau (`distinct_actions = k`): không có hai cụm cùng một loại, nghĩa là không có hai cụm phải xử lý giống nhau. Tên đặt theo ma trận Recency × Giá trị (`segment_naming.py`).
2. **Độ ổn định:** ARI trung bình giữa các lần chạy ≥ 0.9. Nhãn không đổi khi đổi random_state.
3. **Chất lượng thống kê:** xếp hạng trung bình của Silhouette (↑), Calinski-Harabasz (↑) và Davies-Bouldin (↓); tham khảo thêm điểm elbow của inertia.

2. Kết quả

k	Inertia	Silhouette	Calinski-Harabasz	Davies-Bouldin	ARI	Cụm nhỏ nhất	Nhóm hành động	Hạng TK	Đạt điều kiện
2	106,747	0.494	117,209	0.749	0.995	44.2%	2/2	1.0	—
3	75,474	0.401	101,084	0.882	0.988	24.9%	3/3	3.3	✅
4	61,960	0.346	88,475	0.990	0.944	15.4%	4/4	5.3	✅
5 ◄	49,782	0.374	87,957	0.846	0.956	10.2%	5/5	3.3	✅
6	41,627	0.372	87,592	0.867	0.969	4.2%	5/6	4.3	—
7	36,410	0.346	85,550	0.873	0.986	3.2%	6/7	6.3	—
8	31,427	0.364	86,943	0.800	0.961	3.0%	6/8	4.3	—

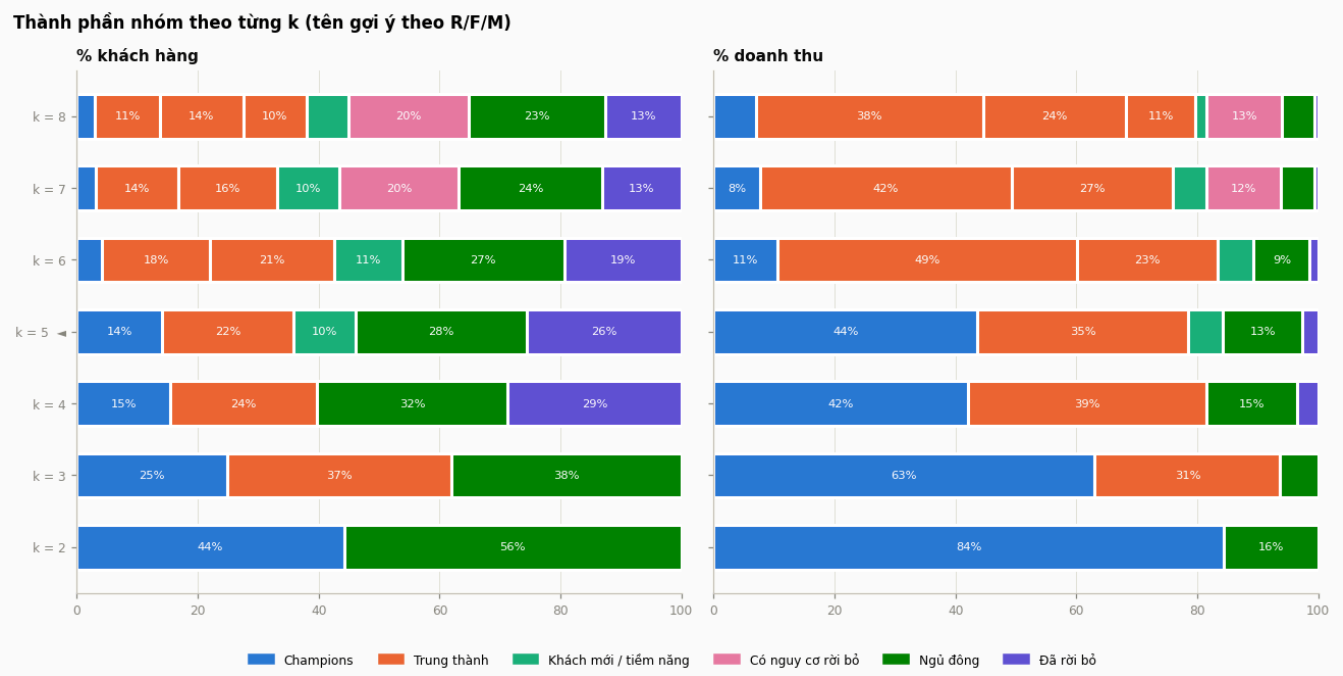


- Elbow của inertia: **k = 4**. Silhouette cao nhất: **k = 2**.

3. Chọn k = 5

1. **Đạt cả 3 lớp điều kiện:** cụm nhỏ nhất 10.2% (≥ 5%), 5/5 cụm là các loại hành vi khác nhau, ARI 0.956 (≥ 0.9).
2. **Nhiều nhóm hành động nhất trong các k đạt điều kiện** (k = 3, 4, 5): mỗi nhóm thêm là một chiến lược riêng triển khai được.
3. **Thống kê không kém:** hạng thống kê 3.3 (tốt nhất, đồng hạng); Davies-Bouldin 0.846, silhouette 0.374. - **Không chọn k = 3:** không tách được *Khách mới / tiềm năng*, *Đã rời bỏ*; các khách này bị gộp vào nhóm khác và nhận chung một hành động. - **Không chọn k = 4:** không tách được *Khách mới / tiềm năng*; các khách này bị gộp vào nhóm khác và nhận chung một hành động. - **Không chọn k = 6:** cụm nhỏ nhất chỉ 4.2%; chỉ 5/6 nhóm hành động khác nhau (có cụm trùng loại). - **Không chọn k = 7:** cụm nhỏ nhất chỉ 3.2%; chỉ 6/7 nhóm hành động khác nhau (có cụm trùng loại). - **Không chọn k = 8:** cụm nhỏ nhất chỉ 3.0%; chỉ 6/8 nhóm hành động khác nhau (có cụm trùng loại).

4. k = 5 chia khách hàng thành những nhóm nào



k = 5 (được chọn)

Cụm	Tên nhóm	% khách	% doanh thu	Recency (ngày)	Frequency	Monetary
0	Champions	14.1%	43.6%	149	17	421,487
2	Trung thành	21.7%	34.9%	659	9	219,127
4	Ngủ đông	28.5%	13.1%	1,650	3	64,500
3	Khách mới / tiềm năng	10.2%	5.7%	206	4	80,930
1	Đã rời bỏ	25.5%	2.6%	2,391	1	12,788

So sánh: k = 3

Cụm	Tên nhóm	% khách	% doanh thu	Recency (ngày)	Frequency	Monetary
0	Champions	24.9%	63.0%	201	14	340,703
2	Trung thành	37.0%	30.7%	977	5	108,472
1	Ngủ đông	38.1%	6.3%	2,165	1	20,306

So sánh: k = 4

Cụm	Tên nhóm	% khách	% doanh thu	Recency (ngày)	Frequency	Monetary
1	Champions	15.4%	42.1%	125	15	367,444
2	Trung thành	24.3%	39.5%	595	9	216,897
3	Ngủ đông	31.6%	14.9%	1,333	3	66,978
0	Đã rời bỏ	28.7%	3.5%	2,392	1	14,546

So sánh: k = 6

Cụm	Tên nhóm	% khách	% doanh thu	Recency (ngày)	Frequency	Monetary
1	Trung thành	17.9%	49.5%	247	16	375,932
2	Trung thành (2)	20.5%	23.3%	998	7	158,576
5	Champions	4.2%	10.6%	31	14	319,249
0	Ngủ đông	26.9%	9.3%	1,888	2	47,456
4	Khách mới / tiềm năng	11.2%	5.9%	248	3	74,252
3	Đã rời bỏ	19.3%	1.4%	2,421	1	9,498

So sánh: k = 7

Cụm	Tên nhóm	% khách	% doanh thu	Recency (ngày)	Frequency	Monetary
4	Trung thành	13.7%	41.8%	195	17	418,235
2	Trung thành (2)	16.4%	26.6%	660	10	229,406
3	Có nguy cơ rời bỏ	19.7%	12.4%	1,400	4	90,624
5	Champions	3.2%	7.6%	19	13	294,527
1	Ngủ đông	23.8%	5.5%	2,100	1	31,397
0	Khách mới / tiềm năng	10.2%	5.5%	225	4	76,053
6	Đã rời bỏ	13.1%	0.6%	2,427	1	6,567

So sánh: k = 8

Cụm	Tên nhóm	% khách	% doanh thu	Recency (ngày)	Frequency	Monetary
0	Trung thành	10.8%	37.5%	204	20	483,613
7	Trung thành (3)	13.8%	23.8%	793	10	245,312
6	Có nguy cơ rời bỏ	19.8%	12.6%	1,367	4	91,849
2	Trung thành (2)	10.5%	11.5%	215	7	160,290
4	Champions	3.0%	7.0%	17	13	295,445
5	Ngủ đông	22.7%	5.4%	2,183	1	32,116
1	Khách mới / tiềm năng	7.0%	1.8%	309	2	34,478
3	Đã rời bỏ	12.6%	0.6%	2,467	1	6,540

5. Bước tiếp theo

```
python customer_segmentation/05_kmeans_segmentation.py --k 5
python customer_segmentation/06_cluster_profiling.py
```

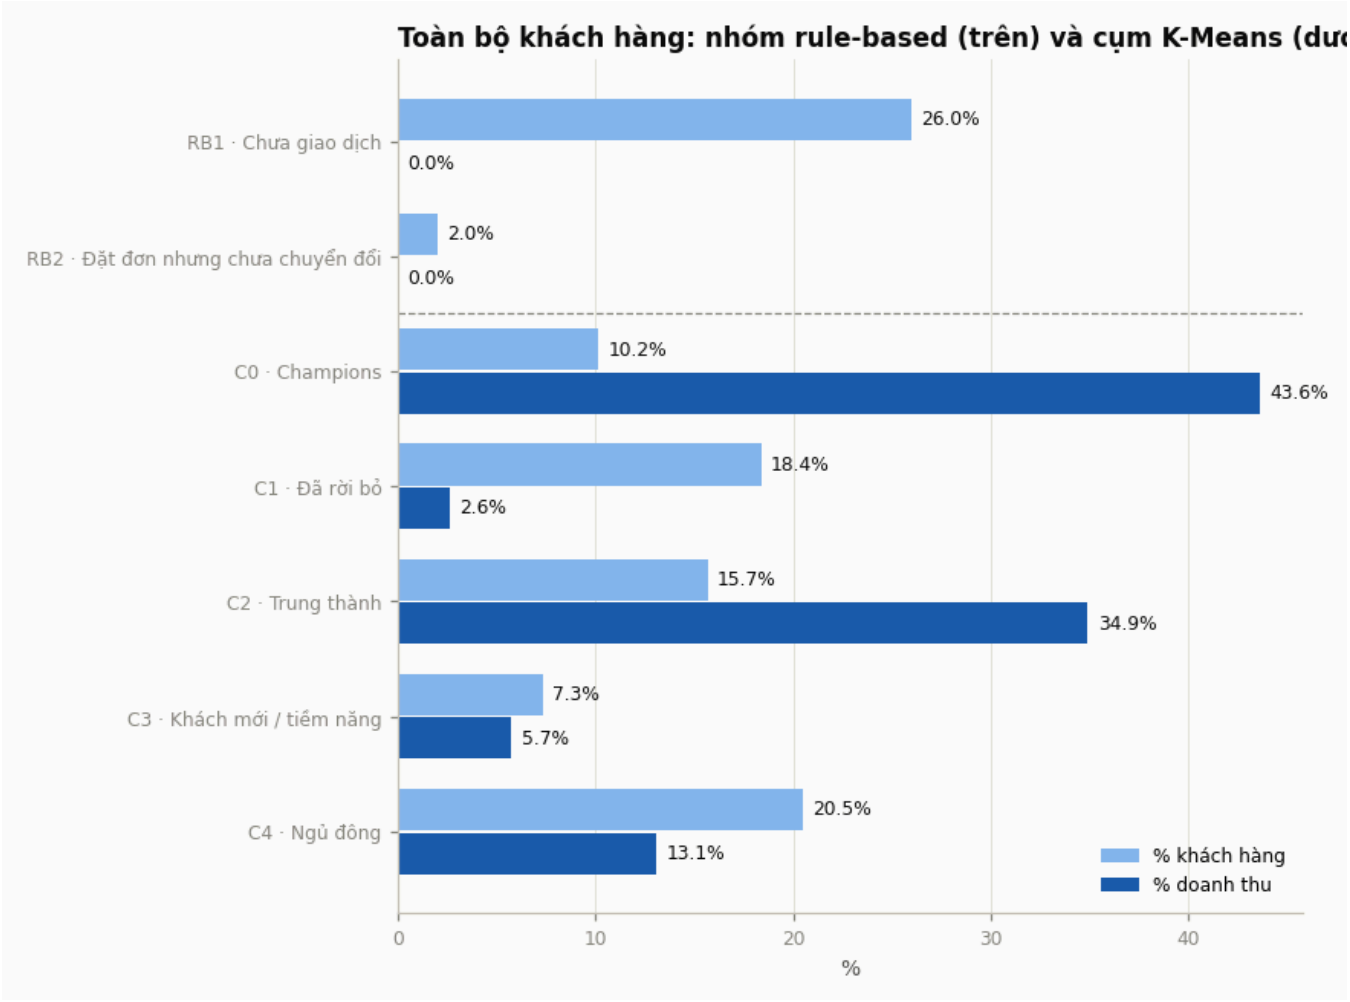
Profile các nhóm khách hàng

Tạo tự động bởi `customer_segmentation/06_cluster_profiling.py` từ nhãn cụm trong `customer_segments.csv`. Tên cụm đặt theo ma trận Recency × Giá trị (`segment_naming.py`) và đã đối chiếu với profile bên dưới. Dữ liệu không có biến nghề nghiệp/thu nhập; chân dung dựa trên giới tính, nhóm tuổi, vùng, kênh thu hút và hành vi mua.

0. Bức tranh tổng thể toàn bộ khách hàng

Khách **chưa có đơn phát sinh doanh thu** được gán nhóm theo luật (**rule-based**, mã RB) trước khi phân cụm; khách **đã mua** được phân cụm bằng K-Means (mã C). Lift nhân khẩu học ở mục này so với toàn bộ khách đã đăng ký.

Phương pháp	Nhóm	Tên	Khách	% khách	% doanh thu	Frequency (median)	Monetary (median)
rule_based	RB1	Chưa giao dịch	31,684	26.0%	0.0%	0	0
rule_based	RB2	Đặt đơn nhưng chưa chuyển đổi	2,407	2.0%	0.0%	0	0
kmeans	C0	Champions	12,384	10.2%	43.6%	17	421,487
kmeans	C1	Đã rời bỏ	22,412	18.4%	2.6%	1	12,788
kmeans	C2	Trung thành	19,103	15.7%	34.9%	9	219,127
kmeans	C3	Khách mới / tiềm năng	8,945	7.3%	5.7%	4	80,930
kmeans	C4	Ngủ đông	24,995	20.5%	13.1%	3	64,500



Luật gán nhóm: có ≥ 1 đơn `paid` / `shipped` / `delivered` / `returned` → K-Means; có đơn nhưng tất cả đều `cancelled` / `created` → **RB2**; chưa đặt đơn nào → **RB1**.

RB1 — Chưa giao dịch

31,684 khách (26.0%) · chưa phát sinh doanh thu.

- **Chân dung nổi bật:** Vùng = Central 43% (lift 1.17).
- **Mục tiêu:** Kích hoạt đơn đầu tiên. **Hành động:** Voucher đơn đầu có hạn, email/push giới thiệu sản phẩm bán chạy theo kênh thu hút của khách. **KPI:** Tỷ lệ chuyển đổi đơn đầu.

RB2 — Đặt đơn nhưng chưa chuyển đổi

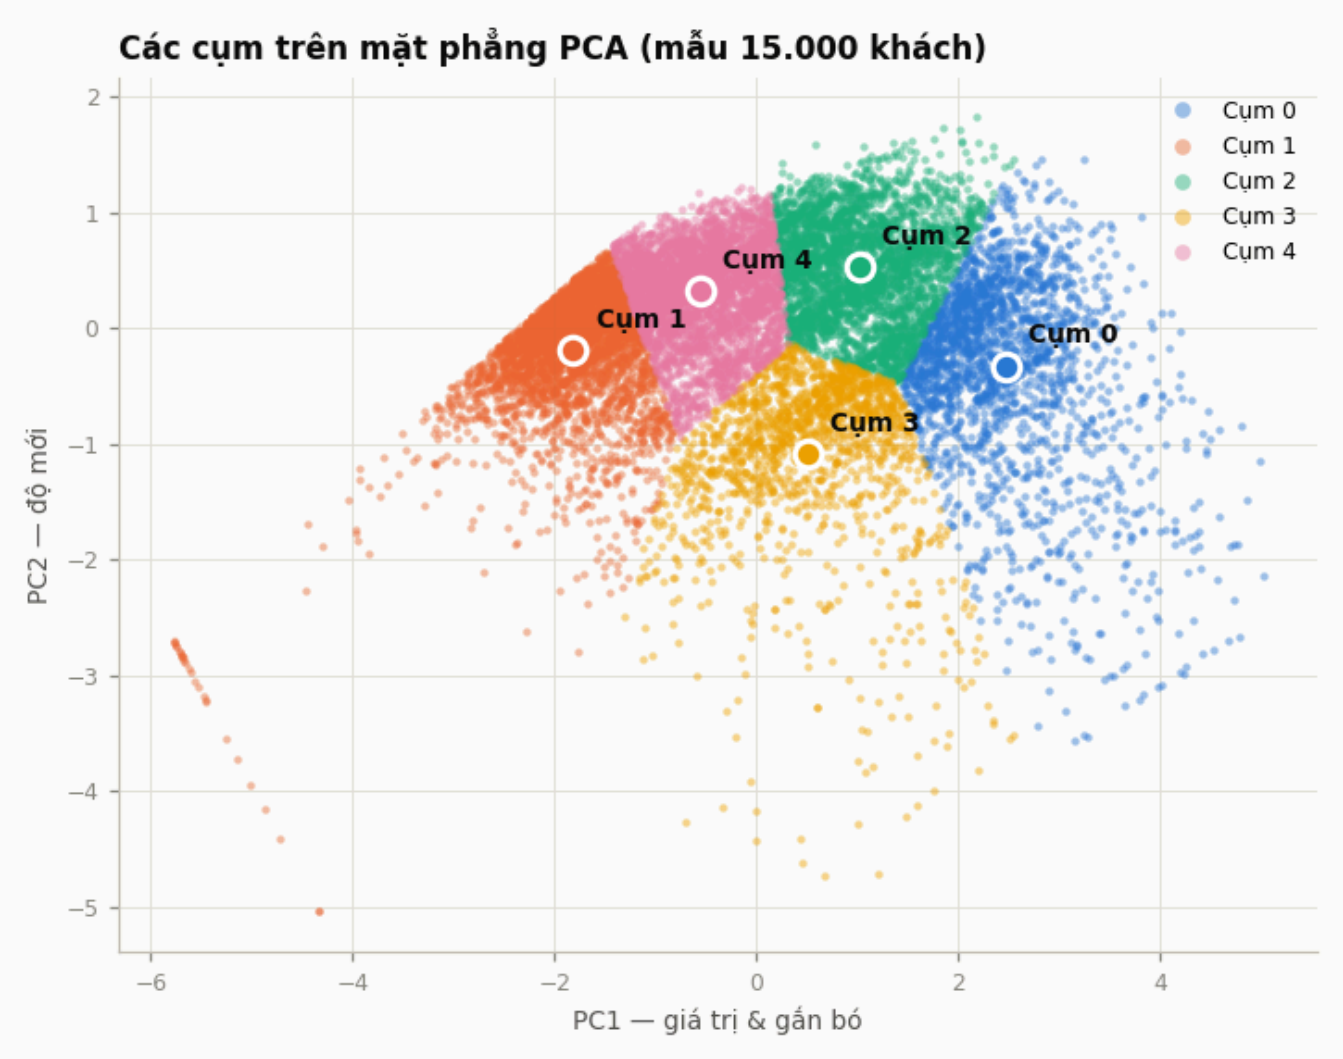
2,407 khách (2.0%) · chưa phát sinh doanh thu.

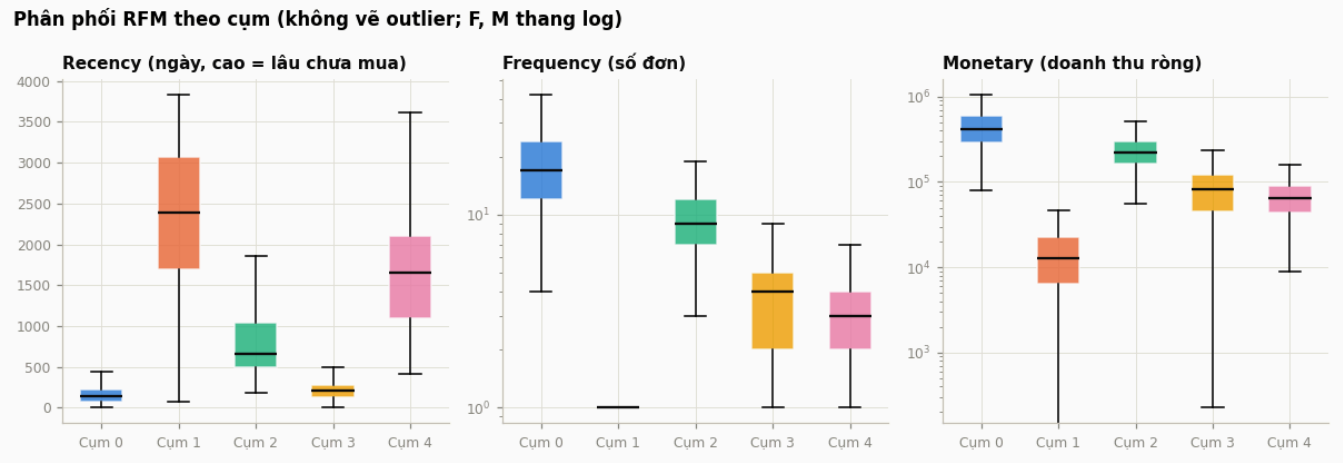
- **Chân dung nổi bật:** gần giống toàn bộ khách (lift trong khoảng 0,85–1,15).
- **Chi tiết:** số đơn thất bại 1 đơn: 2,255 khách (93.7%), 2 đơn: 140 khách (5.8%), 3 đơn: 12 khách (0.5%) · lý do cancelled: 2,123, abandoned: 258, abandoned+cancelled: 26.
- **Mục tiêu:** Gỡ rào cản để chuyển đổi đơn đầu tiên. **Hành động:** Tìm lý do hủy/bỏ dở (thanh toán, giá, giao hàng), retarget bằng đúng sản phẩm khách từng đặt; ưu tiên khách có ≥ 2 đơn thất bại (ý định mua rõ, rào cản lặp lại). **KPI:** Tỷ lệ chuyển đổi đơn đầu tiên.

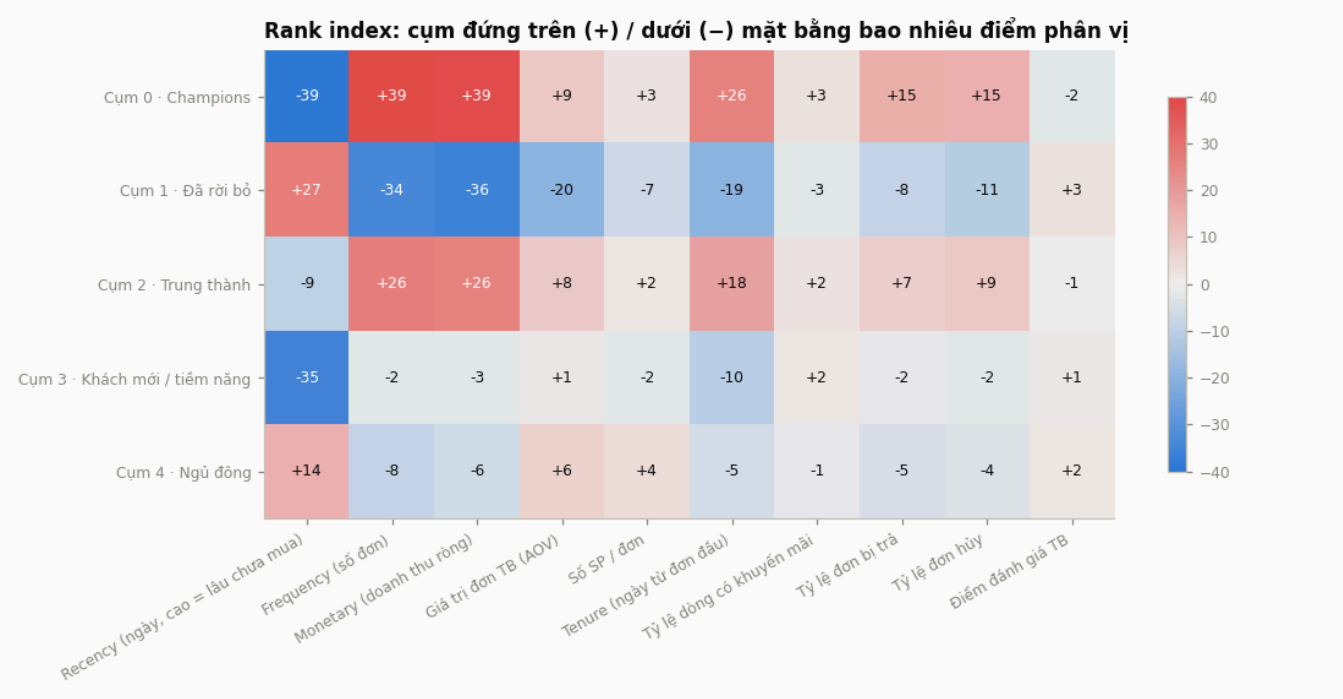
1. Tổng quan cụm K-Means (khách đã mua)

Cụm	Tên nhóm	Khách	% khách	% doanh thu	Recency (ngày)	Frequency	Monetary	AOV	Tỷ lệ trả	Dùng KM
0	Champions	12,384	14.1%	43.6%	149	17	421,487	23,888	6.1%	38.6%
1	Đã rời bỏ	22,412	25.5%	2.6%	2,391	1	12,788	10,487	7.8%	41.1%
2	Trung thành	19,103	21.7%	34.9%	659	9	219,127	23,764	5.9%	37.8%
3	Khách mới / tiềm năng	8,945	10.2%	5.7%	206	4	80,930	20,775	6.2%	39.5%
4	Ngủ đông	24,995	28.5%	13.1%	1,650	3	64,500	22,627	5.2%	36.0%
Tổng	—	87,839	100.0%	100.0%	1,033	4	81,552	21,267	6.3%	38.4%

Giá trị là **median** (tỷ lệ trả và dùng khuyến mãi là trung bình).







2. Biến mô tả nào thực sự khác biệt giữa các cụm?

Với hàng chục nghìn khách, p-value của Chi-square gần như luôn rất nhỏ, nên đánh giá bằng **Cramér's V** (độ lớn hiệu ứng): < 0,05 không đáng kể · 0,05–0,1 yếu · 0,1–0,3 trung bình · ≥ 0,3 mạnh. Biến có V không đáng kể **không nên** dùng để nhắm mục tiêu cụm.

Biến	Cramér's V	Mức độ	p-value
Danh mục ưa thích	0.245	trung bình	0
Thanh toán	0.185	trung bình	0
Thiết bị	0.143	trung bình	0
Nguồn đơn	0.128	trung bình	0
Vùng	0.113	trung bình	0
Kênh thu hút	0.008	không đáng kể	0.25
Giới tính	0.006	không đáng kể	0.65
Nhóm tuổi	0.005	không đáng kể	0.95

3. Chân dung từng cụm

Cụm 0 — Champions

12,384 khách (14.1%) · 43.6% doanh thu · median R = 149 ngày, F = 17 đơn, M = 421,487, AOV = 23,888.

- **Hành vi nổi bật:** Frequency (số đơn) cao hơn mặt bằng (+39 điểm phân vị); Monetary (doanh thu ròng) cao hơn mặt bằng (+39 điểm phân vị); Recency (ngày, cao = lâu chưa mua) thấp hơn mặt bằng (-39 điểm phân vị); Tenure (ngày từ đơn đầu) cao hơn mặt bằng (+26 điểm phân vị).
- **Chân dung nổi bật:** Vùng = West 28% (lift 1.73); Nguồn đơn = email_campaign 6% (lift 0.49); Thanh toán = credit_card 96% (lift 1.36); Nguồn đơn = organic_search 52% (lift 1.35); Danh mục ưa thích = Streetwear 96% (lift 1.21); Thiết bị = mobile 54% (lift 1.20).
- **Mục tiêu:** Giữ chân và tăng giá trị. **Hành động:** Chương trình VIP/early access, upsell sản phẩm premium, hạn chế giảm giá sâu. **KPI:** Retention, AOV.
- **Kênh tiếp cận và thứ tự ưu tiên:** xem mục 8 *Recommendation* của README phân cụm.

Cụm 1 — Đã rời bỏ

22,412 khách (25.5%) · 2.6% doanh thu · median R = 2,391 ngày, F = 1 đơn, M = 12,788, AOV = 10,487.

- **Hành vi nổi bật:** Monetary (doanh thu ròng) thấp hơn mặt bằng (-36 điểm phân vị); Frequency (số đơn) thấp hơn mặt bằng (-34 điểm phân vị); Recency (ngày, cao = lâu chưa mua) cao hơn mặt bằng (+27 điểm phân vị); Giá trị đơn TB (AOV) thấp hơn mặt bằng (-20 điểm phân vị).
- **Chân dung nổi bật:** Danh mục ưa thích = GenZ 6% (lift 2.93); Danh mục ưa thích = Outdoor 37% (lift 2.31); Thiết bị = tablet 13% (lift 2.17); Thanh toán = paypal 13% (lift 2.08); Nguồn đơn = referral 9% (lift 1.76); Thanh toán = bank_transfer 6% (lift 1.53).
- **Mục tiêu:** Tối ưu chi phí tiếp cận. **Hành động:** Chỉ dùng kênh chi phí gần 0 (email định kỳ); không đầu tư ưu đãi lớn. **KPI:** Chi phí/đơn kéo về.
- **Kênh tiếp cận và thứ tự ưu tiên:** xem mục 8 *Recommendation* của README phân cụm.

Cụm 2 — Trung thành

19,103 khách (21.7%) · 34.9% doanh thu · median R = 659 ngày, F = 9 đơn, M = 219,127, AOV = 23,764.

- **Hành vi nổi bật:** Frequency (số đơn) cao hơn mặt bằng (+26 điểm phân vị); Monetary (doanh thu ròng) cao hơn mặt bằng (+26 điểm phân vị); Tenure (ngày từ đơn đầu) cao hơn mặt bằng (+18 điểm phân vị); Recency (ngày, cao = lâu chưa mua) thấp hơn mặt bằng (-9 điểm phân vị).
- **Chân dung nổi bật:** Thanh toán = cod 5% (lift 0.52); Nguồn đơn = direct 6% (lift 0.63); Thanh toán = credit_card 88% (lift 1.25); Nguồn đơn = email_campaign 10% (lift 0.75); Danh mục ưa thích = Streetwear 95% (lift 1.19); Nguồn đơn = organic_search 46% (lift 1.19).
- **Mục tiêu:** Tăng tần suất mua. **Hành động:** Tích điểm theo bậc, cross-sell theo danh mục ưa thích, nhắc mua định kỳ. **KPI:** Frequency, doanh thu/khách.
- **Kênh tiếp cận và thứ tự ưu tiên:** xem mục 8 *Recommendation* của README phân cụm.

Cụm 3 — Khách mới / tiềm năng

8,945 khách (10.2%) · 5.7% doanh thu · median R = 206 ngày, F = 4 đơn, M = 80,930, AOV = 20,775.

- **Hành vi nổi bật:** Recency (ngày, cao = lâu chưa mua) thấp hơn mặt bằng (-35 điểm phân vị); Tenure (ngày từ đơn đầu) thấp hơn mặt bằng (-10 điểm phân vị).

- **Chân dung nổi bật:** Nguồn đơn = direct 12% (lift 1.33); Vùng = West 12% (lift 0.70); Thanh toán = apple_pay 12% (lift 1.29); Danh mục ưa thích = Outdoor 13% (lift 0.82); Nguồn đơn = email_campaign 15% (lift 1.17); Thanh toán = cod 12% (lift 1.17).
- **Mục tiêu:** Tạo thói quen mua lặp lại. **Hành động:** Voucher đơn kế tiếp trong 30 ngày, email onboarding, gợi ý sản phẩm bán chạy. **KPI:** Tỷ lệ mua lần tiếp theo.
- **Kênh tiếp cận và thứ tự ưu tiên:** xem mục 8 *Recommendation* của README phân cụm.

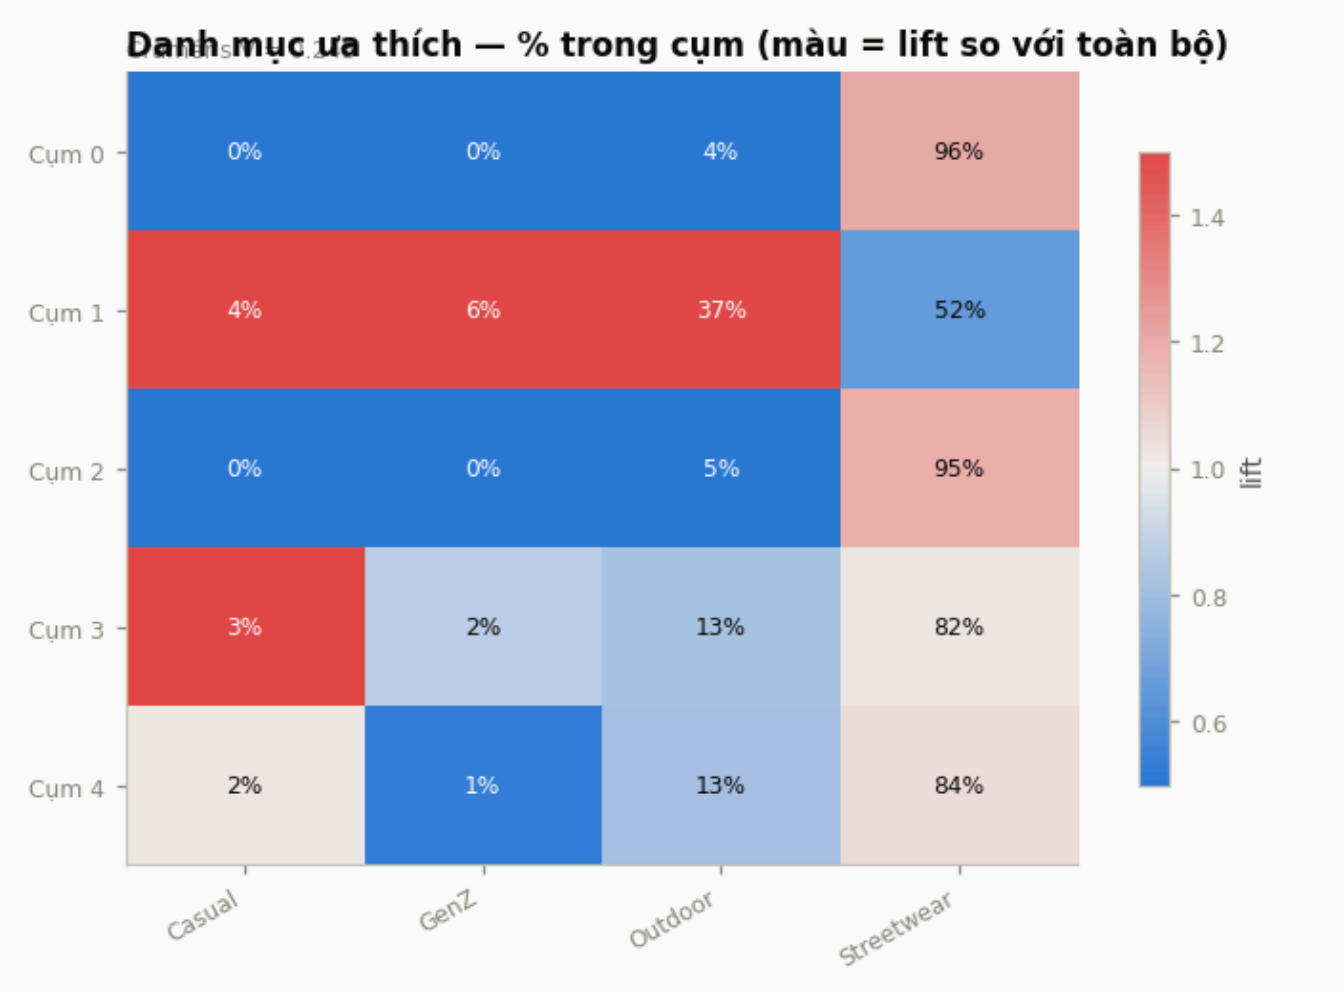
Cụm 4 — Ngủ đông

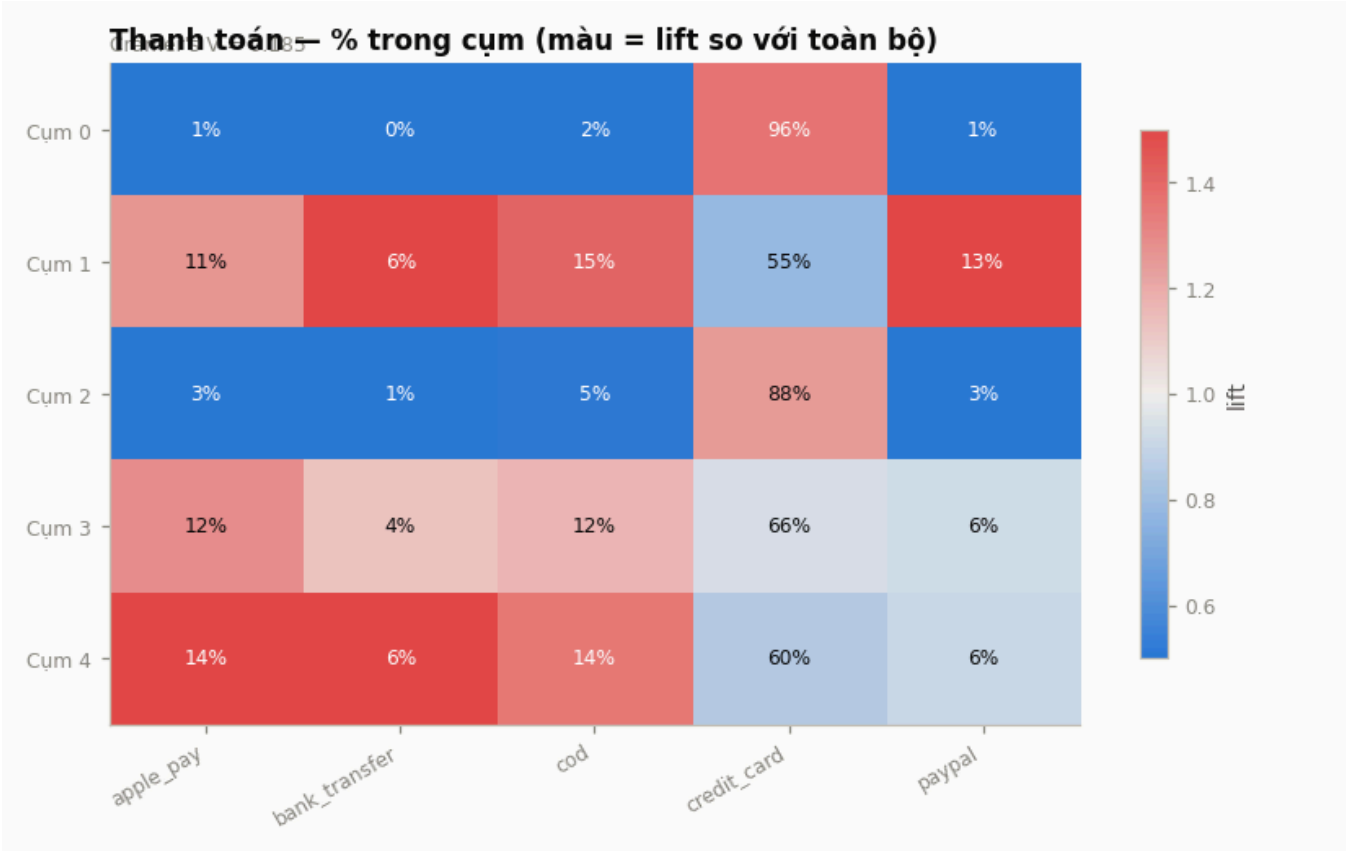
24,995 khách (28.5%) · 13.1% doanh thu · median R = 1,650 ngày, F = 3 đơn, M = 64,500, AOV = 22,627.

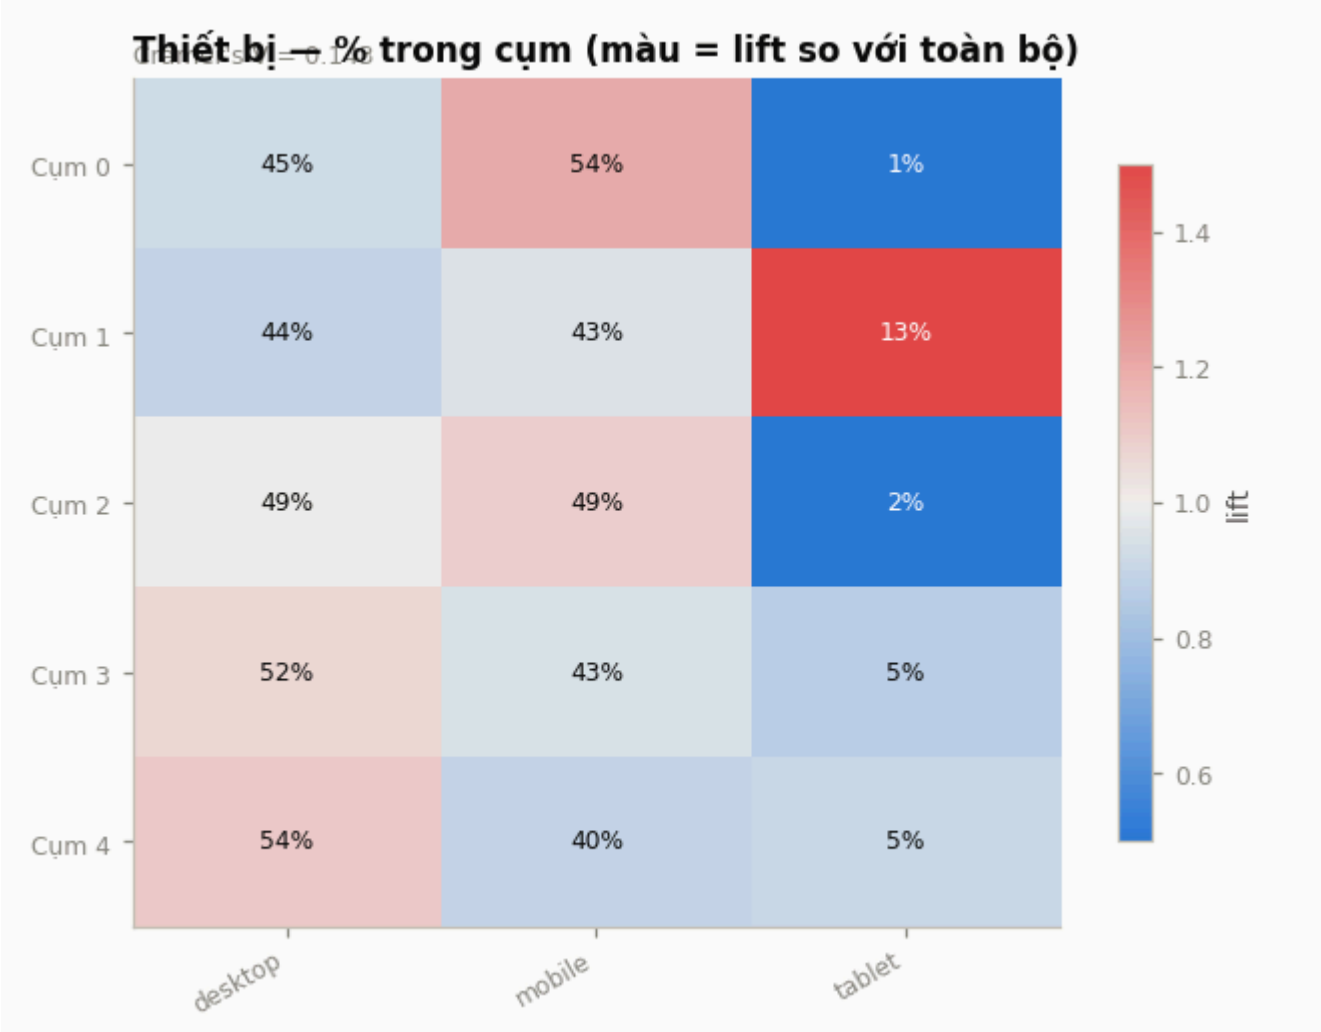
- **Hành vi nổi bật:** Recency (ngày, cao = lâu chưa mua) cao hơn mặt bằng (+14 điểm phân vị); Frequency (số đơn) thấp hơn mặt bằng (-8 điểm phân vị); Giá trị đơn TB (AOV) cao hơn mặt bằng (+6 điểm phân vị); Monetary (doanh thu ròng) thấp hơn mặt bằng (-6 điểm phân vị).
- **Chân dung nổi bật:** Thanh toán = apple_pay 14% (lift 1.60); Thanh toán = bank_transfer 6% (lift 1.58); Nguồn đơn = direct 14% (lift 1.53); Nguồn đơn = email_campaign 18% (lift 1.35); Thanh toán = cod 14% (lift 1.35); Nguồn đơn = social_media 10% (lift 0.74).
- **Mục tiêu:** Đánh thức với chi phí thấp. **Hành động:** Remarketing/email theo mùa, ưu đãi nhỏ; đo phản hồi trước khi đầu tư thêm. **KPI:** Reactivation rate.
- **Kênh tiếp cận và thứ tự ưu tiên:** xem mục 8 *Recommendation* của README phân cụm.

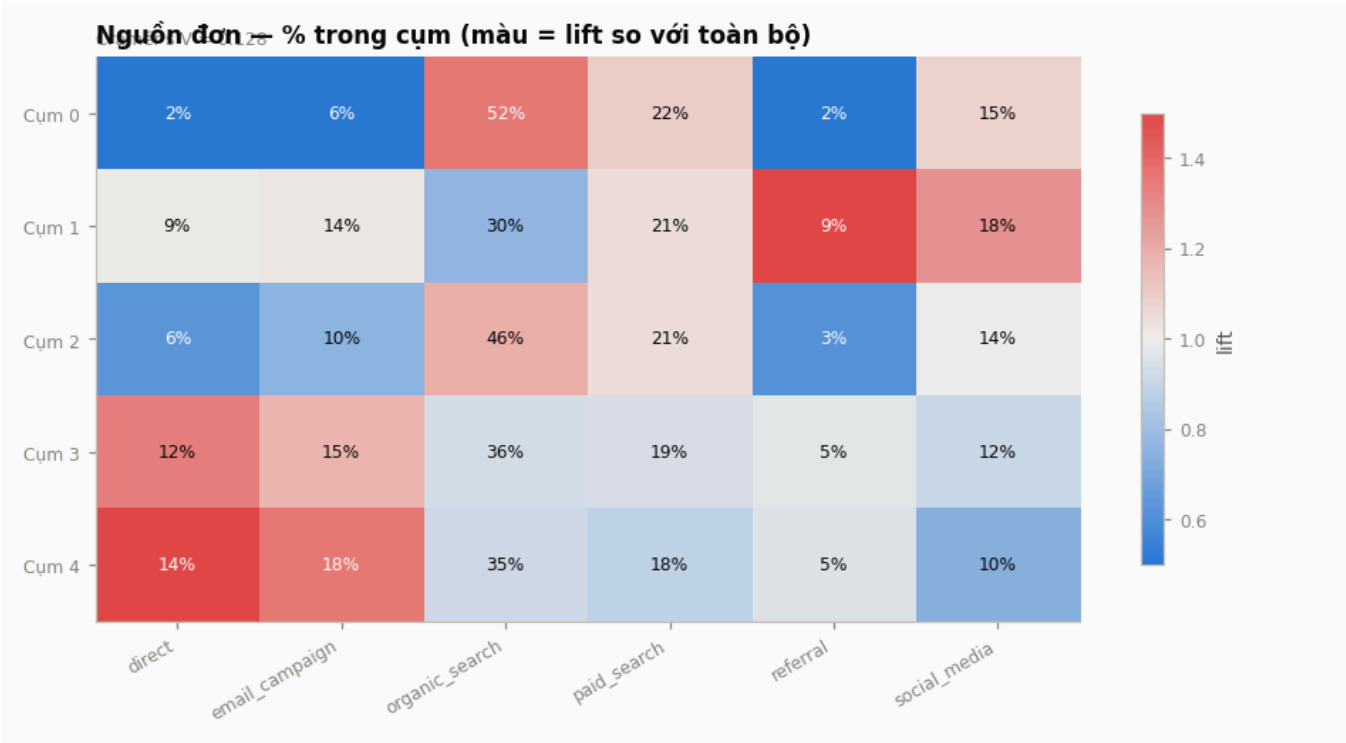
4. Chân dung chi tiết theo biến

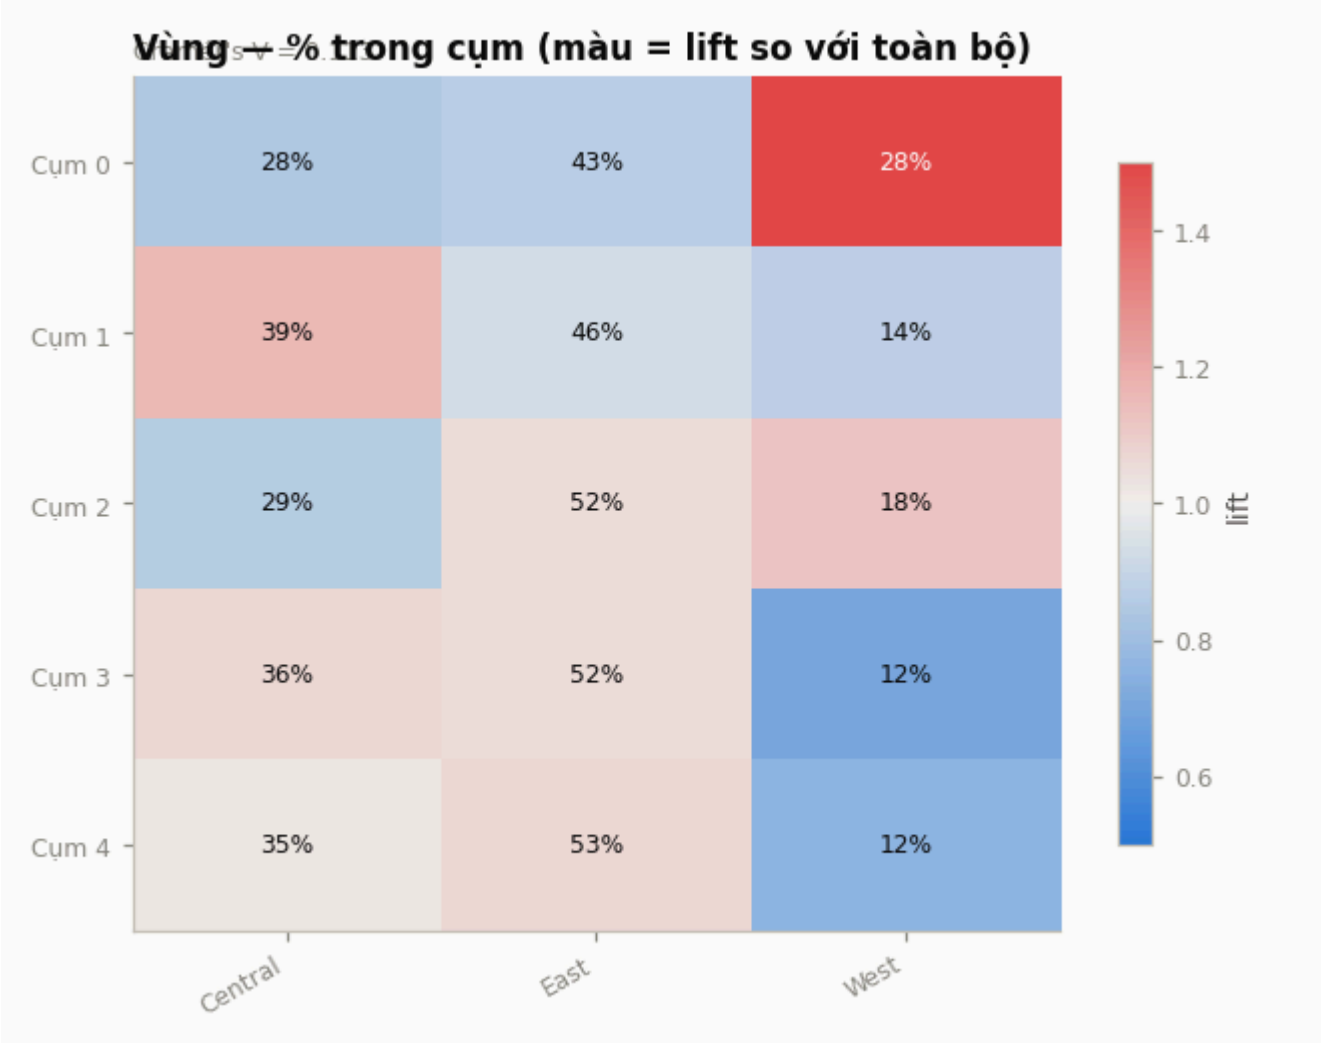
Ô hiển thị % khách trong cụm; màu đỏ = lift > 1 (nhiều hơn mặt bằng), xanh = lift < 1.

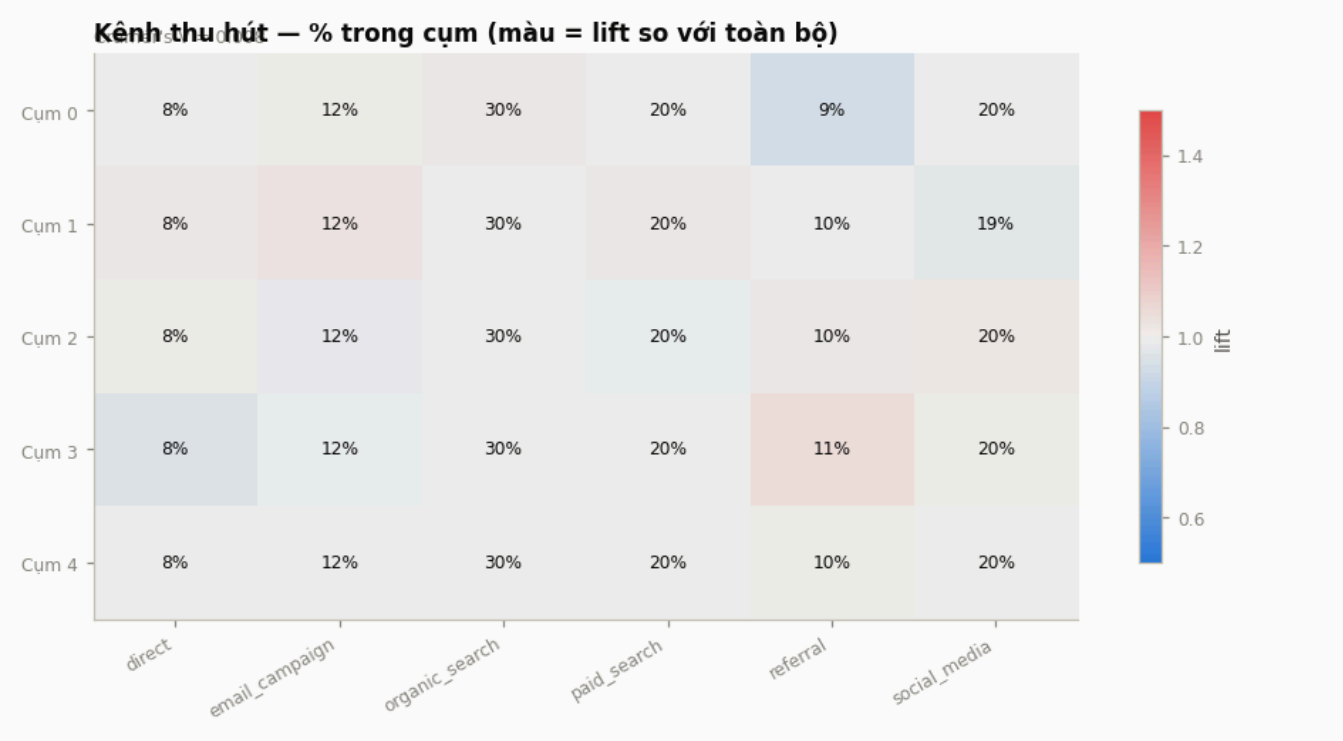


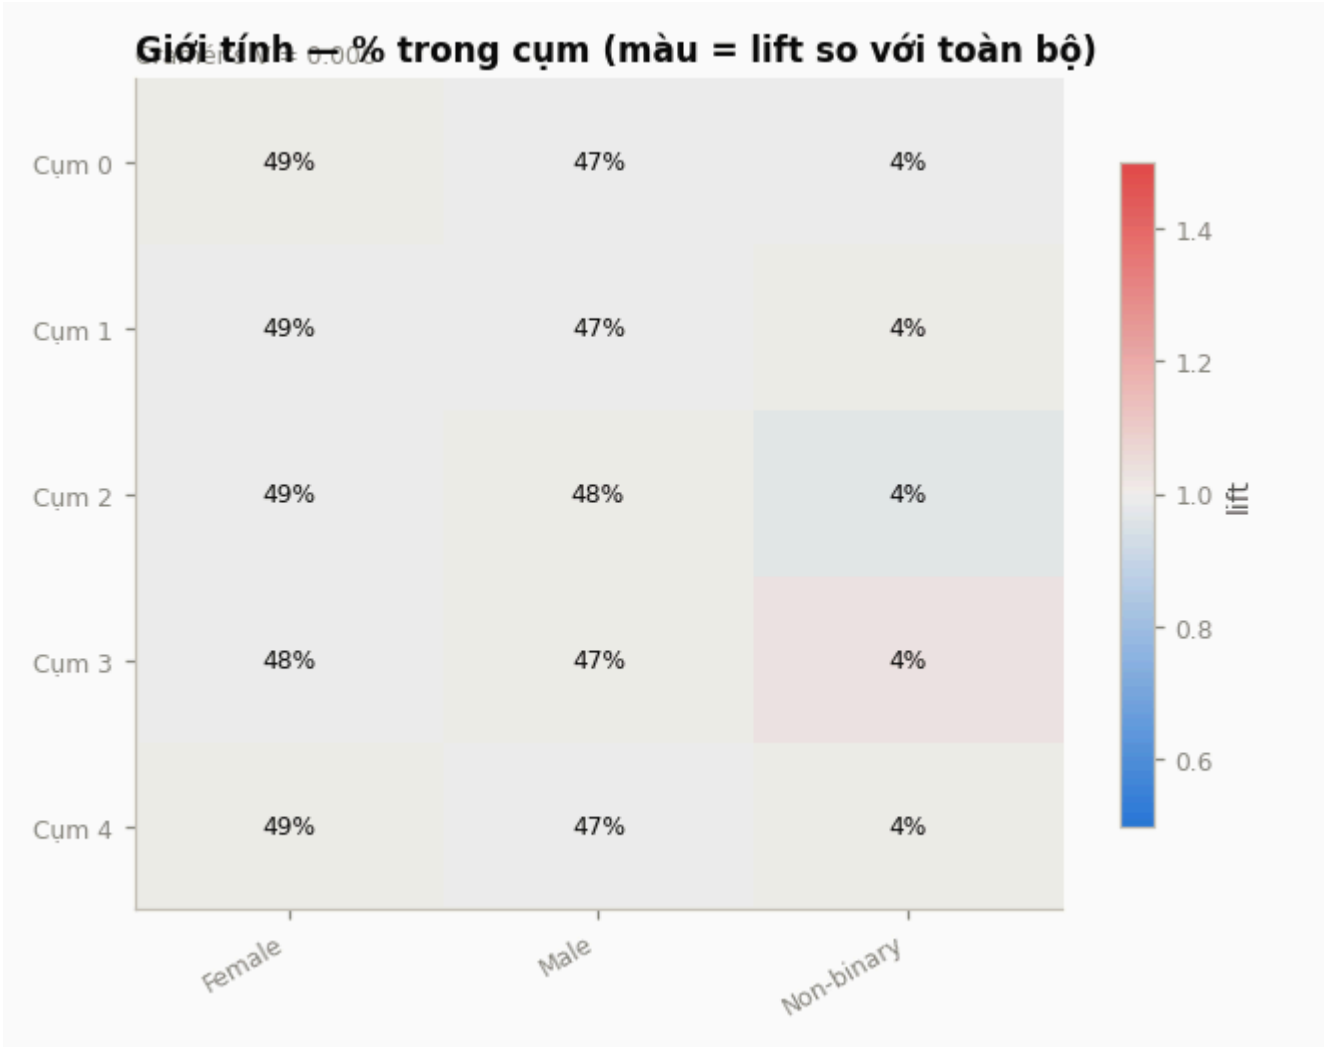

Thanh toán — % trong cụm (màu = lift so với toàn bộ)
Cụm 0
Cụm 1
Cụm 2
Cụm 3
Cụm 4
1%
0%
2%
96%
1%
11%
6%
15%
55%
13%
3%
1%
5%
88%
3%
12%
4%
12%
66%
6%
14%
6%
14%
60%
6%
apple_pay
bank_transfer
cod
credit_card
paypal
lift
1.4
1.2
1.0
0.8
0.6

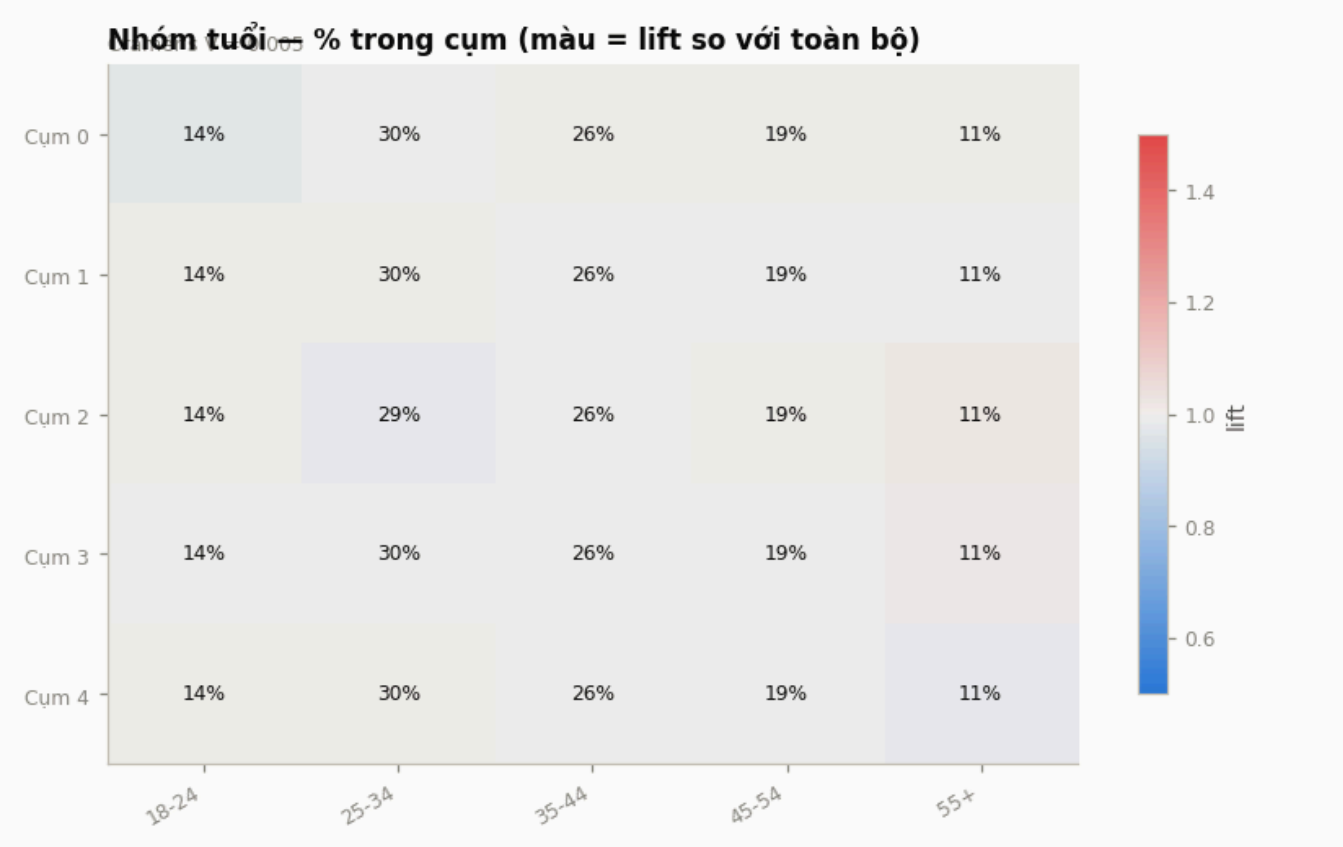

Thiết bị — % trong cụm (màu = lift so với toàn bộ)
Cụm 0
Cụm 1
Cụm 2
Cụm 3
Cụm 4
45%
54%
1%
44%
43%
13%
49%
49%
2%
52%
43%
5%
54%
40%
5%
desktop
mobile
tablet
lift
1.4
1.2
1.0
0.8
0.6


Nguồn đơn → % trong cụm (màu = lift so với toàn bộ)
Cụm 0
Cụm 1
Cụm 2
Cụm 3
Cụm 4
2%
6%
52%
22%
2%
15%
9%
14%
30%
21%
9%
18%
6%
10%
46%
21%
3%
14%
12%
15%
36%
19%
5%
12%
14%
18%
35%
18%
5%
10%
direct
email_campaign
organic_search
paid_search
referral
social_media
lift
1.4
1.2
1.0
0.8
0.6


Vùng → % trong cụm (màu = lift so với toàn bộ)
Cụm 0
Cụm 1
Cụm 2
Cụm 3
Cụm 4
28%
43%
28%
39%
46%
14%
29%
52%
18%
36%
52%
12%
35%
53%
12%
Central
East
West
lift
1.4
1.2
1.0
0.8
0.6


Kênh thu hút — % trong cụm (màu = lift so với toàn bộ)
Cụm 0
Cụm 1
Cụm 2
Cụm 3
Cụm 4
8%
12%
30%
20%
9%
20%
8%
12%
30%
20%
10%
19%
8%
12%
30%
20%
10%
20%
8%
12%
30%
20%
11%
20%
8%
12%
30%
20%
10%
20%
direct
email_campaign
organic_search
paid_search
referral
social_media
lift
1.4
1.2
1.0
0.8
0.6


Giới tính — % trong cụm (màu = lift so với toàn bộ)
Cụm 0
Cụm 1
Cụm 2
Cụm 3
Cụm 4
49%
47%
4%
49%
47%
4%
49%
48%
4%
48%
47%
4%
49%
47%
4%
Female
Male
Non-binary
lift
1.4
1.2
1.0
0.8
0.6


Nhóm tuổi — % trong cụm (màu = lift so với toàn bộ)
Cụm 0
Cụm 1
Cụm 2
Cụm 3
Cụm 4
14%
30%
26%
19%
11%
14%
30%
26%
19%
11%
14%
29%
26%
19%
11%
14%
30%
26%
19%
11%
14%
30%
26%
19%
11%
18-24
25-34
35-44
45-54
55+
lift
1.4
1.2
1.0
0.8
0.6