VIN DATATHON 2026

Báo cáo Dự báo doanh thu

Dự báo Revenue và COGS theo ngày, 01/01/2023 – 01/07/2024: EDA chuỗi thời gian, mô hình, ensemble và SHAP

Ngày tạo: 16/10/2026
Nguồn nội dung:

- forecasting/README.md
- reports/markdown/forecasting_eda.md
- reports/markdown/forecasting_models.md

Revenue Forecasting

Dự báo `Revenue` và `COGS` theo ngày cho **548 ngày** từ 01/01/2023 đến 01/07/2024, dựa trên lịch sử bán hàng 04/07/2012 – 31/12/2022. Đây là Phần 3 của đề thi (20 điểm), và là Phần 4 trong cấu trúc dự án.

Kết quả chính (mọi số liệu là kết quả chạy thật, `random_state = 42`):

- Mô hình cuối là **ensemble 3 tầng**: 0.3 × Ridge + 0.7 × LightGBM (4 mô hình chuyên biệt theo quý), nhân hệ số calibration mức.
- Trên năm 2022 (fold A), ensemble + calibration đạt **MAE 544K VND/ngày, R^2 0.807** cho Revenue, giảm **37% sai số** so với baseline seasonal naive (MAE 864K, R^2 0.445).
- Dự báo Revenue **2023: 1.18 tỷ** (2022 thực tế: 1.17 tỷ); **6 tháng đầu 2024: 0.71 tỷ** (cùng kỳ 2022: 0.69 tỷ).
- SHAP: **mùa vụ năm** (58.7%) và **mức theo giai đoạn** (25.4%) giải thích phần lớn dự báo; ngày cuối tháng là pattern ngắn hạn mạnh nhất.

Báo cáo chi tiết, tự sinh từ code:

- `reports/markdown/forecasting_eda.md` : mục 1–3, phát biểu bài toán và phân tích chuỗi thời gian.
- `reports/markdown/forecasting_models.md` : mục 4–10, đặc trưng, validation, mô hình, ensemble, kết quả, SHAP và dự báo.
- PDF: `reports/04_Forecasting_report.pdf` ghép README này và hai file trên.

Flow tổng quan

```
sales.csv → 1. Hiểu đề → 2. EDA chuỗi → 3. Đặc trưng → 4. Validation → 5. Mô hình → 6. Ensemble → 7
            & ràng buộc     thời gian      từ lịch         theo thời gian   + baseline     3 tầng
```

Bước	Làm gì	Ý nghĩa
1. Hiểu đề và ràng buộc	Xác định horizon 548 ngày, chỉ số chấm, ba điều kiện loại bài	Quyết định ngay từ đầu: không dùng lag, không dùng dữ liệu ngoài, phải tái lập được
2. EDA chuỗi thời gian	Tách giai đoạn, kiểm tra mùa vụ, Tết, ngày trong tháng, chẵn/lẻ, margin theo quý	Mỗi pattern tìm được trở thành một nhóm đặc trưng hoặc một quyết định thiết kế
3. Đặc trưng chỉ từ lịch	81 đặc trưng tính từ ngày tháng và lịch khuyến mãi suy từ `promotions.csv`	Dựng được đặc trưng cho cả 2023–2024 mà không cần doanh thu tương lai, nên không rò rỉ
4. Validation theo thời gian	3 fold A/B/C, baseline seasonal naive, thêm MAE hình dạng	Đo đúng tình huống thật (dự báo năm sau từ quá khứ) và tách lỗi *hình dạng* khỏi lỗi *mức*
5. Mô hình gốc	Ridge, LightGBM high_era, 4 Q-specialist, Prophet	Ba họ mô hình khác bản chất, mạnh ở những chỗ khác nhau
6. Ensemble 3 tầng	Chọn α và trọng số bằng lưới trên CV	Gộp điểm mạnh, để dữ liệu tự quyết định mô hình nào đáng tin
7. Calibration mức	c = tổng thực tế 2022 ÷ tổng dự báo 2022	Mô hình học hình dạng từ 2014–2018 nhưng mức doanh thu đã khác, nên cần điều chỉnh mức riêng
8. Giải thích (SHAP)	TreeSHAP theo nhóm đặc trưng và tác động cục bộ	Nói được bằng ngôn ngữ kinh doanh *vì sao* dự báo cao hay thấp
9. Submission	`submission.csv` 548 dòng, kiểm tra định dạng	Đáp ứng đúng yêu cầu nộp bài, chạy lại ra đúng file

Bước 1. Hiểu đề và ràng buộc

Bài toán: với mỗi ngày từ 01/01/2023 đến 01/07/2024, dự báo `Revenue` và `COGS`. Chấm bằng MAE, RMSE, R^2 trên Kaggle leaderboard.

Thang điểm (20 điểm): hiệu suất mô hình 12 điểm; báo cáo kỹ thuật 8 điểm (pipeline rõ ràng, cross-validation đúng chiều thời gian, kiểm soát leakage, giải thích mô hình, tuân thủ ràng buộc).

Ba điều kiện loại toàn bộ Phần 3:

1. Dùng `Revenue` / `COGS` của tập test làm đặc trưng.
2. Dùng dữ liệu ngoài bộ dữ liệu được cung cấp.
3. Không đính kèm mã nguồn, hoặc kết quả không tái lập được.

Ý nghĩa: ba ràng buộc này định hình cả pipeline.

- Horizon 18 tháng nên không có doanh thu hôm qua hay tuần trước: **không dùng được đặc trưng lag**.
- Mọi bảng khác (orders, web_traffic, inventory…) dừng ở 31/12/2022: **không dùng làm đặc trưng cho ngày cần dự báo**, chỉ dùng để rút ra quy luật lặp lại (lịch khuyến mãi).
- Mọi mô hình đặt `random_state = 42`, LightGBM chạy `deterministic=True`.

Lưu ý về dữ liệu: `sales.csv` có 3.833 ngày liên tục, không thiếu, không trùng. Khi đối soát với dữ liệu giao dịch, `Revenue` = Σ(`quantity` × `unit_price`) của mọi đơn trong ngày, kể cả đơn hủy, chưa trừ giảm giá. Định nghĩa này khác doanh thu trong dashboard và phân nhóm khách hàng, nên phần dự báo chỉ dùng `sales.csv` làm mục tiêu.

Bước 2. EDA chuỗi thời gian

Script: `01_time_series_eda.py`. Kết quả đầy đủ: `forecasting_eda.md`.

Quan sát (từ dữ liệu)	Số liệu	Quyết định thiết kế
Chuỗi chia 4 giai đoạn khác mức	Trung bình ngày: 4.39 triệu (2012–13), 5.27 (2014–18), 3.12 (2019), 2.98 (2020–22); thấp hơn đỉnh 43.5%	Trọng số mẫu ưu tiên 2014–2018 + tầng calibration mức
Mùa vụ năm cùng hình dạng, khác mức	Thấp tháng 1–2, cao nhất tháng 4–6, giảm về cuối năm	Fourier năm k = 1..5
Cuối tháng cao gấp đôi giữa tháng	3 ngày cuối tháng 7.17 triệu, 3 ngày đầu 5.12, giữa tháng 3.58	`is_last1..3`, `is_first1..3`, `days_to_eom`
Tết dời ngày dương lịch mỗi năm	Trước Tết 2.70 triệu, quanh mùng 1 3.30, sau Tết 3.91	`tet_days_diff` và các cờ cửa sổ Tết
Chu kỳ năm chẵn / lẻ	Tháng 8: năm chẵn 5.50 triệu, năm lẻ 3.25	`is_odd_year`
Margin Q3 dao động theo năm	COGS/Revenue Q3: năm lẻ 1.04 (bán lỗ), năm chẵn 0.86; Q1, Q2, Q4 ổn định 0.82–0.91	Mô hình riêng cho COGS + 4 mô hình chuyên biệt theo quý

Ý nghĩa: EDA không chỉ để mô tả. Mỗi dòng trong bảng trên được nối thẳng với một nhóm đặc trưng hoặc một quyết định mô hình, nên mọi lựa chọn ở các bước sau đều có lý do từ dữ liệu.

Bước 3. Đặc trưng chỉ từ lịch

File: `features.py`. Tổng cộng **81 đặc trưng**, chia 8 nhóm: lịch cơ bản, đầu/cuối tháng, xu hướng + giai đoạn, Fourier, lễ dương lịch, Tết, khuyến mãi, năm chẵn/lẻ.

Lịch khuyến mãi suy từ `promotions.csv`: mỗi chiến dịch lặp lại cùng ngày bắt đầu và thời lượng mỗi năm. Spring Sale (18/03), Mid-Year Sale (23/06), Fall Launch (30/08), Year-End Sale (18/11) chạy hằng năm; Urban Blowout (30/07) và Rural Special (30/01) **chỉ chạy năm lẻ**. Theo quy luật này, 2023 có cả hai, 2024 thì không.

Ý nghĩa:

- Vì đặc trưng chỉ phụ thuộc ngày tháng, ma trận đặc trưng cho 2023–2024 dựng được ngay, **không cần bất kỳ giá trị nào của tập test**. Đây là cách kiểm soát leakage từ gốc.
- Ngày Tết Âm lịch và ngày lễ là **kiến thức lịch**, không phải bộ dữ liệu bên ngoài; danh sách nằm trong `config.py` để kiểm tra được.
- Lịch khuyến mãi là quy luật rút ra từ dữ liệu được cung cấp, không phải dữ liệu 2023–2024.

Bước 4. Validation theo thời gian

Fold	Train	Validate	Vai trò
A (chính)	≤ 2021-12	2022	Gần test nhất; dùng để ước lượng hệ số calibration
B (ổn định)	≤ 2020-12	2021	Cải tiến có ổn định qua năm không
C (horizon)	≤ 2021-06	2021-07 → 2022-06	Cửa sổ 12 tháng liên tục, cắt ngang năm

- **Baseline seasonal naive:** doanh thu cùng thứ trong tuần của năm trước (lag 364 ngày). Mô hình nào không thắng baseline này thì không có giá trị.
- **Hai thước đo:** MAE/RMSE/R^2 thông thường, và **MAE hình dạng**: đưa dự báo về đúng tổng của tập validate rồi mới tính MAE.

Ý nghĩa:

- Không xáo trộn dữ liệu: mỗi fold chỉ học từ quá khứ và dự báo tương lai, giống hệt tình huống thật.
- MAE hình dạng tách hai loại lỗi. Lỗi *hình dạng* (đỉnh, đáy, mùa vụ sai chỗ) do mô hình xử lý; lỗi *mức* (cả năm cao hay thấp hơn) do tầng calibration xử lý. Tách ra thì mỗi tầng được tối ưu cho đúng việc của nó.

Bước 5. Mô hình gốc

Script: `02_train_forecast.py`. Mọi mô hình train trên log(target), riêng cho Revenue và COGS.

Mô hình	Cách làm	Vì sao có mặt
M1 Ridge + Fourier	Tuyến tính trên đặc trưng chuẩn hóa, α = 3	Ổn định, ít overfit, làm *anchor*
M2 LightGBM high_era	Trọng số 1.0 cho 2014–2018, 0.01 cho phần còn lại; early stopping trên 180 ngày cuối rồi train lại toàn bộ	Học tương tác phi tuyến (cuối tháng × mùa vụ) từ vùng dữ liệu có mùa vụ rõ nhất
M2q 4 Q-specialist	Như M2, nhân trọng số ×2 cho quý phụ trách; mỗi ngày dùng mô hình đúng quý	Q3 có margin khác hẳn các quý khác, một mô hình chung dễ bị kéo về trung bình
M3 Prophet + promos	Học từ 2020 (tối thiểu 2 năm gần nhất), mùa vụ multiplicative, regressor là cửa sổ khuyến mãi	Họ mô hình khác bản chất, bám sát giai đoạn gần nhất

Kết quả CV, Revenue, trung bình 3 fold:

Mô hình	MAE	R^2	MAE hình dạng
Seasonal naive	840,592	0.450	841,854

Mô hình	MAE	R^2	MAE hình dạng
M1 Ridge + Fourier	644,597	0.676	614,467
M3 Prophet + promos	965,129	0.344	859,008
M2 LightGBM high_era	558,011	0.785	557,283
M2q 4 Q-specialists	554,011	0.797	548,801
Ensemble (chưa calibration)	**545,430**	**0.799**	**529,566**

Ý nghĩa: LightGBM thắng baseline ở mọi fold, Q-specialist nhỉnh hơn bản gốc. Prophet **thua cả baseline**: chỉ có 2–3 năm dữ liệu gần nhất nên mùa vụ năm học được kém ổn định. Kết quả này được giữ nguyên trong báo cáo thay vì bỏ đi, vì nó giải thích tại sao bước ensemble loại Prophet.

Bước 6. Ensemble 3 tầng

Tầng	Công thức	Tham số chọn trên CV
1. Họ LightGBM	LGB_blend = (1 − α)·M2 + α·M2q	α = 1.0
2. Ba họ mô hình	raw = w_1·Ridge + w_3·Prophet + w_2·LGB_blend	w_1 = 0.3, w_3 = 0, w_2 = 0.7
3. Calibration mức	final = c × raw	xem bước 7

α và trọng số được chọn bằng lưới (bước 0.1 cho α, 0.05 cho trọng số) để tối thiểu MAE hình dạng trung bình trên 3 fold × 2 target.

Ý nghĩa:

- Dữ liệu tự chọn: α = 1 nghĩa là 4 Q-specialist tốt hơn mô hình chung; Prophet nhận trọng số 0.
- Ridge vẫn giữ 30% dù đơn lẻ kém LightGBM, vì sai số của hai mô hình chỉ tương quan 0.70: Ridge bù được những chỗ mô hình cây đoán sai. Nhờ vậy ensemble giảm MAE hình dạng 3.5% so với mô hình đơn tốt nhất (529,566 so với 548,801).

Bước 7. Calibration mức

c = tổng Revenue thực tế 2022 ÷ tổng dự báo 2022 của mô hình train đến hết 2021 (fold A). Kết quả: $\mathbf{c_{Revenue} = 1.080}$, $\mathbf{c_{COGS} = 1.097}$. Hệ số này nhân vào dự báo 2023–2024 của mô hình train đến hết 2022.

Đánh giá trung thực: để kiểm tra cách làm này, lấy hệ số ước lượng từ fold B (năm 2021, $c_{Revenue}$ = 1.037) áp lên dự báo 2022:

Target	Mô hình	MAE	RMSE	R^2
Revenue	Seasonal naive	863,664	1,247,432	0.445
Revenue	Ensemble chưa calibration	566,967	762,150	0.793
Revenue	**Ensemble + calibration**	**544,238**	**736,157**	**0.807**
COGS	Seasonal naive	714,915	1,035,433	0.496
COGS	Ensemble chưa calibration	513,189	685,735	0.779
COGS	**Ensemble + calibration**	**478,695**	**635,536**	**0.810**

Ý nghĩa:

- Trên cả 3 fold, ensemble chưa calibration dự báo tổng thấp hơn thực tế 4–7%: mô hình học đúng *hình dạng* nhưng lệch *mức*. Calibration sửa đúng phần này mà không làm thay đổi hình dạng.
- **Khác tài liệu tham chiếu:** tài liệu chỉnh c trực tiếp trên leaderboard. Ở đây c ước lượng hoàn toàn từ dữ liệu train, nên không có thông tin nào từ tập test lọt vào mô hình.

Bước 8. Giải thích mô hình (SHAP)

TreeSHAP tính qua `predict(pred_contrib=True)` của LightGBM, chính xác cho mô hình cây (sai số cộng tính 4.6e-14). Đặc trưng được gom thành nhóm nghiệp vụ, vì các đặc trưng Fourier tương quan nhau nên xếp hạng từng đặc trưng đơn lẻ không ổn định.

Nhóm	Revenue	COGS	Đọc theo ngôn ngữ kinh doanh
Mùa vụ năm	58.7%	58.5%	Tháng nào trong năm quyết định phần lớn doanh thu: cao điểm tháng 4–6
Giai đoạn & xu hướng	25.4%	24.4%	Mức doanh thu sau 2019 thấp hơn hẳn trước đó
Đầu / cuối tháng	6.3%	7.3%	Khách mua dồn vào những ngày cuối tháng
Thứ trong tuần	6.0%	7.3%	Ngày thường cao hơn cuối tuần
Khuyến mãi	2.6%	1.6%	Khuyến mãi không phải động lực chính của doanh thu
Tết, năm chẵn/lẻ, lễ	< 1%	< 1%	Tác động hẹp, chỉ ở vài ngày trong năm

Tác động cục bộ: ngày cuối tháng được dự báo cao hơn giữa tháng **72.6%**, trong đó riêng nhóm đặc trưng đầu/cuối tháng đóng góp +29.1%. Với Tết và tháng 8 năm chẵn/lẻ, chênh lệch dự báo lớn (−43.5% và +39.7%) nhưng đến từ các đặc trưng khác; riêng cờ Tết và cờ năm lẻ chỉ đóng góp khoảng 1%.

Ý nghĩa: global importance là trung bình trên cả 548 ngày, nên pattern hiếm như Tết có điểm thấp dù tác động tại chỗ rõ. Đọc cả global lẫn cục bộ mới thấy đầy đủ mô hình dựa vào đâu.

Bước 9. Submission

File `submission.csv` : 548 dòng `Date,Revenue,COGS`, theo thứ tự ngày từ 2023-01-01 đến 2024-07-01.

Checklist:

- [x] Đúng 3 cột `Date,Revenue,COGS` .
- [x] 548 dòng, không có giá trị âm hoặc NaN (script tự `assert`).
- [x] Không dùng `Revenue` / `COGS` của tập test làm đặc trưng: mọi đặc trưng tính từ ngày tháng.
- [x] Không dùng dữ liệu ngoài: lịch khuyến mãi suy từ `promotions.csv` ; Tết và ngày lễ là kiến thức lịch.
- [x] Tái lập được: `random_state = 42` , LightGBM `deterministic=True` .
- [ ] Đối chiếu thứ tự dòng với `sample_submission.csv` trước khi nộp: file này chưa có trong `data/raw/` , nên hiện tại các dòng được xếp theo thứ tự ngày.

Dự báo và ý nghĩa kinh doanh

	Thực tế 2022	Dự báo 2023	Thực tế 6 tháng đầu 2022	Dự báo 6 tháng đầu 2024
Revenue	1.17 tỷ	1.18 tỷ	0.69 tỷ	0.71 tỷ
COGS	1.02 tỷ	1.08 tỷ	0.59 tỷ	0.61 tỷ

- **Doanh thu đi ngang, chưa hồi phục:** 2023 gần bằng 2022 (+1.2%), nửa đầu 2024 nhỉnh hơn cùng kỳ 2022 (+2.9%). Không có dấu hiệu quay lại mức 2014–2018.
- **Tháng 4–6 chiếm 37.9% doanh thu 2023:** tồn kho, nhân sự và vận chuyển cần sẵn sàng từ tháng 3.
- **Q3 2023 dự báo bán lỗ:** COGS/Revenue 1.05 (Q3 2022 là 0.89), trùng thời điểm Urban Blowout giảm 50% chỉ chạy năm lẻ. Nên xem lại mức giảm của chiến dịch này trước khi chạy năm 2023.
- **Cuối tháng là cao điểm ngắn hạn:** dự báo 3 ngày cuối tháng trung bình 5.55 triệu/ngày, gần gấp đôi giữa tháng (2.92 triệu). Đây là thời điểm hợp lý để đẩy chiến dịch và bảo đảm hàng.
- **Độ tin cậy:** sai số trên năm 2022 khoảng 0.54 triệu/ngày, tương đương 17% doanh thu trung bình ngày năm 2022. Dự báo dùng tốt cho kế hoạch theo tháng/quý; theo từng ngày chỉ nên coi là định hướng.

Hạn chế

- Calibration giả định độ lệch mức của 2023–2024 giống năm 2022. Nếu thị trường thay đổi mạnh, hệ số này cần cập nhật.
- Prophet chưa đóng góp vào ensemble; có thể thử lại với cửa sổ dài hơn hoặc mùa vụ cộng tính.
- Chưa có điểm leaderboard và chưa đối chiếu `sample_submission.csv`.

Cấu trúc và cách chạy

```
forecasting/
├── README.md                # File này: các bước, ý nghĩa, kết quả
├── config.py                # Đường dẫn, seed, fold, ngày Tết và lễ, style biểu đồ
├── features.py              # Đọc sales.csv, suy lịch khuyến mãi, tạo 81 đặc trưng
├── 01_time_series_eda.py    # EDA → plots/eda_*.png, eda_stats.json, forecasting_eda.md
├── 02_train_forecast.py     # CV, ensemble, calibration, SHAP → submission.csv, forecasting_models.md
└── submission.csv           # File nộp, 548 dòng
```

```
python forecasting/01_time_series_eda.py
python forecasting/02_train_forecast.py      # khoảng 10 phút (3 fold × 2 target + train cuối)
python reports/build_reports.py              # dựng reports/04_Forecasting_report.pdf
```

Kết quả trung gian nằm ở `data/processed/forecasting/` (không commit): `cv_metrics.csv`, `forecast_summary.json`, `eda_stats.json`, `plots/`.

Nhật ký cập nhật

Ngày	Thay đổi
2026-10-15	Tạo folder và README mô tả flow, yêu cầu đề, lưu ý leakage và quy luật lịch khuyến mãi
2026-10-16	Triển khai pipeline: EDA chuỗi thời gian, 81 đặc trưng lịch, 3 fold, Ridge / LightGBM / Q-specialist / Prophet, ensemble 3 tầng, calibration, SHAP, `submission.csv`

Dự báo doanh thu — Phân tích chuỗi thời gian

Tạo tự động bởi `forecasting/01_time_series_eda.py` từ `data/raw/sales.csv`. Mọi con số dưới đây tính trực tiếp từ dữ liệu.

1. Giới thiệu

Phần 3 của VinDatathon 2026 Round 1: từ doanh thu hằng ngày đến hết 2022, dự báo **Revenue** và **COGS** cho **548 ngày** kế tiếp (01/01/2023 – 01/07/2024). Phần 2 trả lời *điều gì đã xảy ra*; phần này dự báo *điều gì sẽ xảy ra* và dùng lại các insight của Phần 2 (doanh thu giảm sau 2016, mùa vụ, chiến dịch khuyến mãi) làm giả định thiết kế.

Pipeline: phân tích dữ liệu → đặc trưng chỉ từ lịch → ba mô hình gốc (Ridge, LightGBM, Prophet) và bốn mô hình chuyên biệt theo quý → ensemble phân tầng → calibration mức → giải thích bằng SHAP.

2. Phát biểu bài toán

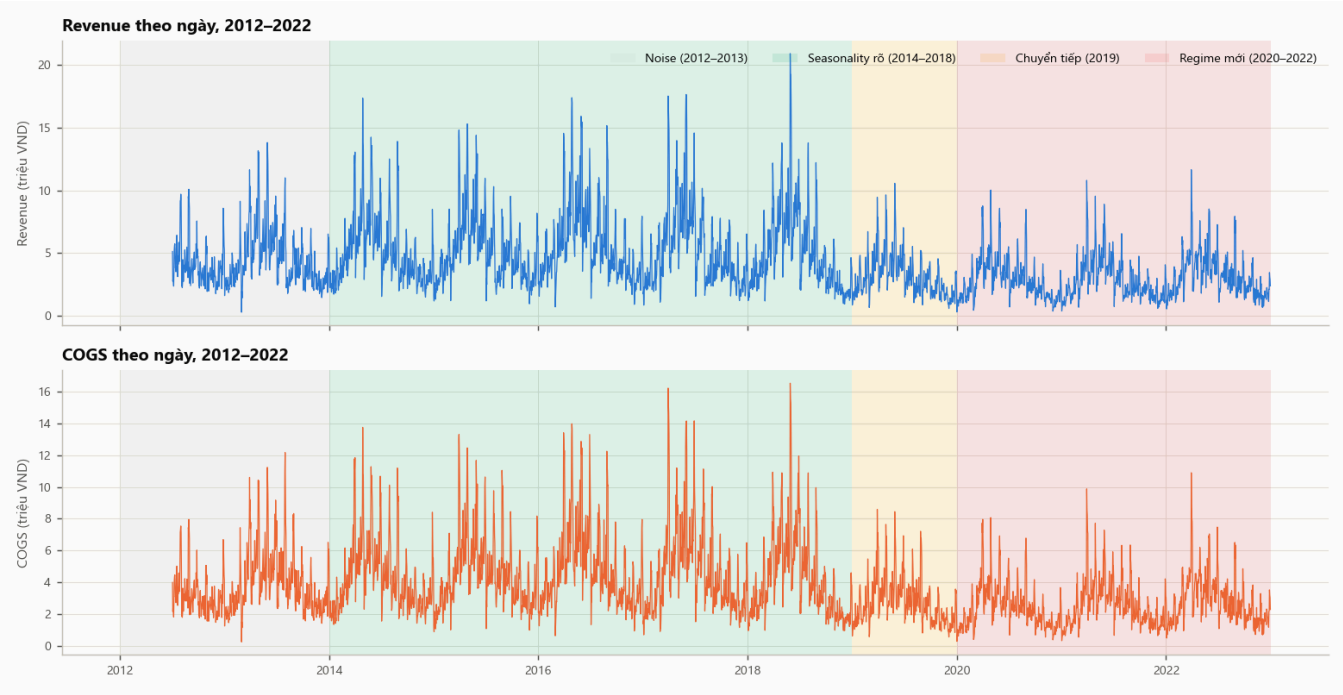
- **Input:** `sales.csv` gồm `Date`, `Revenue`, `COGS`, 3,833 ngày liên tục từ 2012-07-04 đến 2022-12-31. Các bảng phụ (orders, web_traffic, inventory…) đều dừng ở 2022 nên chỉ dùng để rút ra **quy luật lặp lại** (lịch khuyến mãi), không dùng làm đặc trưng cho giai đoạn test.
- **Output:** `submission.csv` gồm 548 dòng `Date, Revenue, COGS`.
- **Chấm điểm:** MAE, RMSE và R^2 trên cả Revenue lẫn COGS.

Vì sao bài toán khó:

1. **Horizon dài 18 tháng:** không có giá trị của hôm qua hay tuần trước, nên không dùng được đặc trưng lag (y_{t-1}, y_{t-7}). Phương án ổn định là **đặc trưng chỉ từ lịch**.
2. **Regime drift:** mức doanh thu sau 2019 khác hẳn giai đoạn trước (mục 3.1).
3. **Không có phản hồi từ test:** không biết sai ở ngày nào, nên mọi lựa chọn phải dựa trên cross-validation theo thời gian.

3. Phân tích dữ liệu

3.1. Bức tranh tổng thể: dữ liệu không đồng nhất theo thời gian

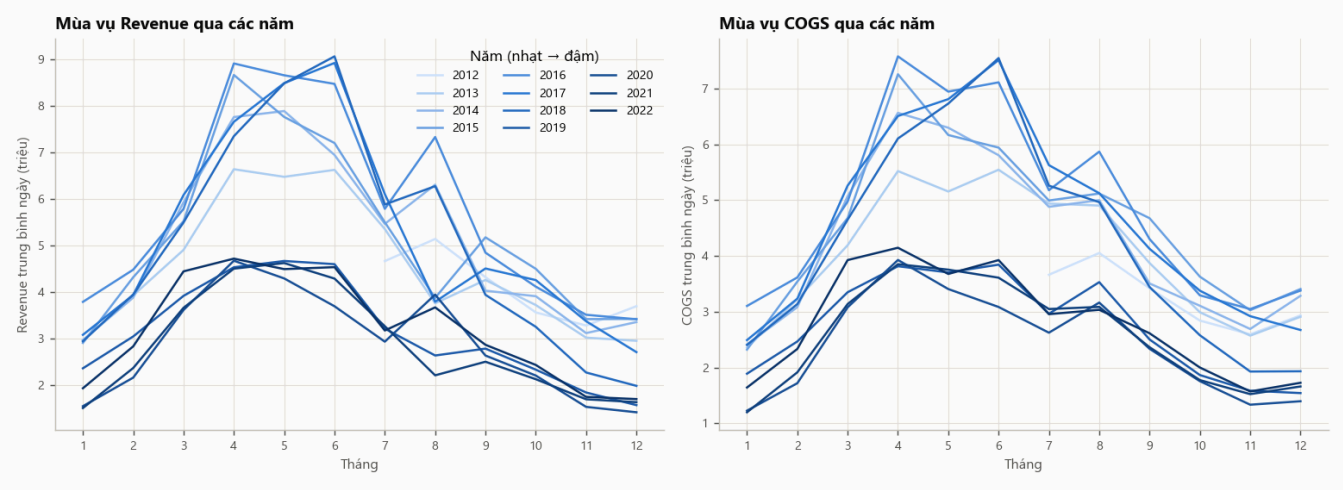


Giai đoạn	Doanh thu trung bình ngày (triệu VND)
Noise (2012–2013)	4.39
Seasonality rõ (2014–2018)	5.27
Chuyển tiếp (2019)	3.12
Regime mới (2020–2022)	2.98

Chuỗi chia thành bốn vùng có tính chất khác nhau. 2014–2018 là vùng có biên độ lớn và mùa vụ rõ nhất; năm 2019 giảm đột ngột; giai đoạn 2020–2022 là một regime mới với mức doanh thu thấp hơn **43.5%** so với 2014–2018. Từ đây có hai quyết định thiết kế:

- **Sample weighting:** ưu tiên vùng 2014–2018 khi train để mô hình học *hình dạng* mùa vụ từ vùng sạch.
- **Calibration tách rời:** vì vùng học có mức khác vùng test, cần một tầng điều chỉnh mức riêng (mục 7).

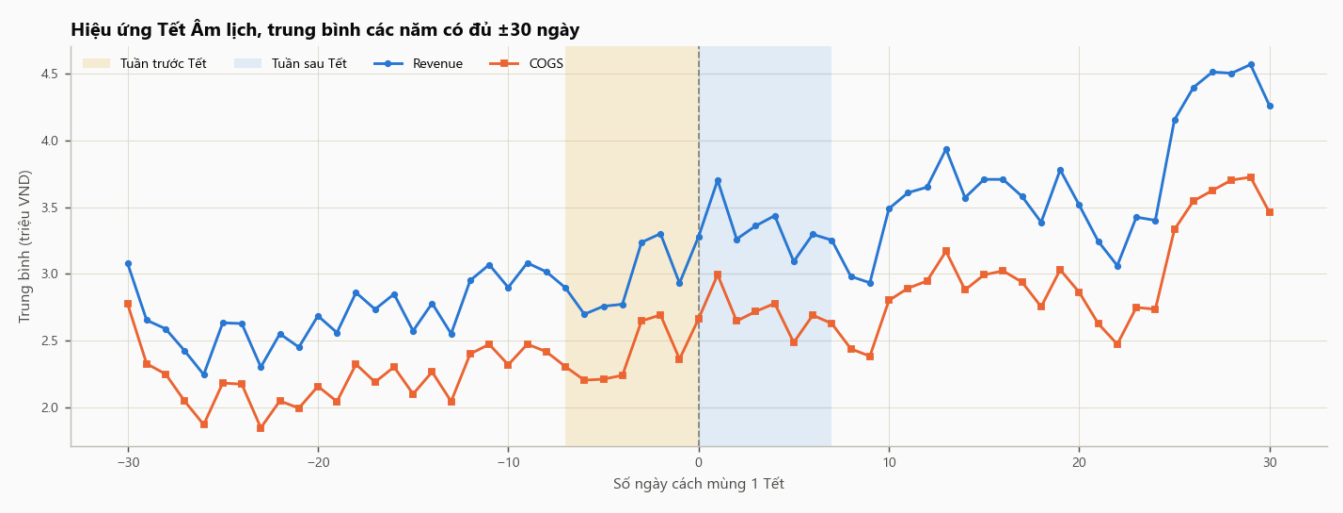
3.2. Mùa vụ có bền vững không?



Các đường cong theo năm có cùng **hình dạng**: thấp ở tháng 1–2, tăng mạnh tháng 3–4, cao nhất tháng 4–6 rồi giảm dần về cuối năm. Khác biệt giữa các năm chủ yếu nằm ở **mức** (level). Kết luận *mùa vụ bền vững, mức thay đổi* là cơ sở để dùng đặc trưng Fourier cho mùa vụ năm.

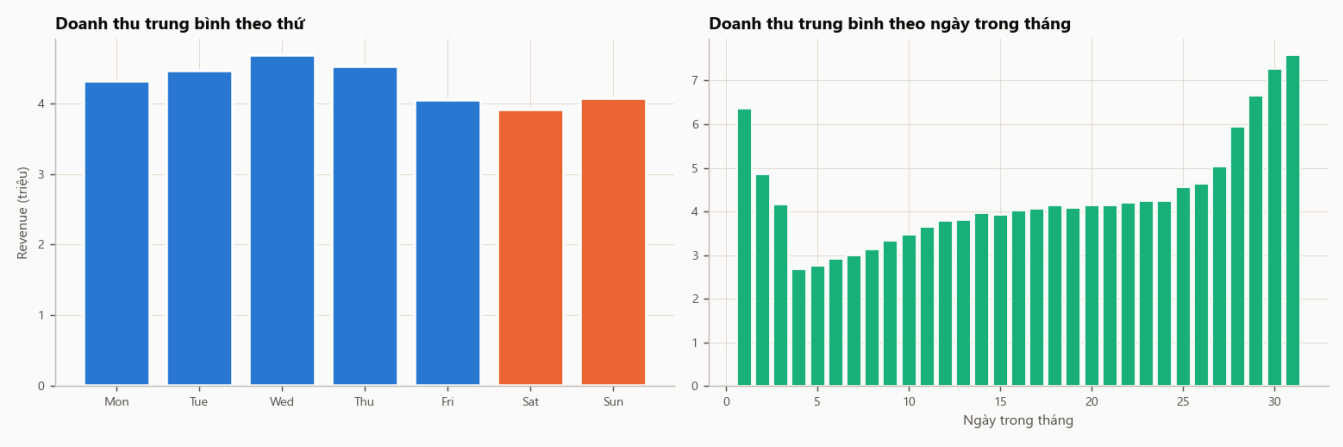
3.3. Các pattern lịch chi tiết

(a) Hiệu ứng Tết Âm lịch



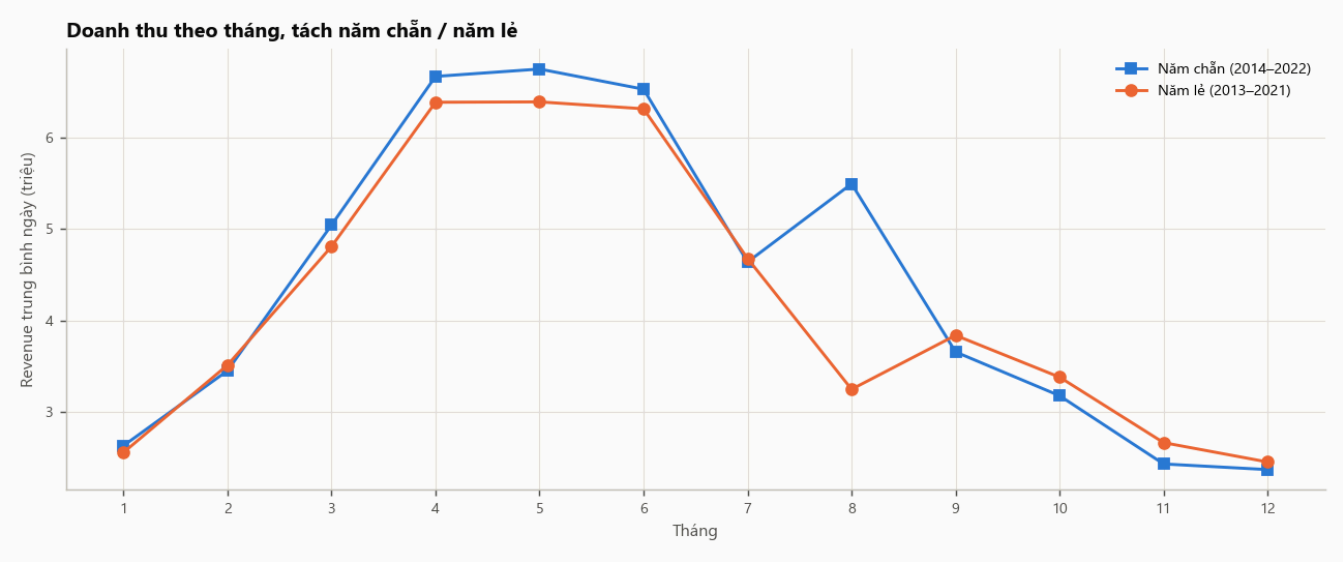
Doanh thu trung bình từ 30 đến 8 ngày trước Tết khoảng **2.70 triệu**, quanh mùng 1 (±3 ngày) khoảng **3.30 triệu**, và 20–30 ngày sau Tết lên **3.91 triệu**. Tết rơi vào ngày dương lịch khác nhau mỗi năm, nên đặc trưng theo tháng không bắt được; dùng `tet_days_diff` (khoảng cách tới mùng 1 Tết gần nhất), áp dụng được cho cả 2023 (22/01) và 2024 (10/02).

(b) Thứ trong tuần và ngày trong tháng



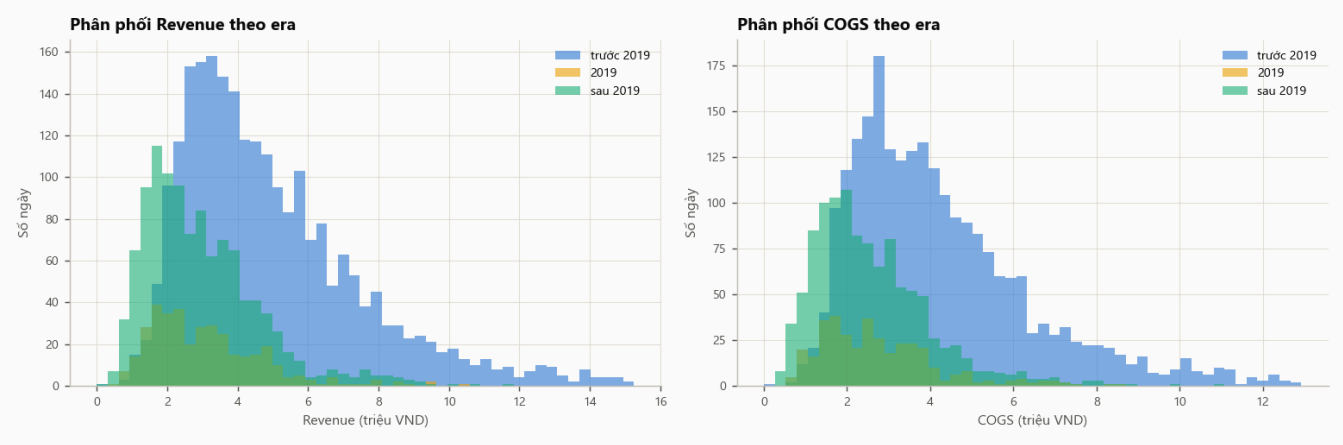
- Ngày thường trung bình **4.41 triệu**, cuối tuần **3.99 triệu**.
- Pattern ngày trong tháng mạnh hơn nhiều: 3 ngày cuối tháng trung bình **7.17 triệu**, 3 ngày đầu tháng **5.12 triệu**, so với **3.58 triệu** ở giữa tháng (ngày 4–20). Từ đây có nhóm đặc trưng `is_last1..3`, `is_first1..3` và `days_to_eom`.

(c) Chu kỳ năm chẵn / năm lẻ

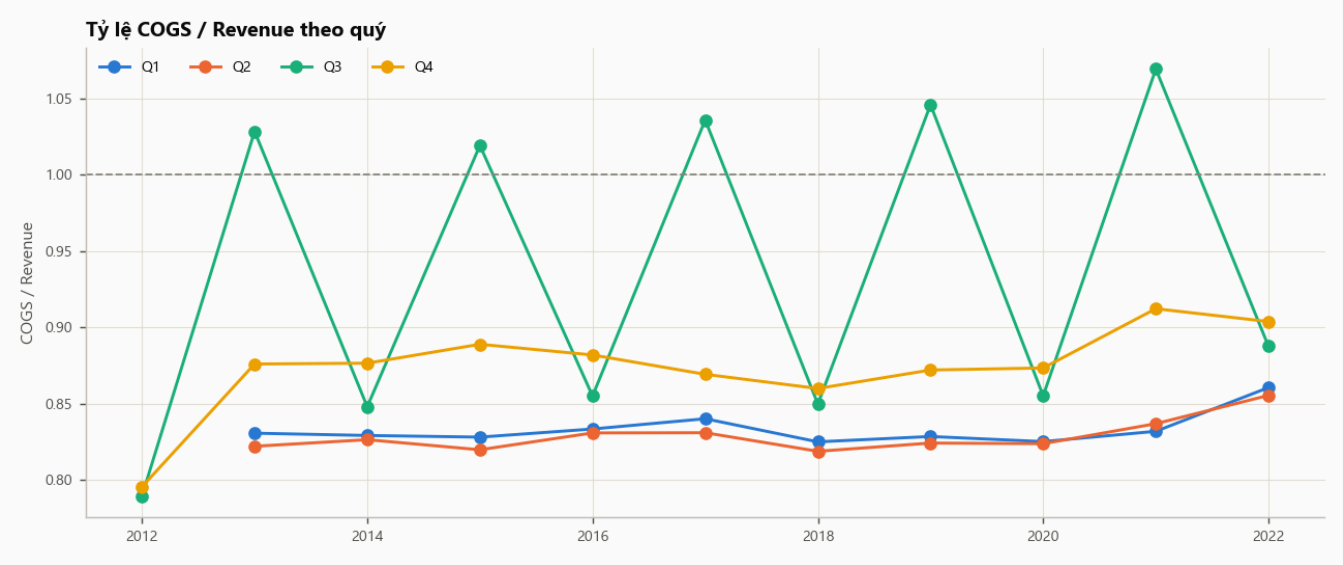


`promotions.csv` có hai chiến dịch chỉ chạy năm lẻ: `urban_blowout`, `rural_special`. Khác biệt rõ nhất ở **tháng 8**: năm chẵn trung bình **5.50 triệu**, năm lẻ **3.25 triệu**. Test gồm 2023 (lẻ) và 2024 (chẵn), nên đặc trưng `is_odd_year` cho mô hình chuyển giữa hai pattern.

3.4. Phân phối và margin theo quý

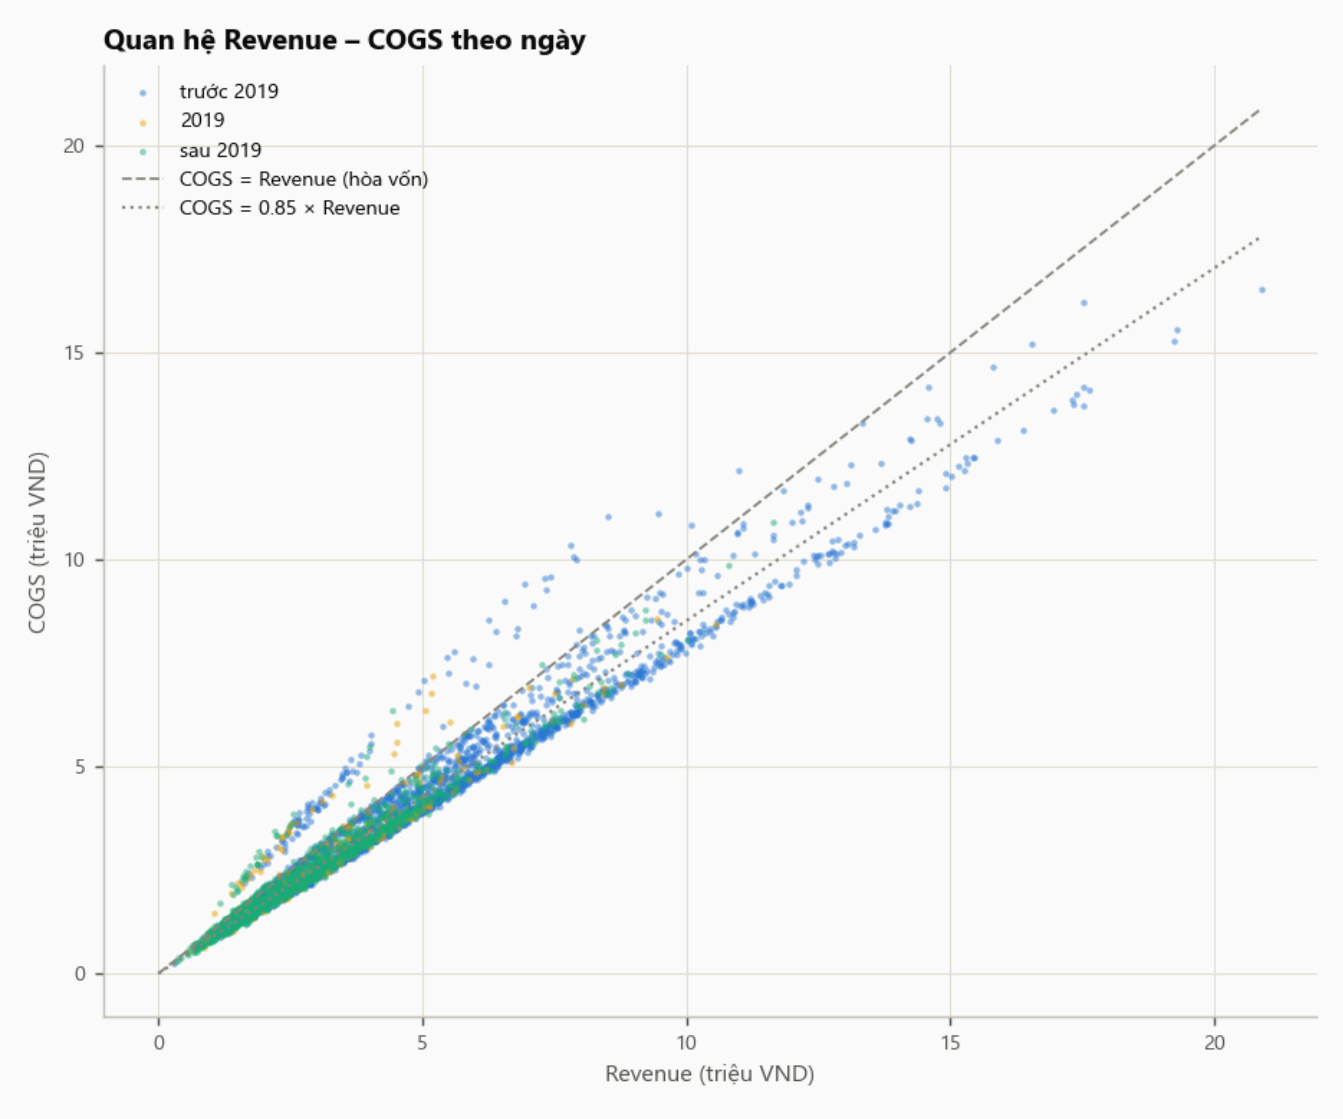


Ba era có phân phối gần như không chồng lấp. Nếu mọi mẫu có cùng trọng số, mô hình sẽ thỏa hiệp ở một mức trung bình không thuộc era nào, và dự báo 2023 bị lệch mức. Đây là lý do pipeline cần tầng calibration.



Q1, Q2, Q4 có tỷ lệ COGS/Revenue ổn định trong khoảng 0.82–0.91. Riêng **Q3 dao động theo năm chẵn/lẻ**: năm lẻ trung bình **1.04** (bán lỗ, COGS vượt Revenue), năm chẵn **0.86**. Pattern này trùng với `urban_blowout` (chỉ năm lẻ, cuối tháng 7) và dẫn tới hai ý tưởng: đặc trưng `is_odd_year` và **mô hình chuyên biệt theo quý**.

3.5. Quan hệ Revenue – COGS



COGS gần tuyến tính theo Revenue với hệ số khoảng **0.85**. Có 382 ngày COGS vượt Revenue, tập trung ở Q3 năm lẻ. Vì margin Q3 vi phạm giả định *tỷ lệ ổn định*, pipeline dự báo **COGS bằng mô hình riêng** (train trên log COGS) thay vì nhân Revenue với một tỷ lệ cố định.

Dự báo doanh thu — Mô hình, đánh giá và giải thích

Tạo tự động bởi `forecasting/02_train_forecast.py`. Phân tích dữ liệu nằm ở báo cáo trước (`forecasting_eda.md`); mọi con số dưới đây là kết quả chạy thật, `random_state = 42`.

4. Feature engineering

Mọi đặc trưng tính được từ ngày tháng (`forecasting/features.py`), tổng cộng **81 đặc trưng**, nên ma trận đặc trưng cho 2023–2024 dựng sẵn được mà không cần doanh thu của test:

Nhóm	Đặc trưng	Từ quan sát nào
Lịch cơ bản	năm, tháng, ngày, thứ, ngày trong năm, quý, cuối tuần	Mùa vụ năm, thứ trong tuần (mục 3.2, 3.3)
Đầu / cuối tháng	`is_first1..3`, `is_last1..3`, `days_to_eom`, `days_from_som`	Cuối tháng cao gấp đôi giữa tháng (3.3b)
Xu hướng + chế độ	`t_days`, `regime_pre2019`, `regime_2019`, `regime_post2019`	Regime drift (3.1)
Fourier	sin/cos năm k = 1..5, tuần và tháng k = 1..2	Hình dạng mùa vụ bền vững (3.2)
Lễ	10 ngày lễ dương lịch cố định ở Việt Nam, Black Friday	Ngày mua sắm
Tết Âm lịch	`tet_days_diff`, `tet_in_7`, `tet_in_14`, `tet_before_7`, `tet_after_7`, `tet_on`	Hiệu ứng Tết (3.3a)
Khuyến mãi	trạng thái, số ngày đã/còn lại và mức giảm của 6 chiến dịch	Lịch khuyến mãi
Năm lẻ	`is_odd_year`	Chu kỳ chẵn/lẻ, margin Q3 (3.3c, 3.4)

Lịch khuyến mãi suy từ `promotions.csv` (không dùng dữ liệu ngoài): mỗi chiến dịch lặp lại cùng ngày bắt đầu và thời lượng mỗi năm.

Chiến dịch	Bắt đầu	Thời lượng	Mức giảm	Lặp lại
`spring_sale`	18/03	30 ngày	12	hằng năm
`mid_year_sale`	23/06	29 ngày	18	hằng năm
`fall_launch`	30/08	32 ngày	10	hằng năm
`year_end_sale`	18/11	45 ngày	20	hằng năm
`urban_blowout`	30/07	34 ngày	50	chỉ năm lẻ
`rural_special`	30/01	30 ngày	15	chỉ năm lẻ

Ngày Tết Âm lịch và ngày lễ là **kiến thức lịch**, không phải bộ dữ liệu bên ngoài.

5. Chiến lược validation

Ba fold theo thời gian, không xáo trộn dữ liệu:

Fold	Train	Validate	Vai trò
A (chính)	≤ 2021-12	2022	2022 gần phân phối test nhất; dùng để ước lượng hệ số calibration
B (ổn định)	≤ 2020-12	2021	Kiểm tra cải tiến có ổn định qua năm không
C (horizon)	≤ 2021-06	2021-07 → 2022-06	Cửa sổ 12 tháng liên tục, gần horizon thật

Hai thước đo: **MAE/RMSE/R^2 thông thường** và **MAE hình dạng** (đưa dự báo về đúng tổng của tập validate trước khi tính MAE). MAE hình dạng tách được chất lượng *hình dạng* khỏi vấn đề *mức*, vốn do tầng calibration xử lý.

6. Lựa chọn và huấn luyện mô hình

Ba họ mô hình khác bản chất để ensemble có diversity:

- **M1 Ridge + Fourier:** tuyến tính trên đặc trưng chuẩn hóa z-score, train trên log(target), $\alpha = 3$. Ổn định, làm *anchor*.
- **M2 LightGBM high_era:** trọng số 1.0 cho 2014–2018, 0.01 cho phần còn lại; learning rate 0.03, 63 lá. Train 2 giai đoạn: early stopping trên 180 ngày cuối để chọn số vòng, rồi train lại trên toàn bộ dữ liệu.
- **M2q 4 Q-specialist:** cùng cấu hình M2, nhân trọng số ×2 cho quý phụ trách. Khi dự báo, mỗi ngày lấy dự báo của specialist đúng quý của ngày đó (không lấy trung bình). Tổng cộng 4 quý × 2 target = 8 mô hình.
- **M3 Prophet + promos:** học từ 2020 trở đi (trend không bị bước nhảy 2019 bóp méo); fold nào train kết thúc sớm thì lùi về đủ 2 năm gần nhất để mùa vụ năm không bị thiếu dữ liệu. Mùa vụ năm và tuần dạng multiplicative, regressor là cửa sổ của các chiến dịch khuyến mãi.

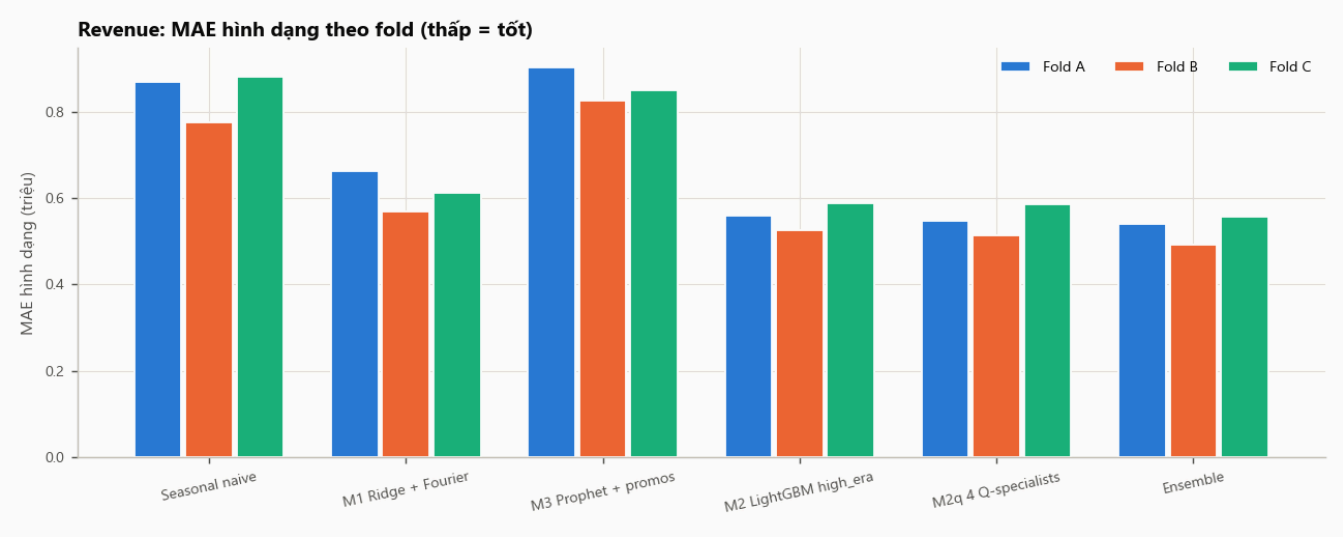
Diversity (tương quan sai số trên fold A, Revenue): Ridge vs Prophet = 0.71, Ridge vs LGB = 0.70, Prophet vs LGB = 0.56.

7. Ensemble phân tầng và calibration

Tầng	Công thức	Tham số
1. Hợp nhất họ LightGBM	$\text{LGB_blend} = (1 - \alpha)\cdot M2 + \alpha\cdot M2q$	$\alpha = 1.00$
2. Hợp nhất 3 họ	$\text{raw} = w_1\cdot M1 + w_3\cdot M3 + w_2\cdot \text{LGB_blend}$	$w_1 = 0.30$, $w_3 = 0.00$, $w_2 = 0.70$
3. Calibration mức	$\text{final} = c \times \text{raw}$	$c_{Revenue} = 1.080$, $c_{COGS} = 1.097$

- **α và trọng số** chọn bằng lưới (bước 0.1 cho α, 0.05 cho trọng số) để tối thiểu **MAE hình dạng** trung bình trên 3 fold và cả 2 target.
- **Calibration:** c = tổng thực tế 2022 ÷ tổng dự báo 2022 của mô hình train đến 2021 (fold A), rồi áp cho mô hình train đến 2022 dự báo 2023–2024. Hệ số tách khỏi tầng blend vì vấn đề *mức* khác vấn đề *hình dạng*.
- **Khác tài liệu tham chiếu:** tài liệu chỉnh c trực tiếp trên Leaderboard. Ở đây không dùng Leaderboard; c ước lượng hoàn toàn từ dữ liệu train, nên không có rò rỉ từ test.

8. Kết quả cross-validation



Revenue: trung bình 3 fold

Mô hình	MAE	RMSE	R^2	MAE hình dạng	Mức dự báo / thực tế
Seasonal naive (cùng thứ, năm trước)	840,592	1,232,949	0.450	841,854	0.96
M1 Ridge + Fourier	644,597	944,853	0.676	614,467	0.89
M3 Prophet + promos	965,129	1,344,605	0.344	859,008	1.07
M2 LightGBM high_era	558,011	770,167	0.785	557,283	0.96
M2q 4 Q-specialists	554,011	748,401	0.797	548,801	0.96
Ensemble (chưa calibration)	545,430	744,724	0.799	529,566	0.94

COGS: trung bình 3 fold

Mô hình	MAE	RMSE	R^2	MAE hình dạng	Mức dự báo / thực tế
Seasonal naive (cùng thứ, năm trước)	686,869	1,012,621	0.518	684,908	0.92
M1 Ridge + Fourier	588,239	861,485	0.650	543,010	0.88
M3 Prophet + promos	860,172	1,195,796	0.327	762,693	1.08
M2 LightGBM high_era	506,871	697,915	0.771	495,771	0.94
M2q 4 Q-specialists	498,365	682,245	0.781	486,066	0.93
Ensemble (chưa calibration)	497,684	690,590	0.776	473,413	0.92

Đánh giá trung thực của tầng calibration (fold A, 2022): áp hệ số ước lượng từ fold B (năm 2021) lên dự báo 2022, mô phỏng đúng cách hệ số được dùng cho 2023–2024.

Target	Mô hình	MAE	RMSE	R^2
Revenue	Seasonal naive (cùng thứ, năm trước)	863,664	1,247,432	0.445
Revenue	Ensemble (chưa calibration)	566,967	762,150	0.793
Revenue	Ensemble + calibration	544,238	736,157	0.807
COGS	Seasonal naive (cùng thứ, năm trước)	714,915	1,035,433	0.496
COGS	Ensemble (chưa calibration)	513,189	685,735	0.779

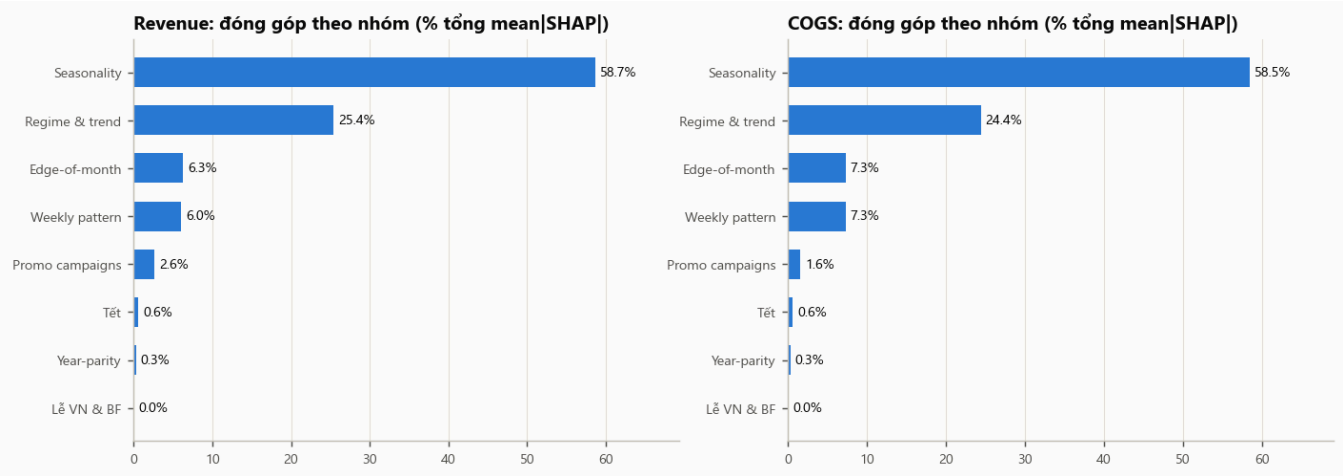
Target	Mô hình	MAE	RMSE	R^2
COGS	Ensemble + calibration	478,695	635,536	0.810

Hệ số ước lượng từ fold B: $c_{Revenue}$ = 1.037, c_{COGS} = 1.075.

9. Khả năng giải thích mô hình (SHAP)

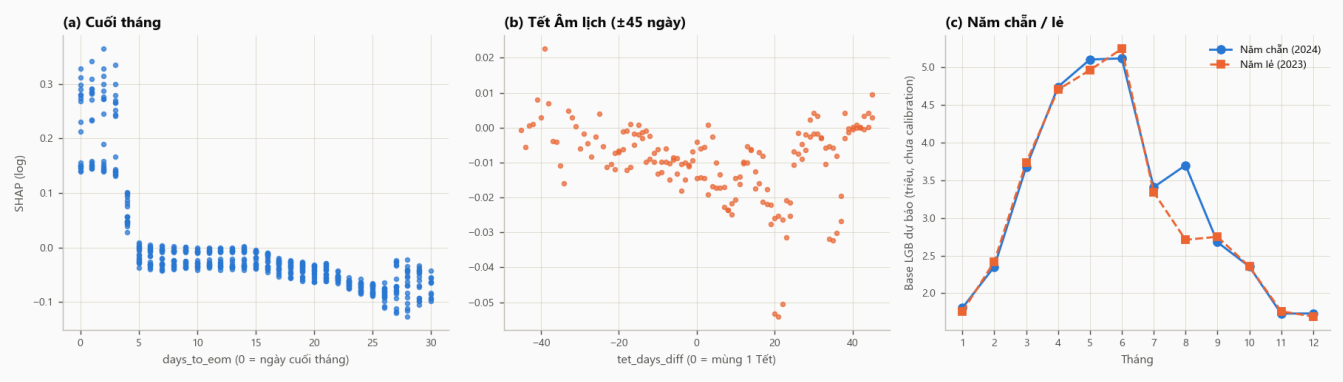
Giải thích **base LightGBM** cuối (train trên toàn bộ 2012–2022), đại diện cho họ cây trong ensemble. TreeSHAP tính trực tiếp qua `predict(pred_contrib=True)`, chính xác cho mô hình cây. Kiểm tra tính cộng tính (base value + Σ SHAP = dự báo log): sai số lớn nhất 4.6e-14. Vì mô hình học trên log, đóng góp Δ quy ra phần trăm doanh thu theo $e^{\Delta} - 1$.

9.1. Global importance



Nhóm pattern	Revenue (%)	COGS (%)
Seasonality	58.7	58.5
Regime & trend	25.4	24.4
Edge-of-month	6.3	7.3
Weekly pattern	6.0	7.3
Promo campaigns	2.6	1.6
Tết	0.6	0.6
Year-parity	0.3	0.3
Lễ VN & BF	0.0	0.0

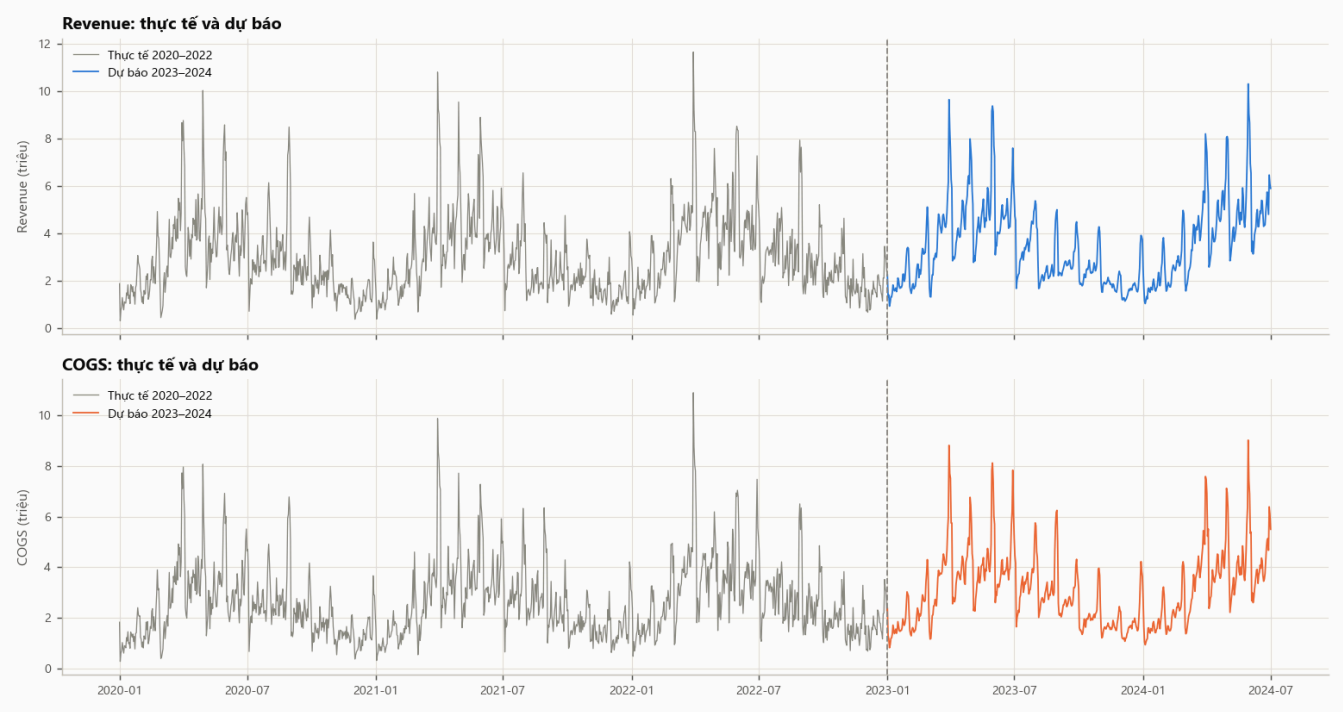
9.2. Local effect



Global importance đo trung bình trên cả 548 ngày, nên pattern hiếm như Tết có global thấp dù tác động cục bộ rõ. Bảng dưới đo tác động ngay tại những ngày pattern xuất hiện: *chênh lệch tổng* cộng SHAP của mọi đặc trưng, *SHAP cô lập* chỉ cộng nhóm đặc trưng của driver.

Driver	Chênh lệch dự báo tổng	SHAP cô lập của nhóm driver
Ngày cuối tháng vs giữa tháng (13–17)	+72.6%	+29.1%
±7 ngày quanh Tết vs cách Tết > 30 ngày	-43.5%	-1.0%
Tháng 8 năm chẵn (2024) vs năm lẻ (2023)	+39.7%	+0.8%

10. Dự báo và ý nghĩa kinh doanh



Target	Thực tế 2021	Thực tế 2022	Dự báo 2023	Thực tế 6 tháng đầu 2022	Dự báo 6 tháng đầu 2024
Revenue	1.04 tỷ	1.17 tỷ	1.18 tỷ	0.69 tỷ	0.71 tỷ
COGS	0.94 tỷ	1.02 tỷ	1.08 tỷ	0.59 tỷ	0.61 tỷ

File nộp: `forecasting/submission.csv`, 548 dòng `Date, Revenue, COGS`, theo thứ tự ngày từ 2023-01-01 đến 2024-07-01.